DAGs

2025-08-28

Plan

- Identificación
- Introducción a los DAGs
- Las tres estructuras canónicas
- Estructuras combinadas
- Caminos causales y de backdoor
- Caminos abiertos y cerrados
- Selección muestral

Objetivos de aprendizaje

Al finalizar esta clase, podrás:

- **Leer e interpretar** un DAG causal
- **Identificar** mediadores, confusores y colisionadores
- **Determinar** qué variables controlar para identificar un efecto causal
- **Reconocer** el sesgo por selección muestral como un caso de colisionador

Identificación

Consideremos un problema estándar en economía laboral: estimar los retornos de la educación.

Nuestra tarea es aislar el impacto causal de ir a la universidad.

Motivación

Imaginemos un modelo de acumulación de capital humano.

Los salarios dependen de la educación y las habilidades, mientras que la elección educativa está influenciada por la habilidad.

Tal vez obtengamos algo como:

$$
\begin{aligned}
W &= f_w(E, A, \epsilon_w) = \alpha_1 E + \alpha_2 A + \epsilon_w \\
E &= f_e(A, \epsilon_e) = \beta A + \epsilon_e \\
A &= f_a(\epsilon_a) = \epsilon_a
\end{aligned}
$$

Donde todos los errores son independientes entre sí, con media cero: $\epsilon_w \perp \epsilon_e \perp \epsilon_a$.

Motivación

Supongamos que la habilidad no es observable.

Si simplemente comparamos los salarios de personas con distintos niveles de educación, obtendremos un estimador sesgado del retorno de la educación.

Bajo supuestos de linealidad y estimación por MCO:

$$\frac{\text{cov}(W, E)}{\text{var}(E)} = \alpha_1 + \alpha_2 \cdot \frac{\beta \, \text{var}(\epsilon_a)}{\beta^2 \, \text{var}(\epsilon_a) + \text{var}(\epsilon_e)}$$

El segundo término es el **sesgo de variable omitida**: desaparece solo si $\alpha_2 = 0$ (la habilidad no afecta salarios) o $\beta = 0$ (la habilidad no afecta educación).

Motivación

Ahora supongamos que sabemos que la habilidad depende de la genética y del entorno familiar. De hecho, suponemos que la habilidad no observable es similar entre hermanos — varía más entre familias que dentro de ellas.

Basándonos en este conocimiento, suponemos que si comparamos dos hermanos con distintos niveles de educación, la variación en habilidad entre ellos es menor que entre familias. Entonces, cualquier diferencia sistemática entre ellos debe deberse a la universidad. (Esta es la estrategia de Ashenfelter & Krueger, 1994, con gemelos idénticos.)

Identificación

Usamos nuestro conocimiento del **proceso generador de datos** para elegir una comparación que corresponde al parámetro teórico que nos interesa.

Identificación no es un proceso *estadístico*, sino un proceso *conceptual*.

La estrategia de identificación no está en los datos, está en el plano teórico.

Identificación

El conocimiento sobre el DGP (proceso generador de datos) puede provenir de diversas fuentes:

- Teoría económica: expectativas racionales, maximización de beneficios
- Otras ciencias: epidemiología, genética, meteorología
- Conocimiento contextual: cómo funcionan las políticas públicas, reglas administrativas
- Contexto histórico: patrones de desarrollo

Identificación

Lo que queremos aprender del **DGP** es esencialmente:

- Qué variables están causalmente relacionadas
- Qué variables no están causalmente relacionadas
- Qué variables están correlacionadas debido a causas comunes
- Qué variables debemos mantener fijas para identificar relaciones causales

Identificación

Podríamos escribir un modelo formal y trabajar a través de las ecuaciones.

Sin embargo, eso puede ser bastante tedioso y complicado.

Nos interesa principalmente saber si existen relaciones causales y en qué dirección: podemos pensar en las formas funcionales y otros detalles más adelante.

Por eso, vamos a intentar resumir la información del DGP de una manera que sea más fácil de trabajar.

Representación gráfica

Comencemos representando gráficamente una relación causal.

- Los nodos representan variables
- Las flechas entre ellos representan una relación causal

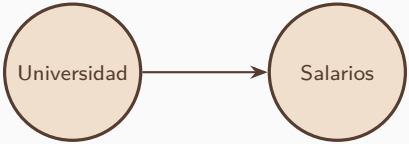

¿Qué captura un DAG?

Cuando tenemos un diagrama con $X \to Y$ abstraemos de:

- La magnitud de la relación
- El signo de la relación
- La forma funcional
- Lo único que importa es que exista alguna relación causal.

Por supuesto, cualquier proceso generador de datos interesante tendrá más de dos variables.

Las tres estructuras canónicas

Toda relación causal entre tres variables toma una de estas tres formas:

- **Mediador**: el efecto de X sobre Y pasa a través de M ($X \to M \to Y$)
- **Confusor**: X e Y comparten una causa común C ($X \leftarrow C \to Y$)
- **Colisionador**: X e Y son causas comunes de K ($X \to K \leftarrow Y$)

Mediador

Veamos este caso:

¿Qué nos dice este diagrama?

Mediador: lectura del diagrama

¿Qué nos dice este diagrama?

- La educación causa capital humano
- El capital humano causa salarios
- La educación causa salarios indirectamente, pero no directamente

Mediador: intuición

Intuición: en este diagrama E $\rightarrow$ Capital Humano $\rightarrow$ Salarios, si mantenemos constante el Capital Humano, la educación ya no puede afectar los salarios a través de él — esa ruta queda bloqueada.

Condicionamos para *detener el flujo de información* a través de un camino.

Pero ojo: esta lógica funciona distinto para colisionadores.

Condicionar en una variable

Introducimos un nuevo concepto: condicionar en una variable.

- Cuando decimos que estamos condicionando en una variable, significa que estamos, de alguna forma, manteniéndola constante.
- En general, podemos hacerlo incluyendo la variable como un control en una regresión, pero hay otras maneras.
- Cuando condicionamos en un **no-colisionador** en un camino abierto, **ese camino se cierra**.
- Los colisionadores se comportan al revés: el camino está cerrado por defecto, y condicionar en ellos **lo abre**.

Mediador: independencia condicional

- Si mantenemos constante el capital humano, no debería haber correlación entre educación y salarios

$$\text{Salarios} \perp \text{Educación} \mid \text{Capital Humano}$$

- Mantener constante el capital humano bloquea el camino de dependencia
- Podemos decir que el capital humano es un **mediador**

Confusor

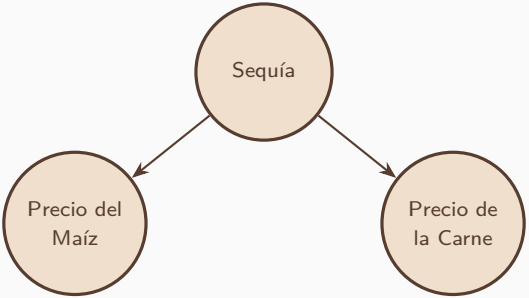

¿Qué tipo de correlaciones podemos esperar en este diagrama?

Confusor: correlación espuria

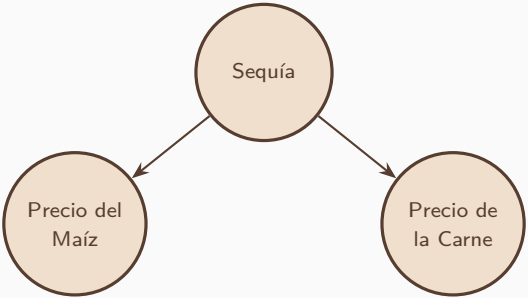

- El precio del maíz está correlacionado con el precio de la carne, porque tienen una causa común: la sequía encarece el forraje y reduce la producción ganadera.
- Pero no están correlacionados si condicionamos en la sequía.

Confusor vs. mediador

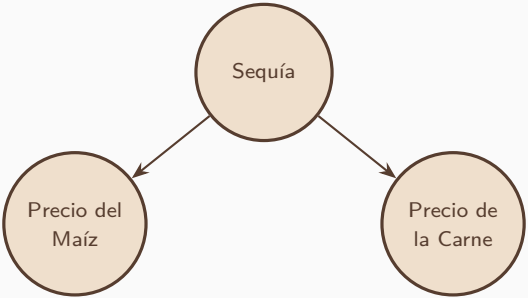

- La estructura de correlación es la misma que en el caso del mediador.
- Pero esta relación no es causal.
- Llamamos a esto una correlación espuria, o un camino de backdoor.

Mediador vs. confusor: la misma distribución

Implicación fundamental: el mediador y el confusor producen exactamente la misma distribución observable de los datos.

Esto significa que los datos solos **no pueden distinguir** entre las dos historias causales. Por ejemplo, la correlación entre educación y salarios podría reflejar:

- **Mediador:** la educación genera capital humano, que aumenta salarios (política educativa funciona)
- **Confusor:** la habilidad innata causa tanto más educación como mayores salarios (la correlación es espuria)

Ambas historias generan la misma correlación observada, pero tienen implicancias de política opuestas. Necesitamos conocimiento del DGP — teoría económica, diseño institucional, contexto — para saber cuál estructura aplica.

Confusor: condicionar cierra el camino

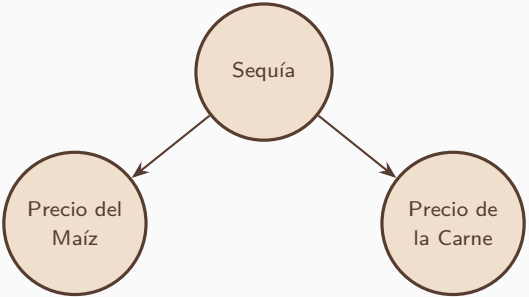

- Si condicionamos en la sequía, se cierra el camino entre las variables. Así, la correlación cambiaría a cero.

Colisionador

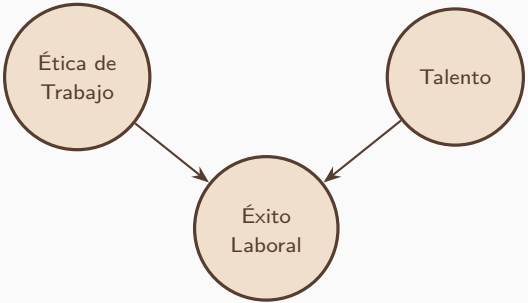

¿Qué tipo de correlaciones podemos esperar en este caso?

Colisionador: correlación marginal

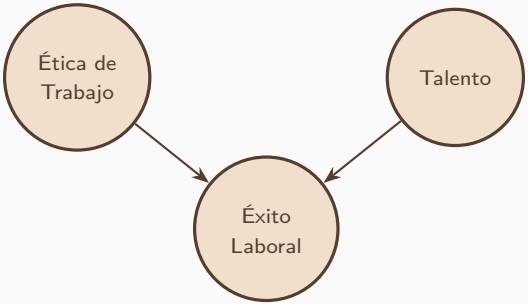

- El éxito laboral está correlacionado tanto con la ética de trabajo como con el talento.
- Pero la ética de trabajo y el talento son independientes.

Colisionador: ¿qué pasa si condicionamos?

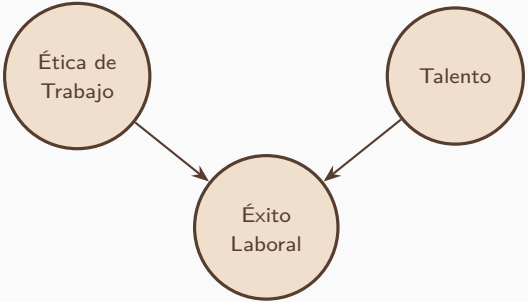

¿Qué pasa si condicionamos en el éxito laboral?

Colisionador: piensa y discute

Tómate 30 segundos: si condicionamos en el éxito laboral, ¿qué predices que ocurrirá con la correlación entre ética de trabajo y talento?

(Discute con un compañero si es posible)

Colisionador: respuesta

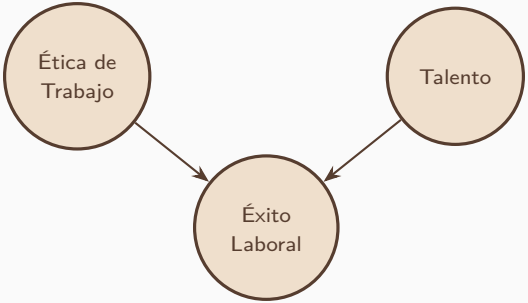

¿Qué pasa si condicionamos en el éxito laboral?

¡Si condicionamos, **creamos una correlación!**

Para mediadores y confusores, condicionar cierra un camino abierto. Los colisionadores funcionan al revés: el camino está cerrado por defecto, y condicionar en ellos **lo abre**.

Colisionador

Este diagrama causal se llama un **colisionador** (*collider*).

Condicionar en el colisionador genera lo que se llama **sesgo del colisionador** (*collider bias*): una forma de correlación espuria.

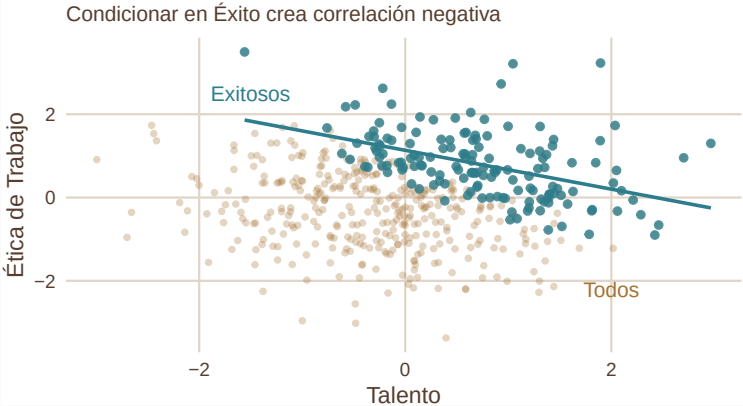

Las tres estructuras: resumen rápido

Estructura	Camino	¿Condicionar?
Mediador	$X \to M \to Y$	Solo si quieres el efecto directo
Confusor	$X \leftarrow C \to Y$	**Sí** — bloquea la correlación espuria
Colisionador	$X \to K \leftarrow Y$	**No** — abriría una correlación espuria

Verificación: ¿puedes identificar cuál es cuál en los ejemplos anteriores?

Ejercicio rápido (10 min)

Para cada diagrama, identifica la estructura y decide si debes condicionar en Z:

1. Fumar $\rightarrow$ Z (Alquitrán) $\rightarrow$ Cáncer
2. Genética $\rightarrow$ Fumar, Genética $\rightarrow$ Cáncer (Z = Genética)
3. Tasa de Interés $\rightarrow$ Z (Inversión) $\leftarrow$ Expectativas
4. Un investigador quiere estimar el efecto de X sobre Y. Observa que X $\rightarrow$ Y, y también X $\rightarrow$ M $\rightarrow$ Y, y que existe un confusor C tal que X $\leftarrow$ C $\rightarrow$ Y. ¿En qué variable(s) debe condicionar?

(Discute con un compañero y luego revisamos juntos)

Segunda parte

Cubrimos las tres estructuras canónicas y cómo condicionar las afecta.

Ahora:

- Estructuras combinadas
- Caminos causales y de backdoor
- Aplicaciones: discriminación de género, selección muestral

Estructuras combinadas

Tomemos cada una de estas tres estructuras y agreguemos otro vínculo causal.

Nuestro objetivo es entender qué relaciones son causales, y cómo se correlacionan las variables, con y sin condicionamiento.

Mediador + efecto directo

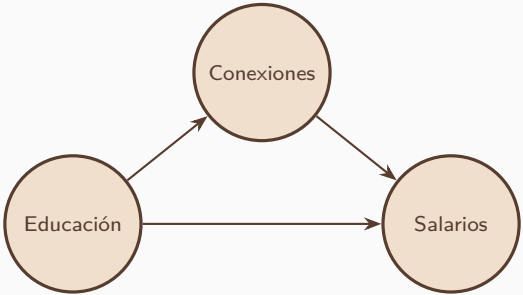

¿Cuál es el efecto **causal** de la educación sobre los salarios?

Mediador + efecto directo: efecto total

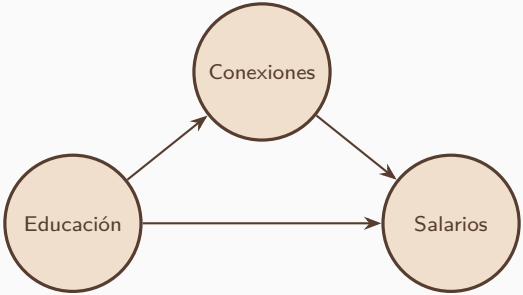

El efecto causal consiste tanto en el efecto directo como en el efecto indirecto a través de las conexiones.

Podemos estimar el efecto causal simplemente observando la relación entre las dos variables.

Mediador + efecto directo: efecto directo puro

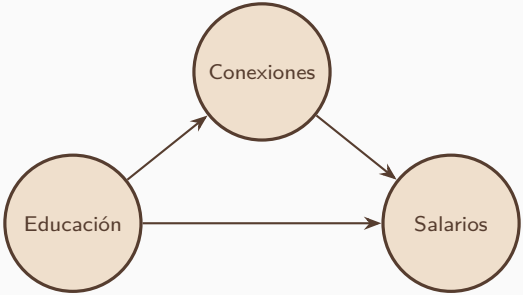

Sin embargo, puede que nos interese estudiar un mecanismo específico de forma aislada.

Si condicionamos en las conexiones, podemos obtener el **efecto directo puro** — siempre que no haya otras variables que afecten tanto al mediador como al resultado.

Confusor + efecto directo

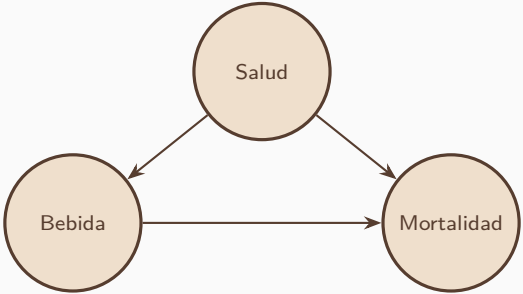

¿Qué deberíamos esperar aquí?

Confusor + efecto directo: sesgo

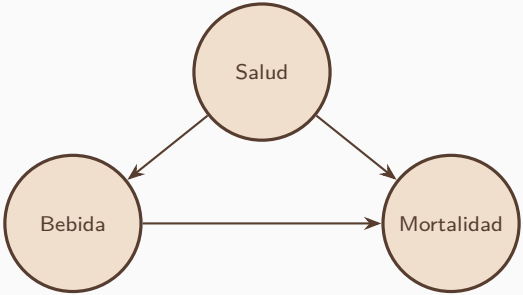

Este es el clásico **confusor (confounder)**.

- Salud crea una correlación espuria entre la bebida y mortalidad.
- Si no condicionamos en la salud, obtendremos una mezcla del efecto directo y de la correlación espuria.

Colisionador + efecto directo

Queremos estudiar si un ingreso más alto lleva a mayores ahorros, pero nos preocupa el papel del patrimonio total.

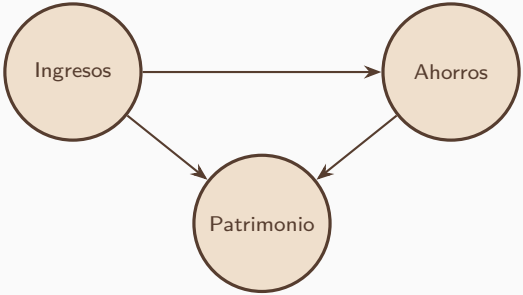

¿Qué sugiere este diagrama que deberíamos hacer?

Colisionador + efecto directo: no condicionar

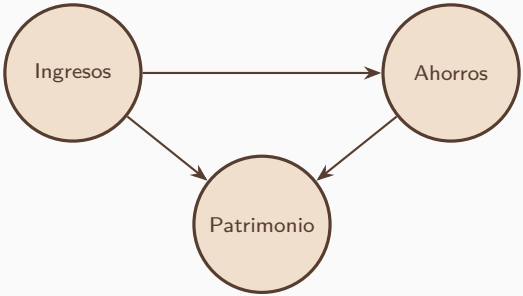

- Podemos estimar la relación directamente.
- El patrimonio no es un confusor, sino un colisionador.
- Si condicionamos en el patrimonio, creamos un sesgo.

Ciclos

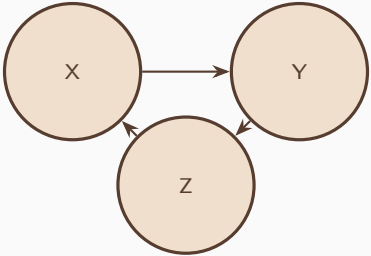

La última estructura posible con 3 nodos y 3 flechas es el ciclo.

Para trabajar con diagramas causales, **NO PODEMOS** tener ciclos.

Introducción a los DAGs

¿Cómo podemos tratar con modelos que incluyen retroalimentación?

Una opción es incorporar explícitamente el tiempo:

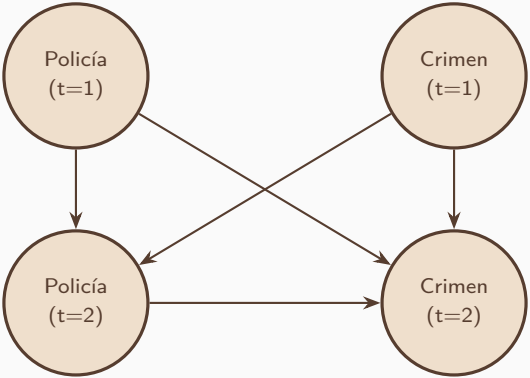

Construyendo un DAG

Vamos a usar esta herramienta para representar el DGP.

- Es importante incluir todas las variables relevantes.
- Igualmente importante es pensar en qué variables no están conectadas.
- La independencia es una suposición fuerte.

Vamos a denotar los factores no observables con líneas punteadas:

El DGP completo

¿Qué historia nos cuenta esta figura?

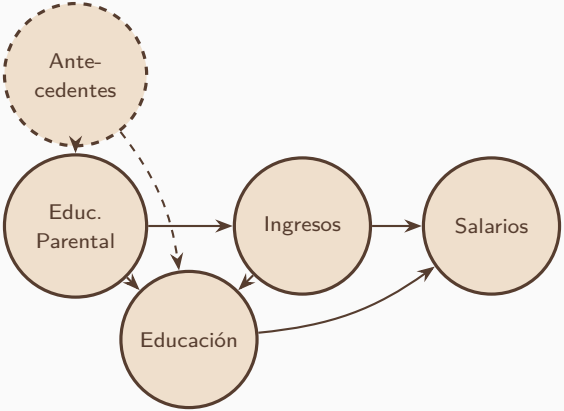

El DGP completo

¿Cómo leer un DAG complejo?

1. Identifica las variables de interés (aquí: Educación $\rightarrow$ Salarios)
2. Busca los **caminos causales** (todas las flechas apuntan hacia el resultado)
3. Busca caminos de **backdoor** (empiezan con $\leftarrow$ desde Educación)
4. Para cada camino: ¿hay un colisionador? $\rightarrow$ si sí, está cerrado por defecto

Intentémoslo con este diagrama.

Todos los caminos

Todos los caminos posibles desde Educación hasta Salarios

- Educación $\rightarrow$ Salarios
- Educación $\leftarrow$ Ingresos $\rightarrow$ Salarios
- Educación $\leftarrow$ Educ. Parental $\rightarrow$ Ingresos $\rightarrow$ Salarios
- Educación $\leftarrow$ Antecedentes $\rightarrow$ Educ. Parental $\rightarrow$ Ingresos $\rightarrow$ Salarios

Caminos buenos y malos

Toda investigación comienza con una pregunta de interés.

Los caminos causales "buenos" son los que corresponden a tu pregunta:

- Pueden ser todos los caminos causales de una variable a otra
- O puede ser que te interese solo uno en particular

Los caminos "malos" son aquellos que generan correlaciones espurias, no relacionadas con tu pregunta.

Caminos causales directos y de backdoor

- Un **camino causal directo** solo tiene flechas desde la variable de interés hacia el resultado
  - Representa una asociación verdaderamente causal
- Un camino Backdoor incluye flechas en dirección contraria
- Educación $\leftarrow$ Ingresos Familiares $\rightarrow$ Salarios es un camino de backdoor
  - Los caminos de backdoor crean correlaciones espurias si están abiertos
- Si cerramos todos los caminos de backdoor **sin abrir colisionadores**, hemos identificado el efecto causal. Esta es la **Condición de Puerta Trasera** (*Backdoor Criterion*), y será la base de todas las estrategias de identificación que estudiaremos en el curso.

Caminos abiertos y cerrados

- ¿Cómo lidiamos con los caminos de backdoor?
  - ¡Los cerramos!
- Esto significa que intentamos detener la cadena causal
- Hay dos formas principales:
  - Control estadístico
  - Un camino también se cierra si tiene un **colisionador**

Caminos abiertos y cerrados

La forma principal de cerrar un camino es controlar al menos una de las variables en ese camino

- Esto significa usar estadística para "mantenerla constante"
- Podemos usar controles en regresiones u otros métodos similares.

Caminos abiertos y cerrados

Un colisionador es una variable que recibe flechas de ambos lados:

- El camino $X \to Z \to Y$ es directo
- El camino $X \to Z \leftarrow Y$ está bloqueado

Advertencia: Controlar un colisionador abre este camino bloqueado

Ejemplo 1

Existe un gran debate sobre la discriminación de género en el mercado laboral, principalmente en el sector de tecnología.

Google, por ejemplo, fue acusado de ofrecer *menores salarios* para sus trabajadoras mujeres.

Google dice que, cuando se comparan hombres y mujeres con el mismo nivel de puesto, desempeño, antigüedad y ubicación, sus salarios son básicamente idénticos.

Ejemplo 1

Vamos a trabajar con ese modelo.

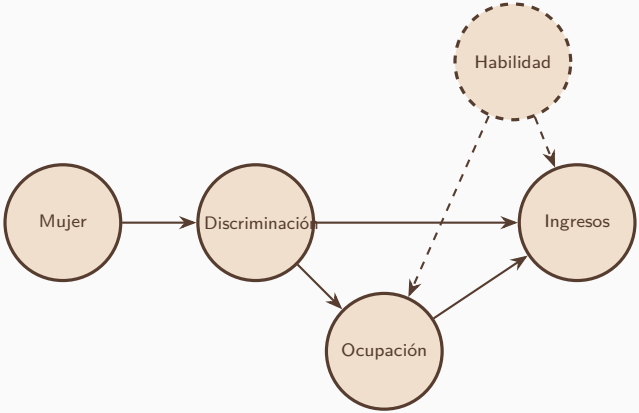

¿Cuáles son todos los caminos desde “Mujer” hacia “Ingresos”?

Ejemplo 1

Vamos a trabajar con ese modelo.

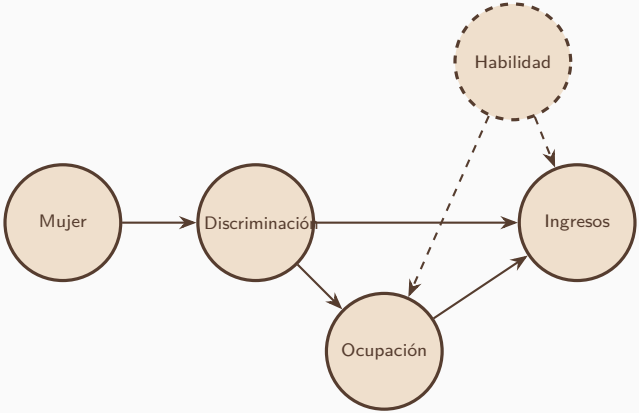

¿Qué va a pasar cuando controlamos por Ocupación?

Ejemplo 1

- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ingresos
- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ocupación $\rightarrow$ Ingresos
- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ocupación $\leftarrow$ Habilidad $\rightarrow$ Ingresos

Ejemplo 1

- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ingresos
- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ocupación $\rightarrow$ Ingresos
- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ocupación $\leftarrow$ Habilidad $\rightarrow$ Ingresos

Los dos primeros son caminos causales "buenos". Representan dos formas diferentes en que la discriminación afecta los ingresos.

El tercer camino contiene un colisionador en Ocupación, por lo que está **cerrado por defecto**.

Ejemplo 1

- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ingresos
- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ocupación $\rightarrow$ Ingresos
- Mujer $\rightarrow$ Discriminación $\rightarrow$ Ocupación $\leftarrow$ Habilidad $\rightarrow$ Ingresos

Si condicionamos en ocupación, cerramos el segundo camino, pero abrimos el tercero.

Ejemplo 1 — Simulación

Simulamos un mundo donde la discriminación afecta ingresos directamente **y** a través de la ocupación:

- **Incondicional:** correlación bruta entre Mujer e Ingresos (todos los caminos abiertos)
- **Condicional (1):** controlamos por Ocupación — cierra el camino mediador, pero **abre el colisionador**
- **Condicional (2):** controlamos por Ocupación **y** Habilidad — cierra el sesgo del colisionador

Ejemplo 1 — Simulación

```r
library(tidyverse)
library(stargazer)

tb <- tibble(
  female = ifelse(runif(10000)>=0.5,1,0),
  ability = rnorm(10000),
  discrimination = female,
  occupation = 1 + 2*ability + 0*female - 2*discrimination + rnorm(10000),
  wage = 1 - 1*discrimination + 1*occupation + 2*ability + rnorm(10000)
)

lm_1 <- lm(wage ~ female, tb)
lm_2 <- lm(wage ~ female + occupation, tb)
lm_3 <- lm(wage ~ female + occupation + ability, tb)
```

Ejemplo 1 — Simulación

	Incondicional	Condicional (1)	Condicional (2)
Mujer	-3.001^{***}	0.634^{***}	-0.936^{***}
	(0.084)	(0.030)	(0.029)
Ocupación		1.801^{***}	1.011^{***}
		(0.006)	(0.010)
Habilidad			1.969^{***}
			(0.022)
R^2	0.112	0.909	0.949

Ejemplo 1 — Lección

¿Qué hizo Google? Comparó hombres y mujeres **dentro del mismo puesto** — es decir, condicionó en Ocupación.

Pero si la discriminación afecta *qué puesto* obtienen las mujeres, entonces Ocupación es un colisionador: controlar por ella **oculta** parte de la discriminación y **abre** un sesgo por habilidad.

La regresión condicional (1) muestra un coeficiente *positivo* para Mujer — como si las mujeres ganaran *más*. No es que la discriminación desapareció: es que el sesgo del colisionador la invirtió.

Moraleja: controlar por variables que son *consecuencia* del tratamiento puede empeorar el sesgo, no mejorarlo.

Recapitulación

Tipo	Estructura	¿Abierto por defecto?	¿Condicionar?
Mediador	$X \to M \to Y$	Sí	Solo si quieres efecto directo
Confusor	$X \leftarrow C \to Y$	Sí	**Sí** — cierra correlación espuria
Colisionador	$X \to K \leftarrow Y$	No	**No** — lo abrirías

Objetivo: cerrar todos los caminos de backdoor sin abrir colisionadores.

Ejemplo 2

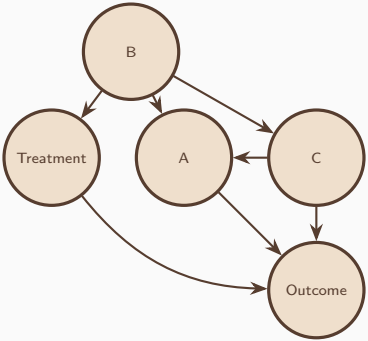

- 1. Escribe todos los caminos entre Treatment y Outcome.

Ejemplo 2

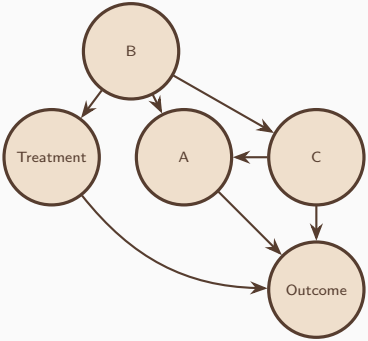

2. Queremos identificar todos los efectos causales de T a O. ¿Qué estrategias funcionarían?

- a) Condicionar solo en B
- b) Condicionar solo en C
- c) Condicionar en A y C
- d) Condicionar en B y C

Ejemplo 2

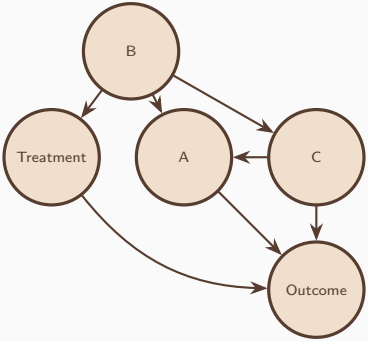

3. Ahora nos interesa solamente el efecto directo de T a O. ¿Qué estrategias funcionarían?

- a) Condicionar solo en B
- b) Condicionar solo en C
- c) Condicionar en A y C
- d) Condicionar en B y C

Ejemplo 2 — Discusión

Tómate 5 minutos para trabajar las tres preguntas.

1. Traza todos los caminos entre T y O
2. Clasifica cuáles están abiertos y cuáles cerrados
3. Determina el conjunto mínimo de variables a controlar

(Compara tu respuesta con un compañero antes de ver las soluciones)

Ejemplo 2 — Respuestas (1/2)

Pregunta 1 — Caminos entre Treatment y Outcome:

- $T \rightarrow O$ (causal directo)
- $T \leftarrow B \rightarrow A \rightarrow O$ (backdoor abierto)
- $T \leftarrow B \rightarrow C \rightarrow O$ (backdoor abierto)
- $T \leftarrow B \rightarrow C \rightarrow A \rightarrow O$ (backdoor abierto)
- $T \leftarrow B \rightarrow A \leftarrow C \rightarrow O$ (**cerrado** — A es colisionador)

Ejemplo 2 — Respuestas (2/2)

Preguntas 2 y 3: La respuesta mínima es **(a) condicionar solo en B**.

B bloquea todos los backdoor abiertos sin abrir el colisionador. Nota: (b) no funciona porque no cierra $T \leftarrow B \rightarrow A \rightarrow O$. Condicionar en A (opciones c, e) es peligroso: abre el colisionador $B \rightarrow A \leftarrow C$.

Las preguntas 2 y 3 tienen la misma respuesta porque $T \rightarrow O$ es el único arco saliente de T — no existe camino indirecto de T a O. Por lo tanto, efecto total = efecto directo.

Selección Muestral

Hasta ahora, los problemas de confusión surgieron dentro del modelo.

¿Qué pasa cuando el problema no está en las variables del modelo, sino en **quién entra a la muestra**?

Veremos que la selección muestral es simplemente otro caso de colisionador.

Selección Muestral - Jugadores de Baloncesto

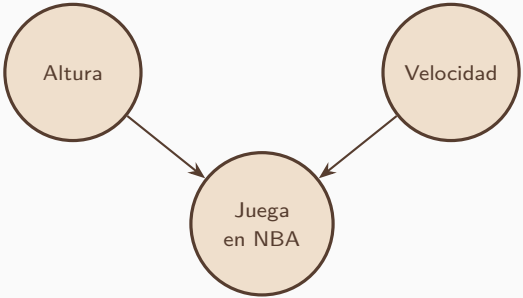

- Supongamos que no existe una relación entre altura y velocidad.
- Pero sabemos que jugar en la NBA es un colisionador.
- Si controlamos por NBA, encontramos una relación negativa.

Selección Muestral - Jugadores de Baloncesto

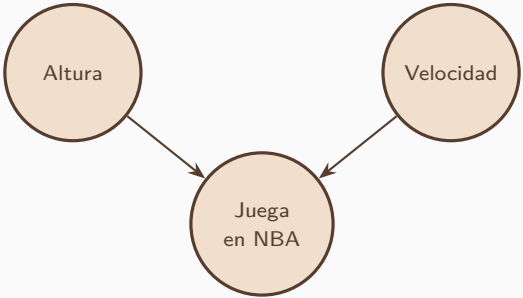

Si la muestra es solamente de jugadores de la NBA, estamos básicamente controlando por esa variable

Por lo tanto, entre jugadores de la NBA, podemos ver una relación negativa, aunque esa relación no exista en la población en general.

Selección Muestral - Jugadores de Baloncesto

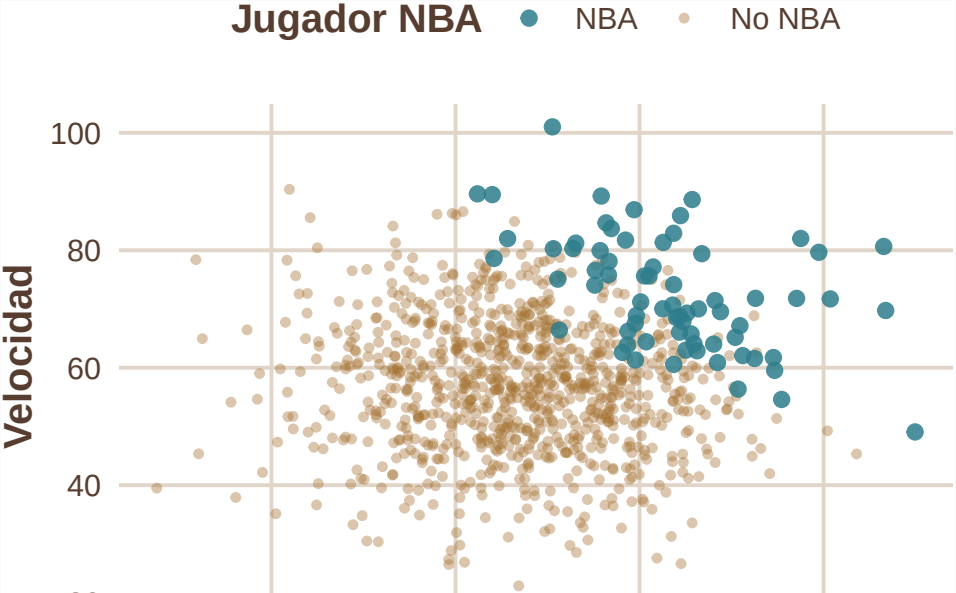

Selección Muestral — Reflexión (2 min)

Piensa en un ejemplo de tu área de interés donde la selección muestral podría generar una correlación espuria.

- ¿Cuál es el "colisionador" que determina quién entra a la muestra?
- ¿Qué relación espuria podría aparecer?

(Comparte tu ejemplo con un compañero)

Resumen: Las estructuras causales

Estructura	Definición	¿Condicionar?
Mediador	$X \to M \to Y$	Solo si quieres efecto directo
Confusor	$X \leftarrow C \to Y$	Sí — para cerrar el camino
Colisionador	$X \to K \leftarrow Y$	No — abrirías un camino cerrado
Selección	Muestra seleccionada por K	Cuidado — equivale a controlar K

Un **camino de backdoor** está abierto si no tiene colisionadores y no está controlado.

Objetivo: cerrar todos los caminos de backdoor sin abrir colisionadores.

Probando el Diagrama

- Una última cosa que se puede hacer es utilizar el diagrama para formular hipótesis.
- Se puede analizar la relación entre cualesquiera dos variables.
- Si el diagrama nos dice que dos variables deben ser independientes, pero están correlacionadas en la realidad, puede ser que nos falte algún elemento.
- De la misma forma, podemos analizar relaciones condicionales o no-condicionales.
- Si todas las relaciones están de acuerdo con el diagrama, es una señal de confianza en el diagrama.

Resumen y anticipación

Los DAGs son un lenguaje visual para representar el proceso generador de datos.

- **Tres estructuras**: mediador, confusor y colisionador — cada una con reglas distintas para condicionar.
- **Caminos de backdoor**: generan correlaciones espurias; debemos cerrarlos.
- **Condición de puerta trasera**: si cerramos todos los backdoor sin abrir colisionadores, identificamos el efecto causal.
- **Selección muestral**: condicionar por quién entra a la muestra es un caso de colisionador.

Próxima clase: Resultados Potenciales — formalizamos qué es un efecto causal y cómo los experimentos aleatorios lo estiman.

Apéndice

Magnitud del sesgo (detalle algebraico)

Podemos utilizar el diagrama para comprender la magnitud de los efectos bajo hipótesis de linealidad y estimación por MCO.

Por ejemplo, supón que un aumento de 1 unidad de "Salud" causa α unidades de "Bebida", y β unidades de "Mortalidad".

Supón también que el efecto de "Bebida" en "Mortalidad" es δ.

Si estimamos una regresión de Mortalidad en Bebida, vamos a obtener una combinación de los efectos: $\delta + \alpha\beta$.

Pero si bloqueamos el camino por "Salud", obtenemos el verdadero efecto causal, δ.

Pregunta: si $\alpha > 0$ y $\beta > 0$, sin condicionar, ¿cuál sería el signo del sesgo?