

Diferencias en Diferencias

2026-07-20

Hemos visto cómo estimar efectos causales cuando el tratamiento es casi aleatorio, condicionado a características observables.

Pero a menudo nos preocupan características no observables (variables confusoras).

Veremos cómo tratar ciertos tipos de confusores no observados usando datos de panel.

¿Qué son los datos de panel?

Datos de panel: observaciones repetidas de unidades i (personas, estados, etc.) a lo largo del tiempo t .

Utilidad: permite comparar resultados entre unidades tratadas y no tratadas *antes* del tratamiento.

Diferencias previas al tratamiento pueden revelar factores confusos **no observados**.

Un ejemplo: elección activa en California


En julio de 2011 (Q3), California cambió la pregunta sobre donación de órganos en las solicitudes de licencia de conducir.

- **Antes:** sistema de inclusión voluntaria (*opt-in*) — marcar una casilla.
- **Después: elección activa** — hay que responder sí o no para completar el trámite.

La idea: si obligamos a la gente a pronunciarse, ¿se registran más donantes?


Comparamos California con los demás estados (Kessler & Roth, 2014).

¿Tendencias paralelas antes de la reforma?




Los **niveles** son muy distintos: California registra mucho menos. ¿Importa?

¿Tendencias paralelas antes de la reforma?




No: DID compara **tendencias**, no niveles. Antes de la reforma ambas series suben casi en paralelo.

¿Qué habría pasado sin la reforma?



Si siguieran paralelas, California habría acompañado el **cambio** de los controles (línea punteada).

El efecto del tratamiento



El ATT es la brecha entre lo **observado** y el **contrafactual**. ¡El signo es negativo!

Hastings (2004)

En 2004, Justine Hastings escribió un estudio que analiza cómo las fusiones en la industria de la gasolina afectan los precios del combustible.

En particular, estudió un episodio en California donde la refinería ARCO compró una de las mayores cadenas de estaciones de servicio, Thrifty.

¿Cómo crees que una fusión así podría afectar los precios?

Hastings (2004)

En 2004, Justine Hastings escribió un estudio que analiza cómo las fusiones en la industria de la gasolina afectan los precios del combustible.

En particular, estudió un episodio en California donde la refinería ARCO compró una de las mayores cadenas de estaciones de servicio, Thrifty.

¿Cómo crees que una fusión así podría afectar los precios?

- Por un lado, podría reducir la competencia y aumentar los precios.
- Por otro lado, la fusión podría reducir los costos de proveer gasolina y, gracias a las sinergias, disminuir los precios.

Hastings intentó responder a esta pregunta de forma empírica usando datos de precios de gasolina por vecindario en California.

El conjunto de datos contenía información sobre vecindarios tanto con como sin estaciones Thrifty.

¿Si sólo tuviéramos datos posteriores a la fusión?

Supongamos primero que sólo contáramos con datos de precios de la gasolina *posteriores* a la fusión.


Podríamos comparar los precios en zonas que tenían una Thrifty antes ($D_i = 1$) con zonas que no la tenían ($D_i = 0$) para estimar el efecto causal de convertir una Thrifty.

¿Por qué esto podría no darnos el efecto causal? ¡Variables omitidas!

Los lugares que ya tenían una Thrifty antes probablemente tenían mayor competencia que los lugares sin Thrifty, por lo que esperaríamos que sus precios fueran más bajos.

Con datos de panel, podemos comprobar esto empíricamente examinando los precios *antes* de la fusión.

Diferencias pre-tratamiento



Antes de la fusión, las estaciones en mercados que competían con Thrifty tenían precios de la gasolina ≈ 3 centavos más bajos en cada período.


¿Es razonable asumir ausencia de confusión después de la fusión?

¡No!

Un supuesto más creíble es que la brecha hubiera permanecido en 3 c si la fusión no hubiera ocurrido.

¡Esta es la idea de la *diferencia-en-diferencias* (DiD)!

Después de la fusión



Después de la fusión

- Después de la fusión, las estaciones ubicadas en zonas con una Thrifty presentaron precios aproximadamente 2 centavos más altos.
- Si suponemos que habrían tenido precios 3 centavos más bajos (como antes de la fusión), ello implica un efecto del tratamiento de $2 - (-3) = 5$ centavos.
- Esta cifra corresponde a la diferencia post-tratamiento (2 centavos) entre tratadas y controles menos la diferencia pre-tratamiento (-3 centavos); es decir, una *diferencia-en-diferencias*.

Formalizando los supuestos de DiD

Suponga que hay dos períodos, $t = 1, 2$.

Las unidades tratadas ($D_i = 1$) reciben el tratamiento en el período 2; las unidades de control nunca son tratadas.

Sea Y_{it} el resultado observado para la unidad i en el período t .

Suponemos

$$Y_{it} = D_i Y_{it}(1) + (1 - D_i) Y_{it}(0)$$

Supuesto de no anticipación:

$$Y_{i1}(0) = Y_{i1}(1)$$

El tratamiento en el período 2 no afecta el resultado en el período 1.

Supuesto de *tendencias paralelas*:

$$\underbrace{\mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 1]}_{\text{Cambio en } Y(0) \text{ para tratados}} = \underbrace{\mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 0]}_{\text{Cambio en } Y(0) \text{ para controles}}$$

Equivalente a

$$\underbrace{\mathbb{E}[Y_{i2}(0) \mid D_i = 1] - \mathbb{E}[Y_{i2}(0) \mid D_i = 0]}_{\text{Sesgo de selección en el período 2}} = \underbrace{\mathbb{E}[Y_{i1}(0) \mid D_i = 1] - \mathbb{E}[Y_{i1}(0) \mid D_i = 0]}_{\text{Sesgo de selección en el período 1}}$$

Demostración

$$\begin{aligned} & \underbrace{\mathbb{E}[Y_{i2} - Y_{i1} \mid D_i = 1]}_{\text{Cambio observado (tratados)}} - \underbrace{\mathbb{E}[Y_{i2} - Y_{i1} \mid D_i = 0]}_{\text{Cambio observado (controles)}} = \\ &= \mathbb{E}[Y_{i2}(1) - Y_{i1}(1) \mid D_i = 1] - \mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 0] \quad (\text{regla de datos observados}) \\ &= \mathbb{E}[Y_{i2}(1) - Y_{i1}(0) \mid D_i = 1] - \mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 0] \quad (\text{sin anticipación}) \\ &= \mathbb{E}[Y_{i2}(1) - Y_{i2}(0) \mid D_i = 1] \\ &\quad + [\mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 1] - \mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 0]] \quad (\text{sumar y restar}) \\ &= \mathbb{E}[Y_{i2}(1) - Y_{i2}(0) \mid D_i = 1] \quad (\text{tendencias paralelas}) \\ &\implies \boxed{\tau_{\text{ATT}} = \mathbb{E}[Y_{i2}(1) - Y_{i2}(0) \mid D_i = 1]} \end{aligned}$$

τ_{ATT} es el **efecto medio del tratamiento sobre los tratados**: el efecto promedio en el período 2 para las unidades que recibieron el tratamiento.

Estimando el ATT

Demostramos que, bajo los supuestos de DiD (tendencias paralelas y sin anticipación), el ATT se identifica como

$$\tau_{\text{ATT}} = \underbrace{\mathbb{E}[Y_{i2} - Y_{i1} \mid D_i = 1]}_{\text{Cambio en la media poblacional (tratados)}} - \underbrace{\mathbb{E}[Y_{i2} - Y_{i1} \mid D_i = 0]}_{\text{Cambio en la media poblacional (controles)}}.$$


¿Cómo lo estimamos?

¡Sustituyendo medias muestrales!

Nuestro estimador es


$$\hat{\tau}_{\text{ATT}} = \underbrace{\bar{Y}_{12} - \bar{Y}_{11}}_{\text{Cambio en la media muestral (tratados)}} - \underbrace{\bar{Y}_{02} - \bar{Y}_{01}}_{\text{Cambio en la media muestral (controles)}},$$

Ejemplo numérico



$$\hat{\tau}_{\text{ATT}} = \underbrace{\bar{Y}_{12} - \bar{Y}_{11}}_{\text{Cambio en la media muestral (tratados)}} - \underbrace{\bar{Y}_{02} - \bar{Y}_{01}}_{\text{Cambio en la media muestral (controles)}} =$$

Ejemplo numérico



$$\begin{aligned}\hat{\tau}_{\text{ATT}} &= \underbrace{\bar{Y}_{12} - \bar{Y}_{11}}_{\text{Cambio en la media muestral (tratados)}} - \underbrace{\bar{Y}_{02} - \bar{Y}_{01}}_{\text{Cambio en la media muestral (controles)}} = \\ &= (1.43 - 1.25) - (1.41 - 1.28) =\end{aligned}$$

Considere la regresión

$$Y_{it} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 D_i + \beta_3 D_i \times \text{Post}_t + \varepsilon_{it}$$

donde

$$\text{Post}_t = \mathbf{1}[t = 2].$$

El coeficiente poblacional β_3 es igual a τ_{ATT} bajo los supuestos de DiD.

El modelo anterior implica la CEF:

$$\mathbb{E}[Y_{it} \mid D_i = 0, \text{Post}_t = 0] = \beta_0,$$

$$\mathbb{E}[Y_{it} \mid D_i = 0, \text{Post}_t = 1] = \beta_0 + \beta_1,$$

$$\mathbb{E}[Y_{it} \mid D_i = 1, \text{Post}_t = 0] = \beta_0 + \beta_2,$$

$$\mathbb{E}[Y_{it} \mid D_i = 1, \text{Post}_t = 1] = \beta_0 + \beta_1 + \beta_2 + \beta_3.$$


Por lo tanto,

$$\begin{aligned} \beta_3 &= (\mathbb{E}[Y_{it} \mid D_i = 1, \text{Post}_t = 1] - \mathbb{E}[Y_{it} \mid D_i = 1, \text{Post}_t = 0]) \\ &\quad - (\mathbb{E}[Y_{it} \mid D_i = 0, \text{Post}_t = 1] - \mathbb{E}[Y_{it} \mid D_i = 0, \text{Post}_t = 0]) = \tau_{\text{ATT}}. \end{aligned}$$

De manera análoga con datos muestrales:

$$\hat{\beta}_3 = (\bar{Y}_{12} - \bar{Y}_{11}) - (\bar{Y}_{02} - \bar{Y}_{01}) = \hat{\tau}_{\text{ATT}}.$$

Ejemplo con Datos de Hastings




Estimamos la siguiente regresión vía MCO:

$$Y_{it} = \beta_0 + \beta_1 \cdot \text{Post}_t + \beta_2 D_i + \beta_3 (D_i \cdot \text{Post}_t) + \varepsilon_{it}$$

donde $\text{Post}_t = 1$ para octubre y 0 para junio. Los coeficientes estimados son:

Ejemplo con Datos de Hastings



- Constante ($\hat{\beta}_0$) = 1.28
- Post ($\hat{\beta}_1$) = 0.13
- Tratado ($\hat{\beta}_2$) = -0.03
- Tratado $\times$ Post ($\hat{\beta}_3$) = 0.05

DID: Resumen hasta ahora

El estimador de Diferencias en Diferencias (DID) se puede escribir como: la diferencia entre grupos, de la diferencia a lo largo del tiempo:

$$\hat{\tau}_{ATT} = (\bar{Y}_{12} - \bar{Y}_{11}) - (\bar{Y}_{02} - \bar{Y}_{01})$$

Los supuestos clave son:

- 1) No anticipación: el efecto del tratamiento en el período cero es nulo.
- 2) Tendencias paralelas: el grupo tratado habría tenido el mismo *cambio* en los resultados que el grupo de control, en ausencia del tratamiento.

Podemos estimar el efecto del tratamiento por MCO (Mínimos Cuadrados Ordinarios):

$$Y_{it} = \beta_0 + \beta_1 \cdot \text{Post}_t + \beta_2 D_i + \beta_3 (D_i \cdot \text{Post}_t) + \varepsilon_{it}$$

El efecto del tratamiento corresponde a β_3 .

El DID más famoso: Card & Krueger (1994)

La pregunta: ¿destruye empleo un aumento del salario mínimo?

La predicción del modelo competitivo estándar es clara: el empleo debería **caer**.

El experimento natural: en abril de 1992, Nueva Jersey subió el salario mínimo de \$4.25 a \$5.05 por hora. Pensilvania no lo hizo.

Card y Krueger encuestaron ≈ 400 locales de comida rápida (Burger King, KFC, Wendy's, Roy Rogers) en NJ y en el este de Pensilvania, **antes** (feb-mar 1992) y **después** (nov-dic 1992) del alza.

- Tratados: NJ. Controles: PA.
- Resultado: empleo en equivalentes de tiempo completo (FTE) por local.

	PA (control)	NJ (tratado)	Dif.
Antes (feb-mar 1992)	23.33	20.44	-2.89
Después (nov-dic 1992)	21.17	21.03	-0.14
Cambio	-2.16	+0.59	

$$\hat{\tau}_{\text{ATT}} = \underbrace{(+0.59)}_{\Delta \text{ NJ}} - \underbrace{(-2.16)}_{\Delta \text{ PA}} = +2.75$$

El empleo en NJ **subió** ≈ 2.75 FTE respecto de su contrafactual, en vez de caer.

¿Por qué importó tanto?

El resultado contradecía la predicción del modelo competitivo: subir el salario mínimo **no** destruyó empleo.

- Desató tres décadas de debate y replicación (Neumark & Wascher; Dube, Lester & Reich; Cengiz et al.).
- Instaló al DID como herramienta central de la economía laboral.
- Es justamente el tipo de giro metodológico que vimos en la *revolución de la credibilidad*: un diseño creíble puede derrotar a la predicción teórica.

Pero: ¿es creíble aquí el supuesto de tendencias paralelas?

Con solo **dos períodos** no podemos verificarlo: no vemos si NJ y PA venían moviéndose juntos.

Eso motiva lo que sigue.

DID con múltiples períodos

DID con múltiples períodos

El DID con dos períodos y dos grupos es bastante sencillo. Pero a menudo queremos usar datos de muchos períodos.

Supongamos que tenemos un grupo tratado y uno de control observados desde $t = -t_a$ hasta $+t_b$. El tratamiento ocurre en el período 1 (la notación anterior tenía el tratamiento en 2).

Para cada período s , podemos estimar un efecto del tratamiento usando la estrategia DID de 2x2, fijando $t = 0$ como referencia.

$$\beta_s = \underbrace{(\bar{Y}_{1s} - \bar{Y}_{0s})}_{\text{Dif en el período } s} - \underbrace{(\bar{Y}_{10} - \bar{Y}_{00})}_{\text{Dif en el período 0}}$$

Convenientemente, podemos estimar los mismos efectos con una regresión:

$$Y_{it} = \phi_t + \gamma D_i + \sum_{s \neq 0} \beta_s \times D_i \times 1[t = s] + \varepsilon_{it}$$

Este tipo de regresión a veces se denomina “efectos fijos de dos vías” (two-way fixed effects), porque tenemos dummies para el tiempo (ϕ_t) y el grupo (γ).

Alternativamente, podríamos sustituir γD_i por efectos fijos individuales λ_i y obtener las mismas estimaciones.

Ejemplo: Expansión de Medicaid

La Ley del Cuidado de Salud a Bajo Precio (Affordable Care Act) amplió la cobertura médica para personas de bajos ingresos.


La expansión entró en vigencia en 2014, pero algunos estados optaron por no participar y no tuvieron cambios.

Carey, Miller y Wherry (2020) estudian el impacto de la expansión de Medicaid mediante un análisis DID. Comparan los primeros estados en adoptar la medida con aquellos que no lo hicieron.

Ejemplo: Expansión de Medicaid

Veamos las estimaciones de β_s con sus IC para cada punto en el tiempo:

Panel B. Uninsured



Tendencias Paralelas

Nótese que el gráfico anterior incluye “efectos del tratamiento” estimados para períodos anteriores al tratamiento. ¿Por qué es importante mostrarlos?

Nótese que el gráfico anterior incluye “efectos del tratamiento” estimados para períodos anteriores al tratamiento. ¿Por qué es importante mostrarlos?

El supuesto de tendencias paralelas es que, sin el tratamiento, las diferencias entre los grupos deberían permanecer constantes a lo largo del tiempo. Por lo tanto, en los períodos anteriores al tratamiento deberíamos ver que el coeficiente es igual a cero.

Una forma de pensar en el supuesto de tendencias paralelas es en términos de una ecuación en diferencias.

Si tomamos la forma de regresión del DID simple de 2x2 y restamos Y_{i0} :

$$(Y_{i1} - Y_{i0}) = \beta_1 + \beta_3 D_i + (\varepsilon_{i1} - \varepsilon_{i0})$$


Esto es simplemente una comparación de medias entre los grupos tratado y de control **en diferencias**.

En la forma de regresión en diferencias, el supuesto de tendencias paralelas es simplemente la independencia del tratamiento.

Estamos *asumiendo* que no hay factores de confusión, solo que en lugar de los niveles, lo estamos asumiendo para los cambios.

Tendencias Paralelas

$$Y_{it} = \alpha_0 + \gamma D_i + \lambda \text{Post}_t + \delta(D_i \cdot \text{Post}_t) + \varepsilon_{it}$$



Tendencias Paralelas


Podemos pensar en el método DID como un control efectivo para cualquier **factor de confusión invariante en el tiempo**, así como para cualquier factor que sea **exactamente común a los grupos tratado y no tratado**.

Por ejemplo:


- Los estados que adoptaron la expansión de Medicaid son más demócratas, más educados, tienen ingresos promedio más altos.
 - Los factores que son relativamente “fijos” son controlados por las diferencias en el tiempo.
- El período “posterior” incluye diferentes condiciones macroeconómicas.
 - Los factores que cambian con el tiempo, pero que son iguales para todos los estados, son controlados por las diferencias entre grupos.

El supuesto de tendencias paralelas se violaría si, por ejemplo, las condiciones macroeconómicas tendieran a beneficiar a los estados republicanos en comparación con

Tendencias paralelas



Tendencias paralelas




En este caso, ¡estimariamos “efectos del tratamiento” para cada período, incluso antes de que comenzara el tratamiento!

Por lo tanto, queremos ver efectos nulos en los períodos “anteriores” para asegurarnos de que los grupos seguían una tendencia paralela antes del tratamiento.

Tendencias Paralelas

También deberíamos considerar lo que los intervalos de confianza descartan.


¿Este efecto parece convincente?



Tendencias Paralelas


También deberíamos considerar lo que los intervalos de confianza descartan.

¿Este efecto parece convincente?



Tendencias Paralelas

¿Qué tal este?



(a) Medicaid Eligibility

De mirar el gráfico a un problema serio


Hasta aquí, nuestra estrategia para validar tendencias paralelas ha sido **mirar el gráfico**: si los coeficientes pre-tratamiento se ven planos, respiramos tranquilos.

Es tentador razonar así:

“Los coeficientes pre-tratamiento no son significativos $\Rightarrow$ las tendencias son paralelas $\Rightarrow$ el supuesto se cumple.”

Roth (2022) muestra que este razonamiento es **más débil de lo que parece**. Veamos tres problemas.

Problema 1: bajo poder



La tendencia pre-tratamiento está **claramente inclinada**, pero cada IC incluye el cero: el test “se aprueba”. Ausencia de evidencia $\neq$ evidencia de ausencia.

Problema 2: el sesgo de *pre-testing*

Peor aún: **condicionar** en “haber pasado el test” distorsiona nuestras estimaciones.

- Solo seguimos adelante (y publicamos) cuando los coeficientes pre-tratamiento se ven planos.
- Pero “verse plano” en una muestra ruidosa es en parte **suerte**: seleccionamos realizaciones donde el ruido pre-tratamiento fue pequeño.
- Roth muestra que este filtro puede **empeorar** el sesgo del estimador post-tratamiento, no reducirlo.

El propio acto de “chequear y luego estimar” introduce un sesgo.

Problema 3: pasado plano $\neq$ futuro paralelo

Aunque las tendencias pre-tratamiento fueran *exactamente* paralelas, eso **no garantiza** que lo sean después.

- Tendencias paralelas es un supuesto sobre un **contrafactual que nunca observamos**: $Y(0)$ para los tratados *después* del tratamiento.
- Un shock que coincida con el tratamiento (p. ej., una recesión que afecte distinto a tratados y controles) rompe el supuesto **sin dejar rastro** en el pre-período.

Los pre-trends **informan**, pero no **prueban** el supuesto.

Entonces, ¿qué hacemos?

En vez de tratar los pre-trends como un test de aprobado/reprobado, cambiamos la pregunta:


¿Qué tan grande tendría que ser la violación de tendencias paralelas para ****cambiar mis conclusiones****?

Esta es la idea de **Honest DiD** (Rambachan & Roth, 2023).

En lugar de **asumir** que la violación es exactamente cero, le ponemos un **límite**.

- **Supuesto de suavidad:** la desviación de tendencias paralelas después del tratamiento no puede ser más de M veces la mayor desviación observada **antes**.
- Para cada M obtenemos no un número, sino un **conjunto** de valores posibles del ATT (un IC robusto).
- $M = 0$: tendencias paralelas exactas (el caso estándar). A medida que M crece, el intervalo se ensancha.

Honest DiD: el valor de quiebre



¿Para qué M el IC empieza a incluir el cero? Ese es el **valor de quiebre**: grande $\Rightarrow$ conclusión robusta; pequeño $\Rightarrow$ conclusión frágil.

Tendencias paralelas: qué llevarse

- El supuesto **no es verificable**: es un supuesto sobre un contrafactual.
- Mirar los pre-trends es útil pero **insuficiente**: bajo poder, sesgo de *pre-testing*, y el pasado no garantiza el futuro.
- Buenas prácticas:
 - Graficar el *event-study* siempre (transparencia).
 - No tratar el test de pre-trends como aprobado/reprobado.
 - Reportar **sensibilidad** (Honest DiD): ¿qué tan robusta es la conclusión a violaciones plausibles?


Inferencia

Una preocupación muy importante al estimar un DID es que los errores deben ser agrupados (clustered).

Cuando discutimos la agrupación, vimos que cuando los errores están correlacionados, tenemos que ajustar los errores para reflejar eso. De lo contrario, tendremos errores estándar que son demasiado pequeños.


En datos de panel, tenemos muchas observaciones de un mismo individuo a lo largo del tiempo. Naturalmente, hay características que están correlacionadas a lo largo del tiempo.

Inferencia



DARN, NOT SIGNIFICANT.

WE NEED MORE DATA.
HAVE THEM EACH TRY
YELLING INTO THE MIC
A FEW MORE TIMES.



PERFECT!

ARE YOU SURE
WE'RE DOING
SLOPE HYPOTHESIS
TESTING RIGHT?



The Quarterly Journal of Economics, February 2004

HOW MUCH SHOULD WE TRUST DIFFERENCES-IN-DIFFERENCES ESTIMATES?*

MARIANNE BERTRAND

ESTHER DUFLO

SENDHIL MULLAINATHAN

Most papers that employ Differences-in-Differences estimation (DD) use many years of data and focus on serially correlated outcomes but ignore that the resulting standard errors are inconsistent. To illustrate the severity of this issue, we randomly generate placebo laws in state-level data on female wages from the Current Population Survey. For each law, we use OLS to compute the DD estimate of its “effect” as well as the standard error of this estimate. These conventional DD standard errors severely understate the standard deviation of the estimators: we find an “effect” significant at the 5 percent level for up to 45 percent of the placebo interventions. We use Monte Carlo simulations to investi-

Lección: siempre agrupar (cluster) los errores estándar a nivel del individuo.

Adopción escalonada

A menudo distintas unidades se tratan en **momentos distintos**: varios estados adoptan una política en años diferentes.

Supongamos que, una vez adoptado, el tratamiento permanece activo. La regresión habitual es:

$$Y_{it} = \phi_i + \lambda_t + \beta D_{it} + e_{it}$$

Efectos fijos de unidad (ϕ_i) y de tiempo (λ_t): *two-way fixed effects* (TWFE).

Durante veinte años se interpretó β como “el” efecto del tratamiento.

La pregunta del bloque: ¿qué comparaciones hace TWFE?

Goodman-Bacon (2021): con adopción escalonada, β es un **promedio ponderado de todas las comparaciones 2×2 posibles** entre grupos.

Hay **tres tipos** de comparación 2×2 :

1. Tratado vs **nunca-tratado**. (limpia)
2. Tratado temprano vs tratado tarde, **antes de que el tardío se trate**. (limpia: el tardío aún es control válido)
3. Tratado tarde vs tratado temprano, **después de que el temprano ya se trató**. (¡prohibida!)

La comparación prohibida

En la comparación (3) usamos como “control” a un grupo **que ya fue tratado**.


- Le restamos su **cambio** en el resultado, como si fuera una tendencia contrafactual.
- Pero si los efectos son **dinámicos** (crecen con el tiempo), ese grupo todavía se está moviendo *por efecto del tratamiento*.
- Entonces restamos efecto de tratamiento tratándolo como tendencia $\Rightarrow$ **sesgo**.

Con efectos dinámicos o heterogéneos, β puede **no** ser un promedio válido de los efectos del tratamiento.


Descomponiendo TWFE: castle doctrine

Cheng & Hoekstra (2013): leyes de “castle doctrine” (defensa propia) adoptadas por distintos estados entre 2005 y 2010. ¿Aumentan los homicidios?

Descomponemos el TWFE ($\hat{\beta} = 0.069$) en sus comparaciones 2×2 :



Descomponiendo TWFE: castle doctrine




Aquí el **90% del peso** cae en comparaciones limpias (tratado vs nunca-tratado): hay 29 estados nunca-tratados. Las comparaciones prohibidas pesan poco $\Rightarrow$ **TWFE $\approx$ OK**.
Descomponer te dice si preocuparte.

Cuando SÍ importa

¿Y si no hubiera nunca-tratados y los efectos se **aceleraran** con el tiempo? Caso estilizado: **todos los efectos son positivos**.

Todos los efectos son positivos (ATT = +0.73)

...pero TWFE estima -0.87 — ¡signo equivocado!



TWFE puede dar el **signo equivocado**. No es una curiosidad: es la norma cuando las comparaciones prohibidas dominan.

¿Por qué se voltea el signo?

Con dos cohortes y sin nunca-tratados, TWFE promedia **solo dos** comparaciones 2×2 :

Comparación 2×2	Estimación	Peso
Temprano vs tardío-aún-no-tratado	+0.33	0.2
Tardío vs temprano ya-tratado	-1.17	0.8

$$0.2(+0.33) + 0.8(-1.17) = -0.87$$

En la comparación **prohibida**, la cohorte temprana es el “control” de la tardía — pero su efecto **crece cada vez más rápido** (su efecto medio salta de 0.33 a 1.72, mientras la tardía apenas llega a 0.23). El “control” sube **más** que la tratada, así que el DiD la vuelve negativa (-1.17). Y encima pesa el 80%.

¿Qué hacer? La idea de la imputación (BJS)

Borusyak, Jaravel & Spiess (2024): **nunca uses una observación tratada como contrafactual.**

1. Estima $Y_{it}(0) = \phi_i + \lambda_t$ usando **solo las observaciones no tratadas**.
2. Imputa $\hat{Y}_{it}(0)$ para cada observación tratada.
3. Calcula el efecto individual $\hat{\tau}_{it} = Y_{it} - \hat{Y}_{it}(0)$.
4. Promedia los $\hat{\tau}_{it}$ como quieras: global, por período de evento, por cohorte.

Por qué funciona BJS

- **Nunca** usa una observación tratada como control $\Rightarrow$ elimina la comparación prohibida *por construcción*.
- **Separa identificación de agregación:** primero imputas (identificación), luego eliges tu estimando (agregación).
 - ¿Efecto global? ¿Perfil dinámico? ¿Por cohorte? Es tu decisión, no un artefacto de la regresión.
- El *event-study* sale limpio: los coeficientes pre-tratamiento son verdaderos placebos.

Misma filosofía, distinta implementación:

- Construye explícitamente $ATT(g, t)$: el efecto para la cohorte tratada en g , en el período t .
- Cada uno se estima comparando esa cohorte con los **nunca-tratados** (o los aún-no-tratados).
- Luego **agregas** los $ATT(g, t)$: por período de evento, por cohorte, o global.

BJS y CS coinciden en lo esencial: comparaciones limpias primero, agregación transparente después.

CS: las agregaciones de $ATT(g, t)$


$ATT(g, t)$ es un **efecto por cada cohorte g y período t** : muchos números. Los colapsamos según la pregunta que nos interese:

- **Global**: un solo número, el efecto promedio del tratamiento (como un ATT único).
- **Por tiempo de evento** ($e = t - g$): promedia las cohortes por “años desde el tratamiento” $\Rightarrow$ **el event study** (perfil dinámico).
- **Por cohorte** (g): un efecto por grupo de adopción $\Rightarrow$ revela **heterogeneidad** entre cohortes.
- **Por tiempo calendario** (t): un efecto por año $\Rightarrow$ útil si un shock macro afecta a todos a la vez.


KEY POINT: son los **mismos** $ATT(g, t)$; cambia **cómo los promedias**. TWFE te da *una* mezcla, con pesos implícitos; CS te deja elegir la agregación de forma transparente.

CS: agregar es promediar los bloques

Bloques crudos: un ATT(g,t) por cohorte y año




Agregación por tiempo de evento (promedio = línea negra)



¿Y los estimadores modernos en el caso estilizado?

En el caso estilizado no hay nunca-tratados: desde $t = 7$ *todas* las unidades están tratadas $\Rightarrow$ **no queda control**.



- **BJS y CS coinciden:** estiman el efecto de la cohorte temprana en $t \leq 6$ (donde la tardía aún es control) y recuperan el efecto **exacto y positivo** ($\approx +0.33$).
- Para la cohorte tardía y los períodos $t \geq 7$: **no hay control** $\Rightarrow$ no lo estiman (BJS devuelve NaN; CS no reporta esos (g, t)).

TWFE **inventa** un -0.87 con toda confianza. BJS y CS son **honestos**: donde hay contrafactual creíble estiman (y bien, $+0.33$); donde no lo hay, **callan** en vez de usar comparaciones prohibidas.

Ninguno de los dos produce el signo equivocado. La diferencia con TWFE no es el paquete: es la **filosofía** — *no fabricar un contrafactual que no existe*.

Matiz práctico: BJS calla en silencio (su estimando “global” solo refleja lo identificable — conviene mirar el event-study para ver los NaN). CS lista explícitamente qué (g, t) estima. En datos reales rara vez es tan extremo: suele haber nunca-tratados.

DID como promedio ponderado


Cuatro estimadores, un dataset

Volvamos a castle doctrine (50 estados, 2000–2010). Efecto sobre $\log(\text{homicidios})$:

Estimador	Efecto estimado
TWFE estático (naïve)	0.069
BJS (imputación)	0.067
Callaway–Sant’Anna	0.019

TWFE y BJS casi coinciden — porque, como vimos, aquí las comparaciones prohibidas pesan poco.

Event study: TWFE vs BJS vs CS



BJS y CS casi se superponen; TWFE queda algo por debajo. Coinciden a grandes rasgos (intervalos anchos, muchos nunca-tratados). ¿Cuál reportarías?

¿Cuál reportar?

BJS, aun cuando aquí coincide con TWFE:

- Es **transparente** sobre qué comparaciones hace.
- Es **robusto** a los problemas de TWFE que no siempre podemos descartar de antemano.
- Da esencialmente el mismo número $\Rightarrow$ no pagas costo por la robustez.

Regla práctica para tus proyectos: si el diseño es escalonado, **no reportes TWFE naïve a secas**. Descompón (Bacon) y estima con un método moderno (BJS/CS).

Todo estimador DID es una **elección de dos cosas**:

1. **Qué comparaciones** haces (¿quién es control de quién?).
2. **Con qué pesos** las promedias.
 - **TWFE**: pesos *implícitos* — a veces absurdos (comparación prohibida).
 - **BJS / CS**: pesos *explícitos* — tú eliges el estimando.

Diagnóstico: **descompón** (Bacon), **grafica** (event study), **reporta sensibilidad** (Honest DiD).

DiD, en el fondo: no-confusión en diferencias

Un paso atrás: ¿qué *son* los supuestos de DiD?

No anticipación + tendencias paralelas equivalen a pedir que el **cambio** en el resultado no tratado sea independiente del tratamiento:

$$\mathbb{E}\left[\underbrace{Y_{i2}(0) - Y_{i1}(0)}_{\Delta Y_i(0)} \mid D_i = 1\right] = \mathbb{E}[\Delta Y_i(0) \mid D_i = 0].$$

Es **no-confusión**, pero en cambios en vez de niveles.

- Mejor que controlar por observables: absorbe **todo** confusor fijo no observado.
- Pero en esencia es lo mismo — seguimos **asumiendo** que no queda confusión (ahora en las tendencias).

¿Y si ese supuesto no es creíble? (un shock que golpea distinto a tratados y controles).

Si el supuesto falla: *shift-share* como instrumento

Si no podemos defender la no-confusión en diferencias, necesitamos **variación exógena** — volvemos a las **variables instrumentales**.

Ejemplo central: el diseño *shift-share* (Bartik). La exposición de cada unidad combina:

$$\text{Exposición}_i = \sum_k \underbrace{s_{ik}}_{\text{shares}} \underbrace{g_k}_{\text{shifts}}$$

- **Shares** s_{ik} : composición **preexistente** (cuánto pesa el sector k en i).
- **Shifts** g_k : shocks **comunes** por sector (p. ej., crecimiento nacional de la industria).

Se mueve por los *shifts* (cuasi-aleatorios), no por decisiones de la unidad $\Rightarrow$ es un **instrumento**. Identificación (Borusyak-Hull-Jaravel): basta con que los *shifts* sean cuasi-aleatorios.

Ejemplo: el “China shock” (Autor, Dorn & Hanson, 2013)

Endogeneidad: no podemos regresar el empleo local sobre las importaciones chinas de cada región. Una región que crece por un shock de demanda propio **importa más de todo** — incluido de China. El regresor responde a las condiciones locales: **endógeno**.

Solución shift-share — exposición predicha de la región i :

$$\text{Exposición}_i = \sum_k \underbrace{s_{ik}}_{\text{share}} \times \underbrace{g_k}_{\text{shift}}$$

- **Shares** s_{ik} : qué tan especializada estaba la región en cada industria **antes** del auge (composición predeterminada).
- **Shifts** g_k : el empuje de China por industria, medido con sus exportaciones a **otros** países ricos (Europa, Japón) $\Rightarrow$ captura la **oferta** china (productividad, OMC), no la demanda de EE.UU.

Puente al Control Sintético

Insight de este bloque: **los pesos son una elección.**

Hasta ahora pesamos a **todos** los controles por igual. Pero, ¿y si eligiéramos pesos **sobre las unidades de control** de modo que su tendencia pre-tratamiento **calce exactamente** con la del tratado?

DID: pesos iguales a todos los controles.

Control Sintético: pesos **óptimos** para construir un "clon" del tratado.

Ese es el **Control Sintético** — nuestra próxima clase.

DID: resumen

- DID usa un grupo de comparación que **no es idéntico** al tratado; las **tendencias paralelas** construyen el contrafactual. Supuestos clave: **no anticipación** y **tendencias paralelas**.
- Tendencias paralelas **no es verificable**: los pre-trends informan pero no prueban (bajo poder, *pre-testing*, futuro $\neq$ pasado). Reporta **sensibilidad** (Honest DiD).
- Siempre **agrupa** los errores estándar.
- Con **adopción escalonada**, TWFE mezcla comparaciones prohibidas. Descompón (Bacon) y usa estimadores modernos (**BJS**, CS).
- En el fondo, DiD es **no-confusión en diferencias**; si no es creíble, busca **variación exógena** (IV / *shift-share*).
- Idea unificadora: todo DID es una elección de **comparaciones + pesos**. El Control Sintético lleva esa idea un paso más allá.