

# Machine Learning y Inferencia Causal

Double ML, Model Selection y Sintesis  
2025

---

## Donde hemos estado:

- Clases 1-3: Fundamentos Bayesianos, Decision Theory, Shrinkage
- Clase 4: Regresion Penalizada (Ridge/Lasso)
- Clase 5: Mas alla de linealidad (Splines)
- Clase 6: Metodos basados en arboles (RF, Boosting)

## Hoy: Clase final

1. El problema: ML para inferencia causal
2. Double Machine Learning (DML)
3. Otros metodos causales con ML
4. Model Selection profundo
5. Sintesis e integracion

## Dos objetivos diferentes en econometria: Prediccion

- Minimizar MSE out-of-sample
- $\hat{Y}$  lo mas cercano a  $Y$
- Regularizacion es buena
- Sesgo aceptable

## Dos objetivos diferentes en econometria:

### Prediccion

- Minimizar MSE out-of-sample
- $\hat{Y}$  lo mas cercano a  $Y$
- Regularizacion es buena
- Sesgo aceptable

### Inferencia Causal

- Estimar parametro causal  $\theta$
- Necesitamos  $\hat{\theta} \rightarrow \theta$
- Sesgo es problematico
- Necesitamos errores estandar

# El Dilema Fundamental

## Dos objetivos diferentes en econometria: Prediccion

- Minimizar MSE out-of-sample
- $\hat{Y}$  lo mas cercano a  $Y$
- Regularizacion es buena
- Sesgo aceptable

## Inferencia Causal

- Estimar parametro causal  $\theta$
- Necesitamos  $\hat{\theta} \rightarrow \theta$
- Sesgo es problematico
- Necesitamos errores estandar

### La pregunta clave

¿Podemos usar ML para mejorar estimacion de efectos causales?



## Parte 1: Por que ML Ingenuo Falla

---

**Pregunta economica clasica:** ¿Cual es el retorno a un año adicional de educacion?

**Modelo basico:**

$$\log(\text{wage}_i) = \theta \cdot \text{educ}_i + X_i' \beta + \varepsilon_i$$

donde:

- $\theta$  = parametro causal de interes (retorno a educacion)
- $X_i$  = controles (experiencia, region, etc.)
- $\beta$  = parametros de molestia (nuisance parameters)

**Problema:** Con muchos controles y sus interacciones, ¿como estimar  $\beta$ ?



## Enfoque Ingenuo 1: ML Directo

**Idea:** Usar Lasso/RF para estimar el modelo completo

$$\log(\text{wage}_i) = \theta \cdot \text{educ}_i + f(X_i) + \varepsilon_i$$

donde  $f(X_i)$  se estima con ML.

## Enfoque Ingenuo 1: ML Directo

**Idea:** Usar Lasso/RF para estimar el modelo completo

$$\log(\text{wage}_i) = \theta \cdot \text{educ}_i + f(X_i) + \varepsilon_i$$

donde  $f(X_i)$  se estima con ML.

### **Problema: Regularization Bias**

- Lasso encoge TODOS los coeficientes, incluyendo  $\theta$
- RF/Boosting no dan errores estandar validos
- La regularizacion que mejora prediccion introduce sesgo en  $\theta$

## Enfoque Ingenuo 1: ML Directo

**Idea:** Usar Lasso/RF para estimar el modelo completo

$$\log(\text{wage}_i) = \theta \cdot \text{educ}_i + f(X_i) + \varepsilon_i$$

donde  $f(X_i)$  se estima con ML.

**Problema: Regularization Bias**

- Lasso encoge TODOS los coeficientes, incluyendo  $\theta$
- RF/Boosting no dan errores estandar validos
- La regularizacion que mejora prediccion introduce sesgo en  $\theta$

**Resultado:**

$$\hat{\theta}_{ML} \not\rightarrow \theta \quad (\text{sesgado})$$

## Enfoque Ingenuo 2: Post-Selection

**Idea:** Dos etapas

1. Usar Lasso para seleccionar variables importantes
2. Estimar modelo final con OLS usando solo variables seleccionadas

## Enfoque Ingenuo 2: Post-Selection

**Idea:** Dos etapas

1. Usar Lasso para seleccionar variables importantes
2. Estimar modelo final con OLS usando solo variables seleccionadas

**Problema: Selection Bias**

- Si Lasso elimina una variable importante por casualidad
- OLS en el modelo seleccionado es sesgado
- Errores estandar ignoran incertidumbre de seleccion
- Inferencia invalida (tests de hipotesis incorrectos)

## Enfoque Ingenuo 2: Post-Selection

**Idea:** Dos etapas

1. Usar Lasso para seleccionar variables importantes
2. Estimar modelo final con OLS usando solo variables seleccionadas

**Problema: Selection Bias**


- Si Lasso elimina una variable importante por casualidad
- OLS en el modelo seleccionado es sesgado
- Errores estandar ignoran incertidumbre de seleccion
- Inferencia invalida (tests de hipotesis incorrectos)

**Resultado:**

$SE(\hat{\theta})$  subestimado  $\Rightarrow$  tests invalidos

# El Problema Fundamental

Trade-off inevitable con ML ingenuo:



**Necesitamos:** Metodos que usen ML para reducir varianza SIN introducir sesgo en  $\theta$ .





## Parte 2: Double Machine Learning

---

## La Idea Central de DML (Chernozhukov et al. 2018)

En muchos modelos econométricos:

$$Y = \theta D + g(X) + U$$

$$D = m(X) + V$$

- $Y$  = outcome
- $D$  = variable de interés (tratamiento, educación, etc.)
- $X$  = controles de alta dimensión
- $g(X)$  y  $m(X)$  = funciones de molestia (nuisance)

## La Idea Central de DML (Chernozhukov et al. 2018)

En muchos modelos econometricos:

$$Y = \theta D + g(X) + U$$

$$D = m(X) + V$$

- $Y$  = outcome
- $D$  = variable de interes (tratamiento, educacion, etc.)
- $X$  = controles de alta dimension
- $g(X)$  y  $m(X)$  = funciones de molestia (nuisance)

### Estrategia:

1. Usar ML para estimar  $g(X)$  y  $m(X)$  (prediccion)
2. Usar residuos para estimar  $\theta$  (inferencia)
3. Cross-fitting para evitar overfitting bias

**Setup formal:**

$$Y_i = \theta D_i + g_0(X_i) + U_i$$

$$D_i = m_0(X_i) + V_i$$

**Supuestos:**

- $E[U_i|X_i, D_i] = 0$  (exogeneidad condicional)
- $E[V_i|X_i] = 0$  (por construccion)
- $g_0(\cdot)$  y  $m_0(\cdot)$  son funciones desconocidas

**Setup formal:**

$$Y_i = \theta D_i + g_0(X_i) + U_i$$

$$D_i = m_0(X_i) + V_i$$

**Supuestos:**

- $E[U_i|X_i, D_i] = 0$  (exogeneidad condicional)
- $E[V_i|X_i] = 0$  (por construccion)
- $g_0(\cdot)$  y  $m_0(\cdot)$  son funciones desconocidas

**Objetivo:** Estimar  $\theta$  sin especificar forma funcional de  $g_0$  y  $m_0$ .

**Ventaja:** Usar ML para las funciones no-lineales complejas.

### Naive approach (NO funciona bien):

1. Estimar  $\hat{g}(X_i) = E[Y_i|X_i]$  con ML
2. Estimar  $\hat{m}(X_i) = E[D_i|X_i]$  con ML
3. Computar residuos:
  - $\tilde{Y}_i = Y_i - \hat{g}(X_i)$
  - $\tilde{D}_i = D_i - \hat{m}(X_i)$
4. Regresar  $\tilde{Y}_i$  en  $\tilde{D}_i$ :

$$\hat{\theta} = \frac{\sum_i \tilde{D}_i \tilde{Y}_i}{\sum_i \tilde{D}_i^2}$$

### Naive approach (NO funciona bien):

1. Estimar  $\hat{g}(X_i) = E[Y_i|X_i]$  con ML
2. Estimar  $\hat{m}(X_i) = E[D_i|X_i]$  con ML
3. Computar residuos:
  - $\tilde{Y}_i = Y_i - \hat{g}(X_i)$
  - $\tilde{D}_i = D_i - \hat{m}(X_i)$
4. Regresar  $\tilde{Y}_i$  en  $\tilde{D}_i$ :

$$\hat{\theta} = \frac{\sum_i \tilde{D}_i \tilde{Y}_i}{\sum_i \tilde{D}_i^2}$$

**Problema:** Overfitting bias - estimas  $\hat{g}$  y  $\hat{m}$  en los mismos datos donde calculas residuos.

### Algoritmo (2-fold version):

1. **Dividir datos** aleatoriamente:  $I_1$  y  $I_2$

2. **Primera iteracion:**

- Estimar  $\hat{g}^{(-1)}$  y  $\hat{m}^{(-1)}$  usando datos en  $I_1$
- Predecir en  $I_2$ :  $\tilde{Y}_i^{(1)} = Y_i - \hat{g}^{(-1)}(X_i)$ ,  $\tilde{D}_i^{(1)} = D_i - \hat{m}^{(-1)}(X_i)$

3. **Segunda iteracion:**

- Estimar  $\hat{g}^{(-2)}$  y  $\hat{m}^{(-2)}$  usando datos en  $I_2$
- Predecir en  $I_1$ :  $\tilde{Y}_i^{(2)} = Y_i - \hat{g}^{(-2)}(X_i)$ ,  $\tilde{D}_i^{(2)} = D_i - \hat{m}^{(-2)}(X_i)$

4. **Pooled estimation:**

$$\hat{\theta}_{DML} = \frac{\sum_{i=1}^n \tilde{D}_i \tilde{Y}_i}{\sum_{i=1}^n \tilde{D}_i^2}$$



## Por que Funciona DML

### Propiedad clave: Neyman Orthogonality

La funcion de momento es aproximadamente insensible a errores de estimacion en  $g$  y  $m$ :

$$\psi(W_i; \theta, g, m) = (Y_i - \theta D_i - g(X_i))(D_i - m(X_i))$$

Matematicamente:

$$\frac{\partial}{\partial g} E[\psi(W; \theta_0, g, m)] \Big|_{g=g_0, m=m_0} = 0$$

## Por que Funciona DML

### Propiedad clave: Neyman Orthogonality

La funcion de momento es aproximadamente insensible a errores de estimacion en  $g$  y  $m$ :

$$\psi(W_i; \theta, g, m) = (Y_i - \theta D_i - g(X_i))(D_i - m(X_i))$$

Matematicamente:

$$\left. \frac{\partial}{\partial g} E[\psi(W; \theta_0, g, m)] \right|_{g=g_0, m=m_0} = 0$$

En palabras:

- Errores de primer orden en  $\hat{g}$  y  $\hat{m}$  no afectan  $\hat{\theta}$
- Solo errores de segundo orden importan
- Con regularizacion: errores de segundo orden son pequenos

Error estandar:

$$SE(\hat{\theta}_{DML}) = \sqrt{\frac{1}{n} \frac{\sum_i \hat{\psi}_i^2}{(\sum_i \tilde{D}_i^2 / n)^2}}$$

donde  $\hat{\psi}_i = \tilde{Y}_i - \hat{\theta}_{DML} \tilde{D}_i$  son residuos estimados.

**Error estandar:**

$$SE(\hat{\theta}_{DML}) = \sqrt{\frac{1}{n} \frac{\sum_i \hat{\psi}_i^2}{(\sum_i \tilde{D}_i^2 / n)^2}}$$

donde  $\hat{\psi}_i = \tilde{Y}_i - \hat{\theta}_{DML} \tilde{D}_i$  son residuos estimados.

**Propiedades asintoticas:**

$$\sqrt{n}(\hat{\theta}_{DML} - \theta_0) \xrightarrow{d} N(0, V)$$

**Crucialmente:** Esto es valido incluso si  $p > n$  (mas variables que observaciones)!

## Ejemplo: Retornos a Educacion con DML

### Setup:

- $Y$ :  $\log(\text{wage})$
- $D$ : years of education
- $X$ : experiencia,  $\text{experiencia}^2$ , edad, genero, region, ocupacion (30 dummies), industria (20 dummies), etc.

**Total:** ~100 variables en  $X$  con interacciones.

## Ejemplo: Retornos a Educacion con DML

### Setup:

- $Y$ :  $\log(\text{wage})$
- $D$ : years of education
- $X$ : experiencia, experiencia<sup>2</sup>, edad, genero, region, ocupacion (30 dummies), industria (20 dummies), etc.

**Total:** ~100 variables en  $X$  con interacciones.

### Comparacion de metodos:

1. **OLS basico:** Solo controles lineales
2. **Lasso directo:** Sesgo de regularizacion
3. **DML con Lasso:** Para  $g(X)$  y  $m(X)$
4. **DML con Random Forest:** Mas flexible

## Implementacion en R: Setup

```
# Cargar paquetes necesarios
library(DoubleML)
library(mlr3)
library(mlr3learners)
library(data.table)

# Preparar datos en formato DoubleML
data_dml <- double_ml_data_from_data_frame(
  df = wage_data,
  y_col = "log_wage",      # Outcome
  d_cols = "education",    # Tratamiento
  x_cols = control_vars    # Vector de controles
)
```

## Implementacion: Estimacion

```
# Definir learner para funciones de molestia
```

```
# Opcion 1: Random Forest
```

```
learner_g <- lrn("regr.ranger", num.trees = 500)
```

```
learner_m <- lrn("regr.ranger", num.trees = 500)
```

```
# Opcion 2: Lasso
```

```
learner_g <- lrn("regr.cv_glmnet", s = "lambda.min")
```

```
learner_m <- lrn("regr.cv_glmnet", s = "lambda.min")
```

```
# Estimacion DML
```

```
dml_obj <- DoubleMLPLR$new(  
  data_dml,
```

```
  ml_g = learner_g,
```

```
  ml_m = learner_m,
```



Vamos a ver el código completo:

**Archivo:** `doubleml_example.R`

**Lo que haremos:**

1. Simular datos con efecto heterogéneo
2. Comparar OLS, Lasso, DML con Lasso, DML con RF
3. Examinar sesgo y cobertura de intervalos
4. Aplicar a datos reales de salarios

## Resultados Esperados

### Simulacion tipica:

Metodo	Estimacion	Error Std	95% CI
OLS (controles basicos)	0.082	0.015	[0.053, 0.111]
Lasso (directo)	0.073	0.011	[0.051, 0.095]
DML + Lasso	0.098	0.014	[0.071, 0.125]
DML + Random Forest	0.101	0.013	[0.076, 0.126]
Verdad	0.100	NA	NA

### Observaciones:

- OLS subestima (sesgo de variable omitida)
- Lasso directo tiene sesgo de regularizacion
- DML recupera el parametro correcto con IC validos

### 1. Modelos con multiples tratamientos:

$$Y_i = \theta_1 D_{1i} + \theta_2 D_{2i} + g_0(X_i) + U_i$$

### 2. Variables instrumentales:

$$Y_i = \theta D_i + g_0(X_i) + U_i$$

$$D_i = m_0(Z_i, X_i) + V_i$$

### 3. Efectos parciales:

$$Y_i = g_0(D_i, X_i) + U_i$$

Estimar  $\theta(d) = \frac{\partial}{\partial d} g_0(d, X)$

### DML es apropiado cuando:

1. Tienes muchas variables de control ( $p$  grande)
2. Forma funcional de controles es desconocida/compleja
3. Necesitas estimacion causal + errores estandar validos
4. Exogeneidad condicional es defendible

### DML es apropiado cuando:

1. Tienes muchas variables de control ( $p$  grande)
2. Forma funcional de controles es desconocida/compleja
3. Necesitas estimacion causal + errores estandar validos
4. Exogeneidad condicional es defendible

### DML NO resuelve:

- Endogeneidad fundamental (necesitas IV o experimento)
- Causalidad inversa
- Variables omitidas no observables

### DML es apropiado cuando:

1. Tienes muchas variables de control ( $p$  grande)
2. Forma funcional de controles es desconocida/compleja
3. Necesitas estimacion causal + errores estandar validos
4. Exogeneidad condicional es defendible

### DML NO resuelve:

- Endogeneidad fundamental (necesitas IV o experimento)
- Causalidad inversa
- Variables omitidas no observables

**En resumen:** DML es una herramienta para “high-dimensional controls”, no para identificacion causal per se.



## Parte 3: Otros Metodos Causales con ML

---



### Familia de metodos que usan ML para parametros causales:

1. **Double ML:** Estimacion de efectos promedio
2. **Causal Forests:** Efectos heterogeneos de tratamiento
3. **Post-Double-Selection:** Seleccion robusta de controles
4. **Generalized Random Forests:** Extension flexible
5. **Targeted Learning:** Estimadores doblemente robustos

**Enfoque comun:** Separar prediccion (ML) de inferencia causal.

## Causal Forests (Athey & Wager 2019)

**Objetivo:** Estimar efectos heterogeneos de tratamiento

$$\tau(x) = E[Y_i(1) - Y_i(0)|X_i = x]$$

**Idea:**

- Modificar Random Forests para estimar efectos causales
- Cada arbol construye particiones que maximizan heterogeneidad en efectos
- Agregar arboles para estimar  $\tau(x)$  con intervalos de confianza

# Causal Forests (Athey & Wager 2019)

**Objetivo:** Estimar efectos heterogeneos de tratamiento

$$\tau(x) = E[Y_i(1) - Y_i(0)|X_i = x]$$

**Idea:**

- Modificar Random Forests para estimar efectos causales
- Cada arbol construye particiones que maximizan heterogeneidad en efectos
- Agregar arboles para estimar  $\tau(x)$  con intervalos de confianza

**Ventajas:**

- Estima efectos heterogeneos sin especificar interacciones
- Inferencia valida (errores estandar honestos)
- Robusto a especificacion

## Ejemplo Conceptual: Causal Forest

**Pregunta:** ¿El efecto de entrenamiento laboral varia con educacion y experiencia?

**Problema:** Con muchas variables, ¿cuales incluir como controles?

**Estrategia de dos pasos:**

1. **Primera seleccion:** Usar Lasso para regresar  $Y$  en  $X$ 
  - Seleccionar variables  $\hat{S}_Y$
2. **Segunda seleccion:** Usar Lasso para regresar  $D$  en  $X$ 
  - Seleccionar variables  $\hat{S}_D$
3. **OLS final:** Incluir  $D$  y union  $\hat{S}_Y \cup \hat{S}_D$  como controles

**Problema:** Con muchas variables, ¿cuales incluir como controles?

**Estrategia de dos pasos:**

1. **Primera seleccion:** Usar Lasso para regresar  $Y$  en  $X$ 
  - Seleccionar variables  $\hat{S}_Y$
2. **Segunda seleccion:** Usar Lasso para regresar  $D$  en  $X$ 
  - Seleccionar variables  $\hat{S}_D$
3. **OLS final:** Incluir  $D$  y union  $\hat{S}_Y \cup \hat{S}_D$  como controles

**Ventaja sobre Lasso directo:**

- Incluye variables que predicen  $D$  (confounders) aunque no predigan  $Y$  bien
- Inferencia valida (bajo supuestos)

## Comparacion Rapida

Metodo	Estimando	ML usado	Inferencia	Ventaja
DML	ATE	Cualquiera	Si	Flexible
Causal Forest	CATE $\tau(x)$	Arboles mod.	Si	Heterogeneidad
Post-Dbl-Selection	ATE	Lasso	Si	Simple

### Regla practica:

- ATE con controles flexibles: DML
- Efectos heterogeneos: Causal Forests
- Seleccion de controles: Post-Double-Selection





## Parte 4: Model Selection Profundo

---

## 1. Leave-One-Out CV (LOOCV):

- $K = n$  (cada observacion es un fold)
- Menos sesgo pero mas varianza y costo computacional
- Formula cerrada para algunos modelos (Ridge, splines)

## 2. Repeated K-fold CV:

- Repetir K-fold multiples veces con diferentes splits
- Reduce varianza de estimacion de error
- Recomendado cuando  $n$  es moderado

## 3. Nested CV:

- CV externo para evaluar, CV interno para tuning
- Evita sesgo optimista por “snooping”

## Nested Cross-Validation

**Problema:** Si usas CV para elegir  $\lambda$  Y evaluar rendimiento con los mismos folds, eres demasiado optimista.

**Solucion: Nested CV**

**Loop externo** (evaluacion):

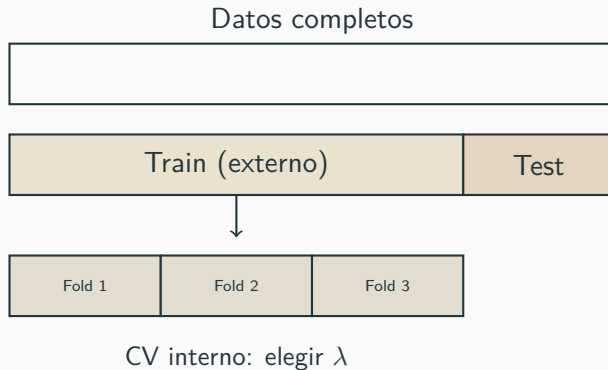
- Dividir en train/test

**Loop interno** (tuning):

- Dentro de train, hacer CV para elegir  $\lambda$
- Entrenar modelo final con  $\lambda$  elegido
- Evaluar en test (externo)

**Resultado:** Estimacion no sesgada del error de generalizacion.

## Ilustracion de Nested CV



## Comparando Modelos No Anidados

**Pregunta:** ¿Ridge es mejor que Lasso? ¿RF es mejor que XGBoost?

**No podemos usar test F.** ¿Qué hacer?

# Comparando Modelos No Anidados

**Pregunta:** ¿Ridge es mejor que Lasso? ¿RF es mejor que XGBoost?

**No podemos usar test F.** ¿Qué hacer?

## 1. Cross-validation + test de significancia

- Comparar errores CV con test pareado (Dietterich 1998)
- Toma en cuenta correlacion entre folds

## 2. Information Criteria (AIC/BIC)

- Para modelos con misma verosimilitud
- Penalizacion por complejidad

## 3. Out-of-sample testing

- Dividir datos en train/validation/test
- Comparar MSE en test

## Test de Comparacion de Modelos

**Setup:** Dos modelos A y B, queremos probar  $H_0 : \text{MSE}_A = \text{MSE}_B$

**Procedimiento (Dietterich test):**

1. Hacer K-fold CV para ambos modelos
2. Computar diferencia de errores en cada fold:  $d_k = \text{MSE}_{A,k} - \text{MSE}_{B,k}$
3. Test t pareado:

$$t = \frac{\bar{d}}{\text{SE}(\bar{d})} \sim t_{K-1}$$

# Test de Comparacion de Modelos

**Setup:** Dos modelos A y B, queremos probar  $H_0 : \text{MSE}_A = \text{MSE}_B$

**Procedimiento (Dietterich test):**

1. Hacer K-fold CV para ambos modelos
2. Computar diferencia de errores en cada fold:  $d_k = \text{MSE}_{A,k} - \text{MSE}_{B,k}$
3. Test t pareado:

$$t = \frac{\bar{d}}{\text{SE}(\bar{d})} \sim t_{K-1}$$

**Advertencia:**

- Los folds NO son independientes (comparten datos)
- Test puede ser anticonservador
- Mejor usar validacion cruzada repetida



**Observacion importante:**

## Prediccion vs Inferencia

- **Prediccion:** Minimizar MSE de  $\hat{Y}$
- **Inferencia:** Estimar  $\theta$  con sesgo minimo y SE validos

## Observacion importante:

### Prediccion vs Inferencia

- **Prediccion:** Minimizar MSE de  $\hat{Y}$
- **Inferencia:** Estimar  $\theta$  con sesgo minimo y SE validos

## Estos objetivos pueden estar en tension:

- Ridge mejora prediccion pero sesga  $\hat{\theta}$
- RF predice muy bien pero no da inferencia sobre parametros
- OLS no predice tan bien pero tiene inferencia standard

## Observacion importante:

### Prediccion vs Inferencia

- **Prediccion:** Minimizar MSE de  $\hat{Y}$
- **Inferencia:** Estimar  $\theta$  con sesgo minimo y SE validos

## Estos objetivos pueden estar en tension:

- Ridge mejora prediccion pero sesga  $\hat{\theta}$
- RF predice muy bien pero no da inferencia sobre parametros
- OLS no predice tan bien pero tiene inferencia standard

**Implicacion:** El “mejor” modelo depende del objetivo.

## Para proyectos de investigacion:

### 1. Definir objetivo claramente:

- ¿Predecir  $Y$ ?  $\hat{\alpha}$ ' Usar CV, elegir modelo con menor MSE
- ¿Estimar efecto causal?  $\hat{\alpha}$ ' Cuidado con regularizacion, usar DML

### 2. Reportar multiple metricas:

- MSE in-sample y out-of-sample
- R-squared (si es relevante)
- Para causales: estimacion puntual, SE, p-value

### 3. Robustez:

- Probar multiples especificaciones
- Reportar rango de estimaciones
- Discutir sensibilidad a supuestos

# Checklist: ML en Economia Aplicada

## Antes de empezar:

- ☐ ¿Tu pregunta es causal o predictiva?
- ☐ ¿Tienes suficientes datos para validacion out-of-sample?
- ☐ ¿Las variables predictoras estan disponibles en aplicacion real?

## Durante analisis:

- ☐ Separar train/validation/test apropiadamente
- ☐ Usar nested CV si estas tuneando hiperparametros
- ☐ Verificar supuestos (si es causal)

## Al reportar:

- ☐ Reportar rendimiento out-of-sample
- ☐ Describir proceso de seleccion de modelo
- ☐ Discutir limitaciones y robustez




## Parte 5: Sintesis e Integracion

---

# Mapa del Curso: Prediccion

**Objetivo:** Minimizar MSE de  $\hat{Y}$




→ Complejidad

Izquierda: Interpretable  
Derecha: Mejor prediccion



# Mapa del Curso: Inferencia Causal

**Objetivo:** Estimar  $\theta$  (efecto causal)



Todos: ML para predicción  
Inferencia separada

**Mensaje clave:** Separar predicción (ML) de estimación causal.

## 1. El trade-off sesgo-varianza es fundamental

- Complejidad vs generalización
- Regularización introduce sesgo para reducir varianza

## 2. Separar predicción de inferencia

- ML excelente para predicción, no para efectos causales

## 3. No hay “mejor” método universal

- Depende de objetivo, datos, estructura del problema

## 4. Interpretabilidad vs rendimiento

- OLS/Lasso: interpretables
- RF/XGBoost: mejores predicciones, menos transparentes
- DML: mejor de ambos mundos

## 1. Sobreajuste por evaluacion repetida

- NO: Ajustar multiples modelos, reportar solo el mejor
- SÍ: Pre-registrar analisis o usar nested CV

## 2. Confundir correlacion con causacion

- NO: “RF predice bien, por tanto X causa Y”
- SÍ: Prediction  $\neq$  causation sin identificacion

## 3. Ignorar incertidumbre

- NO: Reportar solo predicciones puntuales
- SÍ: Incluir intervalos de confianza/prediccion

### Libros:

- James et al. (2021): *Introduction to Statistical Learning* (2nd ed)
- Hastie et al. (2009): *Elements of Statistical Learning*
- Molnar (2022): *Interpretable Machine Learning*

## Donde ML ha tenido impacto:

### 1. Prediccion de politicas

- Targeting de programas sociales (Kleinberg et al. 2015)
- Prediccion de riesgo de desempleo (Athey 2018)

### 2. Efectos heterogeneos

- Retornos a educacion por tipo de estudiante
- Efectos de salario minimo por region/industria

### 3. Nowcasting

- Prediccion de GDP en tiempo real
- Indices de actividad economica

