Inferencia

2026-04-27

Intro

Plan

- Repaso: prueba de hipótesis clásica
- Errores agrupados (*clustering*)
- Bootstrap
- Teaser: inferencia por aleatorización

Objetivos de aprendizaje

Al terminar esta clase, deberías poder:

1. Identificar los componentes de una prueba de hipótesis clásica e interpretar sus resultados
2. Reconocer cuándo los errores agrupados son un problema y cómo corregirlos
3. Explicar la lógica del bootstrap y en qué contextos es preferible a los errores estándar analíticos
4. Describir la idea central de la inferencia por aleatorización y en qué difiere de la inferencia clásica

1. Repaso: Prueba de Hipótesis Clásica

Prueba de Hipótesis Clásica

Empezamos con una hipótesis sobre β a probar, H0. $\beta = \mu$

- Comúnmente, H0: $\beta = 0$.

Elegimos una estadística de prueba.

- Por ejemplo: $t = \dfrac{\hat{\beta} - \mu}{se(\hat{\beta})}$

Y fijamos el nivel de significancia deseado ($\alpha = 5\%$).

Podemos reconstruir la distribución de la estadística bajo ciertas hipótesis:

- H0 es verdadera (o sea, $\beta = \mu$)
- N es grande (aproximación asintótica)

Prueba de Hipótesis Clásica

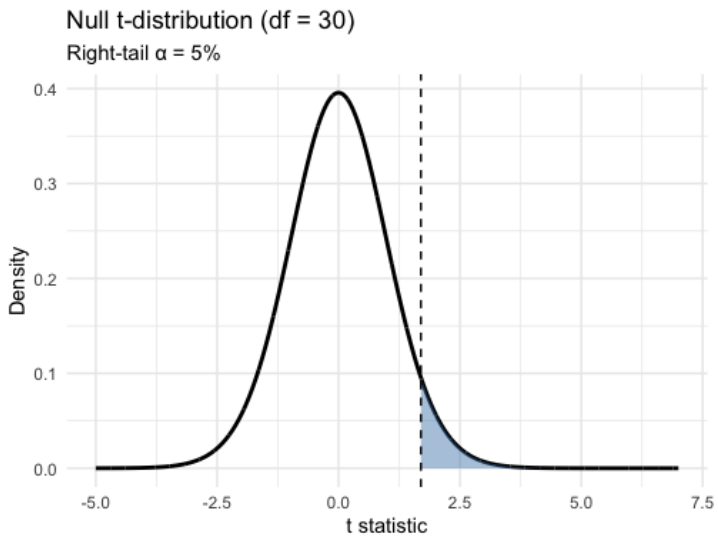

Prueba de Hipótesis Clásica

Rechazamos H0 si la estadística t es muy extrema en comparación con valores más típicos si H0 fuera verdad.

- Bajo la hipótesis nula, la probabilidad de rechazar la nula es α (**error tipo I**).
- La **potencia** de la prueba es la probabilidad de rechazar una H0 que es falsa. Depende de cuán grande sea el efecto real.

Prueba de Hipótesis Clásica

Si cambiamos la elección de α de 5% a 10%, ¿qué resulta?

- A: Tenemos menos probabilidad de rechazar una H0 falsa
- B: Tenemos más probabilidad de rechazar una H0 verdadera
- C: La potencia de la prueba aumenta
- D: B y C son verdad

Prueba de Hipótesis Clásica

Si cambiamos la elección de α de 5% a 10%, ¿qué resulta?

- A: Tenemos menos probabilidad de rechazar una H0 falsa
- **B: Tenemos más probabilidad de rechazar una H0 verdadera** ✓
- **C: La potencia de la prueba aumenta** ✓
- **D: B y C son verdad** ✓

Aumentar α amplía la zona de rechazo: más errores tipo I, pero también mayor potencia.

2. Errores Agrupados

Errores Agrupados

Imagínate que te contratan para evaluar el efecto de una campaña publicitaria de una marca de cerveza.

La empresa hizo un experimento aleatorio con 120 individuos, de los cuales la mitad vio la campaña.

Encuentras que el efecto es positivo y significativo con p-valor 3%.

Después te informan que la aleatorización fue solamente entre dos tiendas: los 60 controles estaban en Concepción, y los 60 tratados en Valparaíso.

¿Es un problema para tu inferencia?

Errores Agrupados

El problema es que la aleatorización no fue entre individuos, sino entre **grupos**.

Es natural suponer que existe correlación dentro de cada grupo: puede haber hecho más calor en Valparaíso, o llovido en Concepción. Esos factores afectan a todos los tratados o a todos los controles.

Entonces, la estimación del error estándar no es válida.

Este problema aparece ampliamente en estudios observacionales: estudiantes en escuelas, personas en comunas, empresas en regiones. Si existen shocks no observados a nivel de grupo, los errores no son i.i.d. y los errores estándar ordinarios **subestiman la varianza real**.

Errores Agrupados

Podemos escribir el modelo con j un grupo e i un individuo:

$$Y_i = \alpha + \beta D_i + v_j + w_{ij}$$

Donde v_j es un shock común al grupo j y w_{ij} es un error individual.

La relación entre los errores estándar agrupados e individuales es:

$$\frac{se_g(\hat{\beta})}{se_i(\hat{\beta})} = D = \sqrt{1 + (n-1)\rho}$$

Donde ρ es la **correlación intragrupal**: la fracción de la varianza total explicada por la variación entre grupos.

Errores Agrupados

En la campaña publicitaria, supón que $\rho = 6\%$ y $n = 60$. ¿Cuánto más grandes son los errores estándar?

$$D = \sqrt{1 + 59 \times 0.06} \approx 2.1$$

¡Los errores son más que el doble de lo que pensábamos!

Con p-valor aparente de 3%, el verdadero podría superar ampliamente el 5%.

Errores Agrupados — simulación

Simulamos datos con estructura de grupo y vemos cómo se comporta la inferencia.

- $N = 1{,}000$ observaciones repartidas en 50 grupos.
- Verdadero efecto: $\beta = 0$ — no hay nada que detectar.
- Variamos la correlación intragrupal ρ entre 0 y 0,5.
- 500 simulaciones por escenario; en cada una estimamos OLS y construimos un IC del 95%.

Como $\beta = 0$, la **tasa de rechazo** de $H_0 : \beta = 0$ debería ser cercana al 5% nominal. Si rechazamos más, los errores estándar son inválidos.

Sin correlacion intragrupal. Tasa de rechazo: 5.2%

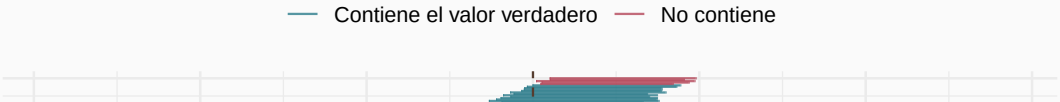

Distribucion del coeficiente estimado (efecto verdadero = 0)

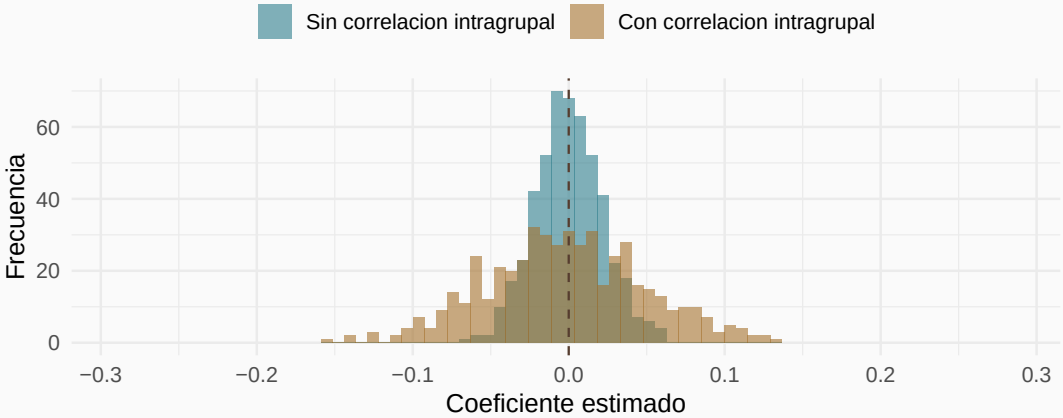

IC 95% sin correccion. Tasa de rechazo: 38.6%

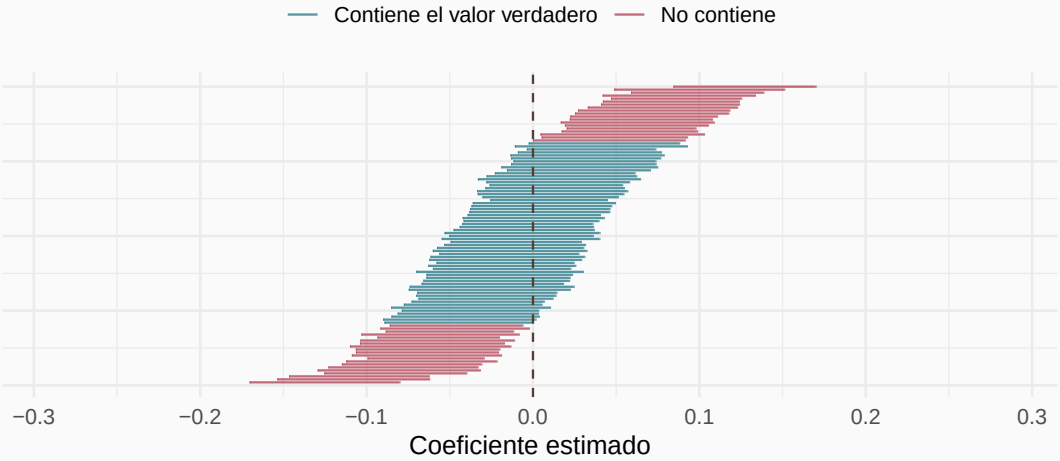

IC 95% con errores agrupados. Tasa de rechazo: 8.4%

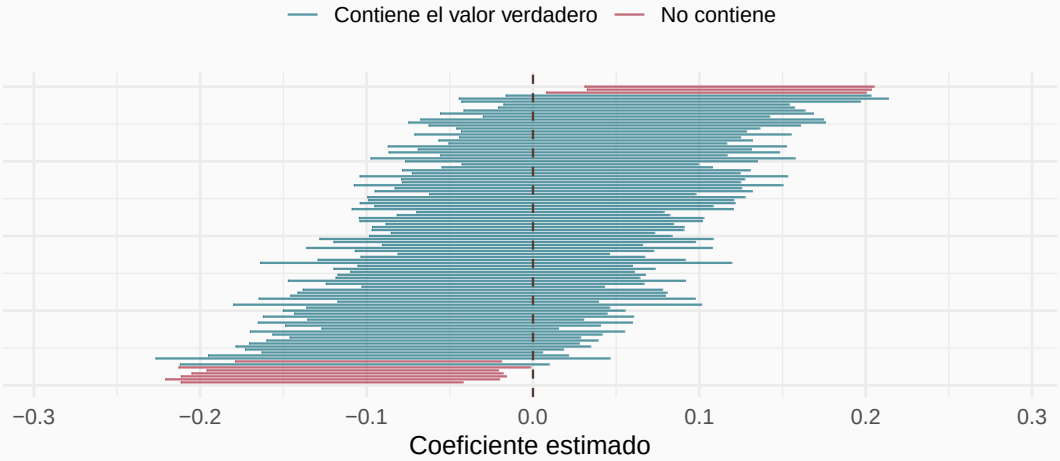

Errores Agrupados

Sin ajuste, rechazamos en exceso del 5% nominal: **la prueba no es válida**.

Con **errores estándar agrupados** (*cluster-robust standard errors*), la tasa de rechazo vuelve al nivel correcto.

Errores Agrupados

¿A qué nivel se agrupa?

- Si existe un argumento teórico, úsalo: si el tratamiento varía por escuela, agrupa por escuela.
- Otra guía: agrupa en el **nivel donde está la variación que identifica el parámetro**.
  - Si trabajas con panel (misma unidad en distintos períodos), siempre agrupa por unidad.
  - Si las prácticas son comunes a toda una comuna, agrupa por comuna.

Piensa y discute (3 minutos)

Tienes datos de rendimiento académico de estudiantes en escuelas, en comunas. Estás evaluando una política asignada aleatoriamente a nivel de **comuna**. ¿A qué nivel agruparías los errores estándar? ¿Por qué?

Errores Agrupados

Una limitación importante: el ajuste funciona bien cuando hay **al menos 50 grupos** (Angrist y Pischke).

Con menos grupos, las distribuciones asintóticas son malas aproximaciones.

En esos casos se usan otros métodos, como el **wild cluster bootstrap**, que sí funciona con pocos grupos.

3. Bootstrap

Bootstrap

Bootstrap es una técnica *extremadamente* útil para hacer inferencia. Funciona *casi siempre*, y cuando no funciona, normalmente hay una variante que sí funciona.

La idea: en vez de modelar la estructura de los datos analíticamente para derivar una fórmula de errores estándar, utilizamos **los propios datos**.

Queremos saber cómo se comporta nuestro estimador si la muestra fuera otra extracción de la misma población. No tenemos otra muestra, pero podemos simularla: extraemos una muestra del mismo tamaño **con reemplazo** de nuestra muestra original.

- Algunas unidades aparecen múltiples veces; otras no aparecen.

Bootstrap

El método:

1. Crear una nueva muestra mediante extracción **con reemplazo** de la muestra original.
2. Estimar el parámetro de interés.
3. Repetir 1 y 2 muchas veces (mil o diez mil).
4. El **error estándar** es la desviación estándar de esos estimadores.

Bootstrap — Ejemplo

Tenemos 4 individuos y hacemos la regresión de Y en X: obtenemos $\hat{\beta} = 0.97$.

i	Y	X
A	4	3
B	2	6
C	10	7
D	6	5

Una muestra bootstrap posible: $\{\text{C, C, D, B}\} \rightarrow \hat{\beta} = 2.55$.

Otra: $\{\text{A, A, B, B}\} \rightarrow \hat{\beta} = -0.67$.

Repetimos miles de veces y obtenemos la distribución del estimador.

Bootstrap

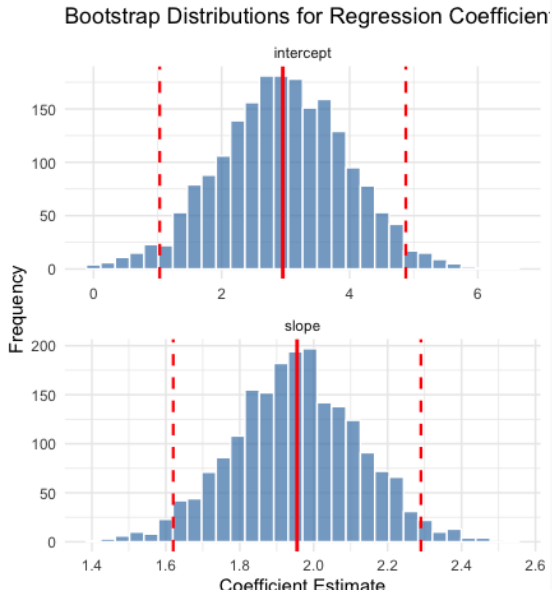
Bootstrap Distributions for Regression Coefficien
intercept
150
100
50
0
0
2
4
6
Frequency
slope
200
150
100
50
0
1.4
1.6
1.8
2.0
2.2
2.4
2.6
Coefficient Estimate

Bootstrap

También podemos construir intervalos de confianza:

- El **IC del 95%** es simplemente el rango que contiene el 95% central de los estimadores bootstrap.

Para una regresión simple no hay gran ventaja, porque conocemos la fórmula analítica del error estándar.

El bootstrap es especialmente útil cuando **no existe una fórmula cerrada**: estimadores de emparejamiento con subclasificación, ponderación inversa de probabilidad (IPW), estimadores en múltiples etapas.

Bootstrap

Variante para datos con estructura de grupo: **cluster bootstrap**.

En vez de resampling de unidades individuales, resamplamos **grupos enteros**.

Ej: en vez de resampling por alumno, resamplamos por escuela.

Uno de los pocos casos donde el bootstrap **no funciona**: emparejamiento con vecino más cercano. El estimador es discontinuo — un pequeño cambio en la muestra no cambia el vecino más cercano. Por eso se prefieren kernel o IPW.

Lo veremos de nuevo en **DID** (bootstrap heterogeneidad-robusto, wild cluster bootstrap para pocos grupos).

4. Inferencia por Aleatorización

Inferencia por Aleatorización

La prueba de hipótesis clásica requiere que N sea grande (aproximación asintótica).

Con experimentos pequeños (20–40 unidades) o valores atípicos influyentes, la inferencia puede ser inválida.

Cuando trabajamos con ensayos aleatorios, podemos usar el **diseño del experimento** como fuente de variabilidad: la única aleatoriedad es **la asignación del tratamiento**, no el muestreo de una población.

Inferencia por Aleatorización — Ejemplo

Name	D	Y	Y^0	Y^1
Andy	1	10	.	10
Ben	1	5	.	5
Chad	1	16	.	16
Daniel	1	3	.	3
Edith	0	5	5	.
Frank	0	7	7	.
George	0	8	8	.
Hank	0	10	10	.

$$ATE = 34/4 - 30/4 = 8.5 - 7.5 = 1$$

Inferencia por Aleatorización — Ejemplo

La **Hipótesis Nula Exacta de Fisher**: el efecto individual es cero para cada unidad.

$$H_0 : \delta_i = 0 \quad \forall i$$

Diferente de la hipótesis clásica (*el efecto medio es cero*): exige que ninguna unidad tenga ningún efecto.

Bajo H_0, podemos completar todos los resultados potenciales no observados y calcular qué ATE habríamos obtenido con **cualquier otra asignación posible**.

Inferencia por Aleatorización — Ejemplo

Bajo H_0, completamos la tabla de resultados potenciales:

Name	D	Y	Y^0	Y^1
Andy	1	10	**10**	10
Ben	1	5	**5**	5
Chad	1	16	**16**	16
Daniel	1	3	**3**	3
Edith	0	5	5	**5**
Frank	0	7	7	**7**
George	0	8	8	**8**
Hank	0	10	10	**10**

Inferencia por Aleatorización — Ejemplo

Con 4 tratados de 8 individuos: $\frac{8!}{4!\,4!} = 70$ asignaciones posibles.

Calculamos el ATE bajo cada una y construimos su distribución.

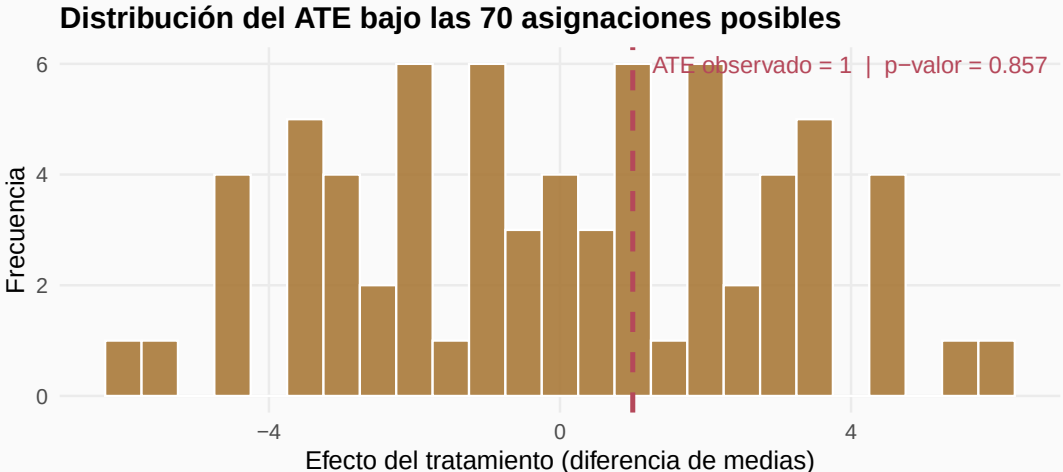

Inferencia por Aleatorización

En práctica, con experimentos grandes, no podemos enumerar todas las asignaciones.

Alternativa: reasignamos el tratamiento miles de veces de manera aleatoria — **prueba de permutación**.

Ventajas: - No requiere aproximaciones asintóticas: válido con muestras pequeñas. - Incorpora la estructura del diseño de manera natural (ej: aleatorización por grupos).

Lo veremos de nuevo en **Control Sintético**, donde la inferencia por permutación es el método estándar.

5. Resumen

Resumen

Método	Cuándo usar	Supuesto clave	Limitación
Clásico (OLS SE)	Siempre como punto de partida	Errores i.i.d., N grande	Inválido con correlación en errores
Agrupado (CRSE)	Datos jerárquicos, panel	Suficientes grupos ($G \geq 50$)	Falla con pocos grupos
Bootstrap	Estimadores complejos sin fórmula cerrada	Estimador varía suavemente	Falla con vecino más cercano
Aleatorización	Experimentos pequeños o con outliers	Solo diseño experimental	Solo para RCTs

Hacia adelante

Estos métodos reaparecen en cada módulo que sigue:

- **Errores agrupados** $\rightarrow$ DID (siempre se agrupa por unidad en datos de panel)
- **Cluster bootstrap** $\rightarrow$ DID heterogéneo, wild cluster bootstrap cuando G es pequeño
- **Aleatorización / permutación** $\rightarrow$ Control sintético (inferencia sin distribuciones asintóticas)

La **potencia** — la capacidad de detectar efectos reales — la discutiremos en **RD** (¿cuántas observaciones necesito cerca del corte?) e **IV** (¿qué tan preciso es un instrumento débil?).