

Teoría Econométrica II

Álgebra lineal para econometría

João Garcia

Universidad de Santiago de Chile

Clase 1 — 21 de septiembre de 2026

1

El curso

Tres ideas organizan el semestre

- ▶ La **identificación** es una propiedad del *diseño*, no del estimador.
- ▶ El ***shrinkage*** es una respuesta al riesgo desde la teoría de la decisión, no un truco de *machine learning*.
- ▶ La **inferencia** vale lo que vale la aproximación que la sustenta.

Tres ideas organizan el semestre

- ▶ La **identificación** es una propiedad del *diseño*, no del estimador.
- ▶ El ***shrinkage*** es una respuesta al riesgo desde la teoría de la decisión, no un truco de *machine learning*.
- ▶ La **inferencia** vale lo que vale la aproximación que la sustenta.

Cada parte del curso es una de estas tres ideas puesta a trabajar sobre un tipo de datos: paneles, tratamientos escalonados, muchos parámetros, pocas observaciones.

Qué cambia respecto de Teoría Econométrica I

Teoría I

Construir estimadores: MCO, VI, máxima verosimilitud, GMM

«¿Es insesgado y consistente?»

El modelo se supone correcto

Teoría II

Elegir entre estimadores y defender la elección

«¿Qué identifica este diseño y qué supuesto lo sostiene?»

El modelo es una aproximación; interesa qué pasa cuando falla

Qué cambia respecto de Teoría Econométrica I

Teoría I	Teoría II
Construir estimadores: MCO, VI, máxima verosimilitud, GMM	Elegir entre estimadores y defender la elección
«¿Es insesgado y consistente?»	«¿Qué identifica este diseño y qué supuesto lo sostiene?»
El modelo se supone correcto	El modelo es una aproximación; interesa qué pasa cuando falla

El prerrequisito técnico es álgebra matricial. Hoy la repasamos; el resto del semestre se usa sin avisar.

Evaluación

Componente	Ponderación
Cuatro tareas (<i>problem sets</i>)	24 %
Prueba solemne (miércoles 11 de noviembre)	26 %
Informe de árbitro sobre el proyecto de un compañero	10 %
Proyecto empírico	40 %

El proyecto se desglosa en propuesta (5), presentación (10) e informe final (25). Las notas de la solemne se publican antes del plazo de retiro temporal.

El proyecto

Replicar y **extender** un artículo publicado que use alguno de los métodos del curso y cuyos archivos de replicación estén disponibles.

Etapa	Fecha
Propuesta: replicación de una tabla principal y plan de extensión	mié 18 nov
Presentaciones	4 y 6 de enero
Informe final	sáb 9 de enero

Intuición

La extensión no tiene que ser ambiciosa: otro país, otro período, otra variable de resultado. Lo que se evalúa es el criterio con que se elige y se defiende.

Cómo trabajamos

- ▶ **Software:** R es el lenguaje del curso (`fixest`, `did`, `glmnet`, `hdm`, `DoubleML`, `boot`). Se dan los equivalentes en Stata; las tareas se pueden entregar en cualquiera de los dos.
- ▶ **Materiales:** diapositivas, código y tareas en [plataforma del curso].
- ▶ **Atención:** [horario por definir] — [correo].
- ▶ **Uso de IA:** [política por definir]. El estudiante responde por todo lo que entrega y debe poder explicarlo.

En la práctica — Antes del miércoles

Instalar R y los paquetes de la primera parte. Dos paquetes no están en CRAN y se instalan aparte; las instrucciones están en el programa.

Hoy

1. Rango, inversa e identificación
2. Proyecciones: P , M y Frisch–Waugh–Lovell
3. Formas cuadráticas y matrices definidas positivas
4. Valores propios y descomposición en valores singulares
5. Cálculo matricial en dos reglas

Hoy

1. Rango, inversa e identificación
2. Proyecciones: P , M y Frisch–Waugh–Lovell
3. Formas cuadráticas y matrices definidas positivas
4. Valores propios y descomposición en valores singulares
5. Cálculo matricial en dos reglas

Al final: **Tarea 0**, sin nota, para saber — ustedes y yo — qué hay que reforzar. Se entrega el domingo 27 y las soluciones se publican el lunes 28.

2

Álgebra lineal para econometría

Notación del curso

Símbolo	Significado
y, X	vector $n \times 1$ y matriz $n \times k$ de regresores
x_i	vector $k \times 1$ de la observación i (columna)
ι_n, I_n	vector de unos, matriz identidad
$X', \text{tr}(A)$	transpuesta, traza
$\ a\ ^2 = a'a$	norma euclidiana al cuadrado
P, M	matriz de proyección y su complemento

Los vectores son columnas salvo que se diga lo contrario. Todo lo que sigue vale para cualquier X de rango completo por columnas.

Rango e independencia lineal

Definición — Rango

El rango de X ($n \times k$) es el número de columnas linealmente independientes. X tiene **rango completo por columnas** si $\text{rango}(X) = k$, es decir, si $Xa = 0$ solo cuando $a = 0$.

Rango e independencia lineal

Definición — Rango

El rango de X ($n \times k$) es el número de columnas linealmente independientes. X tiene **rango completo por columnas** si $\text{rango}(X) = k$, es decir, si $Xa = 0$ solo cuando $a = 0$.

Traducción econométrica: ninguna variable explicativa es combinación lineal exacta de las demás. No es una tecnicidad — es la frontera entre “el dato puede distinguir dos efectos” y “no puede”.

Cuándo $X'X$ es invertible

Resultado — Tres afirmaciones equivalentes

Para X de dimensión $n \times k$ con $n \geq k$:

1. X tiene rango completo por columnas;
2. $X'X$ es definida positiva;
3. $\hat{\beta} = (X'X)^{-1}X'y$ existe y es único.

Cuándo $X'X$ es invertible

Resultado — Tres afirmaciones equivalentes

Para X de dimensión $n \times k$ con $n \geq k$:

1. X tiene rango completo por columnas;
2. $X'X$ es definida positiva;
3. $\hat{\beta} = (X'X)^{-1}X'y$ existe y es único.

La demostración de $1 \Rightarrow 2$ es una línea:

$$a'X'Xa = (Xa)'(Xa) = \|Xa\|^2 > 0 \quad \text{para todo } a \neq 0.$$

Un caso que verán todo el semestre

Sea $d_i \in \{0, 1\}$ con ambos valores presentes, y $X = [\iota_n \ d \ \iota_n - d]$.

❓ Pregunta — Dos minutos, en parejas

¿Cuál es el rango de X ? ¿Qué le pasa a $\hat{\beta}$? ¿Cómo lo arreglarían?

Un caso que verán todo el semestre

Sea $d_i \in \{0, 1\}$ con ambos valores presentes, y $X = [\iota_n \ d \ \iota_n - d]$.


❓ Pregunta — Dos minutos, en parejas

¿Cuál es el rango de X ? ¿Qué le pasa a $\hat{\beta}$? ¿Cómo lo arreglarían?

Rango 2, no 3: la primera columna es la suma de las otras dos. $X'X$ es singular y $\hat{\beta}$ **no está identificado**: hay infinitas soluciones que ajustan igual.

Se arregla eliminando una columna. Cuál se elimina cambia la interpretación de los coeficientes, no el ajuste. Con efectos fijos, el mismo problema aparece al incluir una constante y todas las *dummies* individuales.

MCO es una proyección



MCO no supone nada aquí: **descompone** y en la parte que X puede explicar y la que no. El ángulo recto es $X'e = 0$, las ecuaciones normales.

Las dos matrices

Definición — Proyección y complemento

$$P = X(X'X)^{-1}X', \quad M = I_n - P.$$

Propiedades, todas de una línea:

- ▶ P y M son **simétricas** e **idempotentes**: $PP = P$, $MM = M$
- ▶ $PX = X$ y $MX = 0$: proyectar lo que ya está en el plano no cambia nada
- ▶ $\hat{y} = Py$, $e = My$, y $PM = 0$

Las dos matrices

Definición — Proyección y complemento

$$P = X(X'X)^{-1}X', \quad M = I_n - P.$$

Propiedades, todas de una línea:

- ▶ P y M son **simétricas** e **idempotentes**: $PP = P$, $MM = M$
- ▶ $PX = X$ y $MX = 0$: proyectar lo que ya está en el plano no cambia nada
- ▶ $\hat{y} = Py$, $e = My$, y $PM = 0$

Todo el álgebra de efectos fijos es esto, con X igual a un conjunto de variables dummy.

Traza y grados de libertad

Con $\text{tr}(AB) = \text{tr}(BA)$:

$$\text{tr}(P) = \text{tr}((X'X)^{-1}X'X) = \text{tr}(I_k) = k, \quad \text{tr}(M) = n - k.$$

La traza de una proyección **cuenta dimensiones**: cuántas direcciones de y absorbe el modelo y cuántas quedan libres.

💡 Intuición

En la Parte IV, ridge reemplaza P por H_λ , que ya no es idempotente, y $\text{tr}(H_\lambda) < k$ pasa a llamarse *grados de libertad efectivos*. Es la misma cuenta.

El caso más simple: $X = \iota_n$

$$P = \frac{1}{n} \iota_n \iota_n', \quad Py = \bar{y} \iota_n, \quad My = y - \bar{y} \iota_n.$$

Proyectar sobre la constante es **promediar**; el residuo es **centrar**.

El caso más simple: $X = \iota_n$

$$P = \frac{1}{n} \iota_n \iota_n', \quad Py = \bar{y} \iota_n, \quad My = y - \bar{y} \iota_n.$$

Proyectar sobre la constante es **promediar**; el residuo es **centrar**.

Y $\text{tr}(M) = n - 1$: de ahí viene el denominador de la varianza muestral, no de una convención.

Del promedio al estimador *within*

En un panel con N individuos y T períodos, sea $D = I_N \otimes \iota_T$ la matriz de *dummies* individuales. Entonces

$$M_D \text{ y tiene elementos } y_{it} - \bar{y}_i, \quad \text{tr}(M_D) = NT - N.$$

En la práctica — Por qué importa en octubre

Efectos fijos no es “otro estimador”: es MCO después de aplicar M_D . Y los N grados de libertad que consume son los que hay que descontar al calcular errores estándar.

Frisch-Waugh-Lovell

Resultado — FWL

En $y = X_1\beta_1 + X_2\beta_2 + e$, el estimador MCO de β_2 es el mismo que se obtiene al regresar M_1y sobre M_1X_2 , con $M_1 = I - X_1(X_1'X_1)^{-1}X_1'$.

Frisch-Waugh-Lovell

Resultado — FWL

En $y = X_1\beta_1 + X_2\beta_2 + e$, el estimador MCO de β_2 es el mismo que se obtiene al regresar M_1y sobre M_1X_2 , con $M_1 = I - X_1(X_1'X_1)^{-1}X_1'$.

Controlar por X_1 es residualizar respecto de X_1 . El coeficiente de X_2 usa solo la variación de X_2 que X_1 no explica.

Frisch-Waugh-Lovell

Resultado — FWL

En $y = X_1\beta_1 + X_2\beta_2 + e$, el estimador MCO de β_2 es el mismo que se obtiene al regresar M_1y sobre M_1X_2 , con $M_1 = I - X_1(X_1'X_1)^{-1}X_1'$.

Controlar por X_1 es residualizar respecto de X_1 . El coeficiente de X_2 usa solo la variación de X_2 que X_1 no explica.

Si X_1 explica casi toda la variación de X_2 , lo que queda es ruido: el coeficiente sigue siendo insesgado, pero su varianza explota. Volveremos a esto al hablar de multicolinealidad y de ridge.

FWL, numéricamente

```
largo <- coef(lm(y ~ x1 + x2, data = datos))["x2"]

r_y <- resid(lm(y ~ x1, data = datos)) # y residualizado
r_x2 <- resid(lm(x2 ~ x1, data = datos)) # x2 residualizado
fwl <- coef(lm(r_y ~ r_x2))["r_x2"]

c(regresion_larga = unname(largo), fwl = unname(fwl))
```

```
#> regresion_larga          fwl
#>          -0.3253          -0.3253
```

FWL, numéricamente

```
largo <- coef(lm(y ~ x1 + x2, data = datos))["x2"]

r_y <- resid(lm(y ~ x1, data = datos)) # y residualizado
r_x2 <- resid(lm(x2 ~ x1, data = datos)) # x2 residualizado
fwl <- coef(lm(r_y ~ r_x2))["r_x2"]

c(regresion_larga = unname(largo), fwl = unname(fwl))
```

```
#> regresion_larga          fwl
#>          -0.3253          -0.3253
```

Idénticos, no parecidos: FWL es una identidad algebraica, no una aproximación.

Formas cuadráticas

Definición — Definida y semidefinida positiva

A simétrica es **semidefinida positiva** si $a'Aa \geq 0$ para todo a , y **definida positiva** si además $a'Aa > 0$ para todo $a \neq 0$.

Aparecen en tres lugares del curso:

- ▶ $X'X$, y con ella la existencia de $\hat{\beta}$
- ▶ toda matriz de varianzas: $\text{Var}(a'\hat{\theta}) = a'Va \geq 0$
- ▶ los estadísticos de Wald, que son formas cuadráticas en los residuos

Comparar dos estimadores

Sean $\hat{\theta}_0$ y $\hat{\theta}_1$ insesgados, con varianzas V_0 y V_1 , y supongamos que $V_1 - V_0$ es semidefinida positiva.

❓ Pregunta — Un minuto

¿Qué dice eso sobre $\text{Var}(a' \hat{\theta}_0)$ frente a $\text{Var}(a' \hat{\theta}_1)$, para un vector a cualquiera?

Comparar dos estimadores

Sean $\hat{\theta}_0$ y $\hat{\theta}_1$ insesgados, con varianzas V_0 y V_1 , y supongamos que $V_1 - V_0$ es semidefinida positiva.

❓ Pregunta — Un minuto

¿Qué dice eso sobre $\text{Var}(a' \hat{\theta}_0)$ frente a $\text{Var}(a' \hat{\theta}_1)$, para un vector a cualquiera?

$\text{Var}(a' \hat{\theta}_1) - \text{Var}(a' \hat{\theta}_0) = a'(V_1 - V_0)a \geq 0$: $\hat{\theta}_0$ es al menos tan preciso para **cualquier** combinación lineal, y en particular para cada coeficiente por separado.

Eso es “más eficiente” cuando el parámetro es un vector. El test de Hausman (7 de octubre) compara exactamente $V_1 - V_0$.

Valores propios: qué mide $X'X$

Si $X'X = Q\Lambda Q'$ con Q ortogonal, cada valor propio λ_j mide **cuánta variación** tienen los datos en la dirección q_j .

```
X <- cbind(1, datos$x1, datos$x2)
round(eigen(crossprod(X), symmetric = TRUE)$values, 1)
```

```
#> [1] 309.4 199.9 75.4
```

Valores propios: qué mide $X'X$

Si $X'X = Q\Lambda Q'$ con Q ortogonal, cada valor propio λ_j mide **cuánta variación** tienen los datos en la dirección q_j .

```
X <- cbind(1, datos$x1, datos$x2)
round(eigen(crossprod(X), symmetric = TRUE)$values, 1)
```

```
#> [1] 309.4 199.9 75.4
```


Un valor propio pequeño es multicolinealidad: una dirección del espacio de regresores sobre la que casi no hay datos. La inversa $(X'X)^{-1}$ la amplifica, y esa es la varianza del estimador.

Anticipo: qué hace ridge con esas direcciones

Ridge reemplaza $X'X$ por $X'X + \lambda I$. En cada dirección propia, el estimador se encoge por un factor

$$\frac{d_j^2}{d_j^2 + \lambda}.$$

Las direcciones con poca variación se encogen más: el método **desconfía** donde los datos informan poco.



Cálculo matricial: dos reglas

Para $a, b \in \mathbb{R}^k$ y A simétrica:

$$\frac{\partial a'b}{\partial b} = a, \quad \frac{\partial b'Ab}{\partial b} = 2Ab.$$

Con eso sale todo. En la pizarra:

$$S(b) = (y - Xb)'(y - Xb) \implies \frac{\partial S}{\partial b} = -2X'y + 2X'Xb = 0 \implies \hat{\beta} = (X'X)^{-1}X'y.$$

Cálculo matricial: dos reglas

Para $a, b \in \mathbb{R}^k$ y A simétrica:

$$\frac{\partial a'b}{\partial b} = a, \quad \frac{\partial b'Ab}{\partial b} = 2Ab.$$

Con eso sale todo. En la pizarra:

$$S(b) = (y - Xb)'(y - Xb) \implies \frac{\partial S}{\partial b} = -2X'y + 2X'Xb = 0 \implies \hat{\beta} = (X'X)^{-1}X'y.$$

La hessiana es $2X'X$, definida positiva: el punto crítico es un mínimo, y es único. La misma cuenta con $+\lambda b'b$ da ridge.

Para la próxima clase

En la práctica — Tarea 0 — sin nota

Catorce preguntas sobre lo de hoy, más una parte en R. Se entrega el **domingo 27**; las soluciones se publican el **lunes 28**. Respondan sin software ni IA: el objetivo es saber qué reforzar.

- ▶ **Lecturas:** Hansen, apéndice A (referencia); caps. 2 y 3 para el miércoles.
- ▶ **El miércoles:** qué estima MCO cuando el modelo lineal es falso, y cómo reportar su incertidumbre: heterocedasticidad y datos agrupados.