

Teoría Econométrica II

Qué estima MCO y cómo reportar su incertidumbre

João Garcia

Universidad de Santiago de Chile

Clase 2 — 23 de septiembre de 2026

Dónde quedamos

El lunes: P , M y Frisch–Waugh–Lovell. MCO **descompone** y ; eso es álgebra y no supone nada.

Dónde quedamos

El lunes: P , M y Frisch–Waugh–Lovell. MCO **descompone** y ; eso es álgebra y no supone nada.

Hoy, dos preguntas que sí son estadísticas:

1. Si el modelo lineal no es verdadero, ¿qué estima MCO?
2. ¿Cuánta incertidumbre tiene esa estimación, y de qué depende la respuesta?

1

¿Qué estima MCO?

La esperanza condicional

Definición — Esperanza condicional (CEF)

$m(x) = E[y \mid x]$ es el **mejor predictor** de y dado x : minimiza $E[(y - g(x))^2]$ entre todas las funciones g , lineales o no.

La esperanza condicional

Definición — Esperanza condicional (CEF)

$m(x) = E[y \mid x]$ es el **mejor predictor** de y dado x : minimiza $E[(y - g(x))^2]$ entre todas las funciones g , lineales o no.

Nadie discute que $m(x)$ es el objeto de interés predictivo. El problema es que casi nunca es lineal, y que estimarla sin imponer forma funcional es caro en dimensión alta (volveremos en la Parte IV).

El mejor predictor lineal

Definición — Mejor predictor lineal (BLP)

Si $E[xx']$ es invertible,

$$\beta = \arg \min_b E[(y - x'b)^2] = E[xx']^{-1}E[xy],$$

y $x'\beta$ es el mejor predictor lineal de y dado x .

El mejor predictor lineal

Definición — Mejor predictor lineal (BLP)

Si $E[xx']$ es invertible,

$$\beta = \arg \min_b E[(y - x'b)^2] = E[xx']^{-1}E[xy],$$

y $x'\beta$ es el mejor predictor lineal de y dado x .

MCO es el análogo muestral: $\hat{\beta} = (X'X)^{-1}X'y$. Existe siempre que X tenga rango completo, crea uno o no en el modelo.

Lo que la recta aproxima

Resultado — La proyección aproxima la CEF

$$\beta = \arg \min_b E[(m(x) - x'b)^2].$$

La recta de MCO es la mejor aproximación lineal **a la esperanza condicional**, no a los datos crudos.

Lo que la recta aproxima

Resultado — La proyección aproxima la CEF

$$\beta = \arg \min_b E[(m(x) - x'b)^2].$$

La recta de MCO es la mejor aproximación lineal **a la esperanza condicional**, no a los datos crudos.


Dos consecuencias:

- ▶ MCO siempre estima algo bien definido e interpretable, aunque el modelo sea falso.
- ▶ Ese algo depende de **cómo se distribuye** x : la aproximación pondera más donde hay más datos. Cambiar la muestra cambia la recta, aunque la CEF sea la misma.

La CEF y su aproximación lineal

- Datos simulados: log salario y experiencia
- La esperanza condicional es cóncava; la proyección, no
- MCO recupera la **recta**, no la curva

La pendiente de MCO promedia las pendientes locales.



Dos condiciones que se confunden

$$y = x'\beta + e, \quad E[xe] = 0.$$

La ortogonalidad **se cumple por construcción**: es la definición de β , no un supuesto que se pueda violar.

Dos condiciones que se confunden

$$y = x'\beta + e, \quad E[xe] = 0.$$

La ortogonalidad **se cumple por construcción**: es la definición de β , no un supuesto que se pueda violar.

Qué puede fallar — No es lo mismo

$E[e | x] = 0$ es mucho más fuerte: dice que la CEF **es** lineal. Solo entonces la recta es la esperanza condicional y no apenas su mejor aproximación.

2

De dónde sale la varianza

El punto de partida

De $\hat{\beta} = \beta + (X'X)^{-1}X'e$, dividiendo arriba y abajo por n :

$$\hat{\beta} - \beta = \underbrace{\left(\frac{1}{n} \sum_i x_i x_i'\right)^{-1}}_{\hat{Q}^{-1}} \underbrace{\left(\frac{1}{n} \sum_i x_i e_i\right)}_{\bar{s}}.$$

Todo lo que sigue es averiguar hacia dónde van esos dos objetos.

Supuesto — Lo que se usa, explícitamente

(A1) $\{(y_i, x_i)\}_{i=1}^n$ son i.i.d. — en particular, **independientes entre sí**.

(A2) $E[xe] = 0$ — por construcción, como vimos hace un rato.

(A3) $Q = E[xx']$ existe y es invertible.

(A4) $E\|x\|^4 < \infty$ y $E[e^4] < \infty$, de modo que $\Omega = E[xx'e^2]$ existe.

Tres teoremas, en este orden

1. **Ley de los grandes números**, por (A1) y (A3): $\hat{Q} = \frac{1}{n} \sum_i x_i x_i' \xrightarrow{p} Q$.
2. **Teorema central del límite** (Lindeberg-Lévy, i.i.d.), por (A1), (A2) y (A4):

$$\frac{1}{\sqrt{n}} \sum_i x_i e_i \xrightarrow{d} N(0, \Omega), \quad \Omega = \text{Var}(xe) = E[xx'e^2].$$

3. **Mapeo continuo y Slutsky**, por (A3): invertir es continuo en Q invertible, y se puede multiplicar el límite en distribución por el límite en probabilidad.

Resultado — Distribución asintótica de MCO

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, Q^{-1}\Omega Q^{-1}).$$

Estimar el relleno del sándwich

$$\hat{\Omega} = \frac{1}{n} \sum_i x_i x_i' \hat{e}_i^2 \xrightarrow{p} \Omega, \quad \hat{V} = \hat{Q}^{-1} \hat{\Omega} \hat{Q}^{-1}.$$

- ▶ Otra vez la ley de los grandes números, más $\hat{\beta} \xrightarrow{p} \beta$ para pasar de e_i (que no se observa) a $\hat{e}_i$: ahí entra (A4).
- ▶ Por Slutsky, el estadístico t con $\hat{V}$ es asintóticamente $N(0, 1)$. **Todo esto es asintótico**: nada aquí vale en muestra finita.

✂ En la práctica — Las correcciones HC

$\hat{e}_i$ es en promedio más chico que e_i . HC1 multiplica por $n/(n-k)$; HC3 divide $\hat{e}_i$ por $1 - h_{ii}$ y funciona mejor con n chico o con observaciones de alto apalancamiento.

El caso clásico es un caso particular

Si $E[e^2 | x] = \sigma^2$ (homocedasticidad), entonces $\Omega = E[xx'e^2] = \sigma^2 Q$, y el sándwich colapsa:

$$Q^{-1}\Omega Q^{-1} = \sigma^2 Q^{-1} \quad \Rightarrow \quad \hat{V} = s^2(X'X)^{-1}.$$

El caso clásico es un caso particular

Si $E[e^2 | x] = \sigma^2$ (homocedasticidad), entonces $\Omega = E[xx'e^2] = \sigma^2 Q$, y el sándwich colapsa:

$$Q^{-1}\Omega Q^{-1} = \sigma^2 Q^{-1} \quad \Rightarrow \quad \hat{V} = s^2(X'X)^{-1}.$$

Esa es la fórmula por defecto de cualquier software. Pero solo es válida bajo supuestos fuertes. Con heterocedasticidad puede subestimar o sobreestimar la varianza, y no hay una dirección garantizada.

Qué no arreglan los errores robustos

Qué puede fallar

Un error estándar robusto corrige la **varianza**, no la **especificación**. Si la CEF no es lineal, $\hat{\beta}$ sigue estimando la mejor aproximación lineal.

3

Cuando Independencia No Vale

La independencia falla por diseño

Tres situaciones, todas habituales:

- ▶ **Muestreo por conglomerados:** se eligen escuelas, y dentro de cada escuela todos los estudiantes.
- ▶ **Tratamiento asignado a nivel de grupo:** la política llega a la comuna, no a la persona.
- ▶ **Datos de panel:** la misma unidad observada muchas veces.

La independencia falla por diseño

Tres situaciones, todas habituales:

- ▶ **Muestreo por conglomerados:** se eligen escuelas, y dentro de cada escuela todos los estudiantes.
- ▶ **Tratamiento asignado a nivel de grupo:** la política llega a la comuna, no a la persona.
- ▶ **Datos de panel:** la misma unidad observada muchas veces.

En los tres casos, dos observaciones del mismo grupo comparten un componente no observado. La muestra tiene **menos información** que n observaciones independientes.

Dónde exactamente se rompe la derivación

Agrupemos la suma del paso 2 por grupos, con $s_g = \sum_{i \in g} x_i e_i$:

$$\sum_{i=1}^n x_i e_i = \sum_{g=1}^G s_g.$$

- ▶ (A1) vale **entre** grupos, no **dentro**. El teorema central del límite ya no se aplica a las n observaciones: se aplica a las G sumas s_g .
- ▶ La asintótica corre en G , no en n . Agregar estudiantes a una escuela ya muestreada agrega poca información.

Dónde exactamente se rompe la derivación

Agrupemos la suma del paso 2 por grupos, con $s_g = \sum_{i \in g} x_i e_i$:

$$\sum_{i=1}^n x_i e_i = \sum_{g=1}^G s_g.$$

- ▶ (A1) vale **entre** grupos, no **dentro**. El teorema central del límite ya no se aplica a las n observaciones: se aplica a las G sumas s_g .
- ▶ La asintótica corre en G , no en n . Agregar estudiantes a una escuela ya muestreada agrega poca información.

$$\text{Var}\left(\sum_i x_i e_i\right) = \underbrace{\sum_i E[x_i x_i' e_i^2]}_{\text{lo que estima } \hat{\Omega}} + \underbrace{\sum_g \sum_{i \neq j \in g} E[x_i e_i e_j x_j']}_{\text{lo que } \hat{\Omega} \text{ ignora}}.$$

La varianza agrupada

El mismo sándwich, con un relleno que sí incluye los productos cruzados:

$$\hat{\Omega}_c = \frac{1}{n} \sum_{g=1}^G X'_g \hat{e}_g \hat{e}'_g X_g, \quad \hat{V}_{\text{cluster}} = \hat{Q}^{-1} \hat{\Omega}_c \hat{Q}^{-1}.$$

Dentro del grupo se permite **cualquier** estructura de correlación; entre grupos, ninguna. Es consistente cuando $G \rightarrow \infty$.

 **Qué puede fallar — El estimador robusto no está mal calculado**

Estima consistentemente el objeto equivocado: el supuesto que lo justificaba — (A1) — dejó de cumplirse.

¿A qué nivel agrupar?

La pregunta no es de software. Abadie, Athey, Imbens y Wooldridge (2023): agrupar es una afirmación sobre el **diseño** — cómo se muestreó y cómo se asignó el tratamiento.

- ▶ Regla de trabajo: agrupar **al nivel al que se asigna el tratamiento**.
- ▶ Si el diseño tiene niveles anidados (estudiante en escuela en comuna), el nivel relevante es el más agregado con dependencia plausible.

¿A qué nivel agrupar?

La pregunta no es de software. Abadie, Athey, Imbens y Wooldridge (2023): agrupar es una afirmación sobre el **diseño** — cómo se muestreó y cómo se asignó el tratamiento.

- ▶ Regla de trabajo: agrupar **al nivel al que se asigna el tratamiento**.
- ▶ Si el diseño tiene niveles anidados (estudiante en escuela en comuna), el nivel relevante es el más agregado con dependencia plausible.

⚠ Qué puede fallar — Los dos errores

Agrupar demasiado fino subestima los errores estándar. Agrupar demasiado grueso deja pocos grupos.

Pocos grupos

El teorema central del límite corre en G : con G chico (digamos, menos de 30–40) la aproximación normal simplemente no vale, y los tests **rechazan de más** — un test al 5, % puede rechazar 10 o 15 veces de cada 100.

Pocos grupos

El teorema central del límite corre en G : con G chico (digamos, menos de 30–40) la aproximación normal simplemente no vale, y los tests **rechazan de más** — un test al 5, % puede rechazar 10 o 15 veces de cada 100.

Vamos a ver cómo tratar el problema de pocos grupos con un tipo de bootstrap.

El factor de Moulton

$$\frac{\text{EE agrupado}}{\text{EE i.i.d.}} \approx \sqrt{1 + \rho_x \rho_e (m - 1)}.$$

- Donde m es el tamaño promedio de los grupos, ρ_x es la correlación intragrupal en X , y ρ_e es la correlación intragrupal del error.

Cuánto cuesta ignorarlo

```
m1 <- feols(y ~ x, data = agrupados) # 40 escuelas, 25 estudiantes c/u
se <- function(v) unname(sqrt(diag(vcov(m1, vcov = v))["x"]))

icc <- function(v, g) { # correlación intraclase
  entre <- var(tapply(v, g, mean)); dentro <- mean(tapply(v, g, var))
  entre / (entre + dentro)
}

moulton <- sqrt(1 + icc(agrupados$x, agrupados$escuela) *
  icc(resid(m1), agrupados$escuela) * (m - 1))

round(c(iid = se("iid"), hetero = se("hetero"), cluster = se(~escuela),
  razon = se(~escuela) / se("iid"), moulton = moulton), 3)
```

```
#>      iid  hetero cluster  razon moulton
#> 0.038  0.038   0.115   3.059   2.944
```

El factor de Moulton

$$\frac{\text{EE agrupado}}{\text{EE i.i.d.}} \approx \sqrt{1 + \rho_x \rho_e (m - 1)}.$$

- ▶ Observado: 3,06. Predicho por la fórmula: 2,94; la diferencia viene de estimar ρ_x y ρ_e .
- ▶ Con $m = 25$ y correlaciones intraclase altas, el castigo es un factor cercano a 3: el mismo coeficiente, tres veces menos preciso de lo que dice el software.

✂ En la práctica — La regla mínima del curso

Reportar siempre qué supuesto de dependencia se está haciendo, y por qué. En `fixest`: `vcov = "hetero"` o `vcov = ~grupo`. En `Stata`: `robust` o `cluster(grupo)`.

- ▶ **Lecturas:** Hansen, cap. 2 (§2.18–2.30), cap. 3 (§3.11–3.18) y cap. 4 (§4.14–4.25, sobre todo §4.21–4.25); Abadie, Athey, Imbens & Wooldridge (2023, *QJE*).
- ▶ **Tarea 0:** entrega el domingo 27; soluciones el lunes 28.
- ▶ **El lunes:** variables instrumentales en una sesión — MC2E como GMM, LATE e instrumentos débiles.