

Probit, Logit y Propensity Score

2026-04-22

Motivación

¿Dónde quedamos?

En la clase anterior necesitamos estimar el **propensity score**:

$$\hat{p}(X_i) = \widehat{\Pr}(D_i = 1 \mid X_i)$$

Lo usamos en dos lugares:

1. **Emparejamiento en el PS:** igualar tratados y controles con el mismo $\hat{p}(X)$
2. **Ponderación por inverso de probabilidad (IPW):** reponderar la muestra

Dijimos: “estimamos $\hat{p}(X)$ con un logit o probit de D sobre X .”

¿Por qué logit o probit? ¿Por qué no simplemente OLS?

El objeto que necesitamos

El propensity score es una **probabilidad**:

$$p(X) = \Pr(D = 1 \mid X) \in [0, 1]$$

Necesitamos un modelo que:

- Produzca predicciones **acotadas en $[0, 1]$** para cualquier valor de X
- Sea flexible: la probabilidad de recibir tratamiento puede variar de forma no lineal con X

OLS no garantiza ninguna de las dos cosas.

Primera idea: el Modelo de Probabilidad Lineal

El **Modelo de Probabilidad Lineal (MPL)** estima:

$$D_i = \alpha + X_i' \beta + u_i$$

por MCO, interpretando $\hat{D}_i = \hat{\alpha} + X_i' \hat{\beta}$ como estimación de $\Pr(D_i = 1 \mid X_i)$.

Pregunta: ¿qué podría salir mal?

La patología del MPL

MPL: ventajas honestas

El MPL tiene virtudes reales que no hay que ignorar:

- Los coeficientes son **efectos marginales directos**: $\hat{\beta}_k \approx \Delta \Pr(D = 1)$ cuando X_k sube en 1
- La estimación es simple (MCO) y los errores estándar robustos funcionan bien
- Si $\hat{p}(X)$ se mantiene lejos de 0 y 1, los problemas son menores

El MPL funciona razonablemente bien como aproximación lineal a la CEF binaria **cuando la proporción tratada no es extrema**. El problema aparece en los extremos.

MPL: el problema — predicciones fuera de $[0, 1]$

```
set.seed(2026)
x <- runif(200, 0, 10)
D <- rbinom(200, 1, plogis(-3 + 0.6 * x))


lpm <- lm(D ~ x)
range(predict(lpm))

## [1] -0.0009639 1.1176340

mean(predict(lpm) < 0 | predict(lpm) > 1)

## [1] 0.1
```

MPL: visualización de la patología



MCO extrapola más allá de $[0, 1]$

MPL: heterocedasticidad estructural

Para una variable binaria D :

$$\text{Var}(D \mid X) = p(X)(1 - p(X))$$

La varianza **depende de** X por construcción — el error es heterocedástico mecánicamente.

Consecuencia práctica: los errores estándar de MCO están mal. La solución habitual es usar **errores estándar robustos** (`vcovHC`), que mitigan el problema.

Esto es un motivo adicional para preferir modelos diseñados para resultados binarios.

Lo que queremos

Buscamos una función $g : \mathbb{R} \rightarrow (0, 1)$ tal que:

$$\Pr(D = 1 \mid X) = g(X\beta)$$

La solución natural: usar una **función de distribución acumulada (CDF)**.

$$\text{CDF}(-\infty) = 0, \quad \text{CDF}(+\infty) = 1, \quad \text{CDF creciente}$$

Una CDF está acotada en $(0, 1)$ por definición y produce una curva en S — exactamente la forma que esperamos para una probabilidad.

Logit y Probit

El modelo de variable latente

Imaginamos una variable continua latente D^* :

$$D^* = X\beta + \varepsilon, \quad D = \mathbf{1}\{D^* > 0\}$$

Entonces:

$$\Pr(D = 1 \mid X) = \Pr(D^* > 0 \mid X) = \Pr(\varepsilon > -X\beta \mid X) = F_\varepsilon(X\beta)$$

donde F_ε es la CDF de ε (asumiendo distribución simétrica alrededor de 0).

La **elección de F_ε** determina el modelo:

- $F_\varepsilon = \Phi$ (normal estándar) $\Rightarrow$ **Probit**
- $F_\varepsilon = \Lambda$ (logística) $\Rightarrow$ **Logit**

Logit y probit

Probit: $F_{\varepsilon} = \Phi$ (CDF normal estándar)

$$\Pr(D = 1 \mid X) = \Phi(X\beta)$$


Logit: $F_{\varepsilon} = \Lambda$ (CDF logística)

$$\Pr(D = 1 \mid X) = \Lambda(X\beta) = \frac{e^{X\beta}}{1 + e^{X\beta}}$$

Ambas modelos:

- Producen predicciones en $(0, 1)$, independientemente de $X\beta$
- Tienen forma de S: la probabilidad cambia poco en los extremos y mucho en el centro
- Son **indistinguibles en la práctica** para la mayoría de aplicaciones

Logit vs. probit: prácticamente lo mismo



Logit reescalado por $\pi/\sqrt{3} \sim 1.81$ para comparacion directa

Estimación: máxima verosimilitud

No podemos usar MCO para estimar β porque D es binaria. En su lugar usamos **máxima verosimilitud (MLE)**.

La función de verosimilitud es:

$$\mathcal{L}(\beta) = \prod_{i=1}^n p_i^{D_i} (1 - p_i)^{1-D_i}$$

donde $p_i = \Lambda(X_i\beta)$ para logit o $\Phi(X_i\beta)$ para probit.

Intuición: buscamos $\hat{\beta}$ que asigne la mayor probabilidad posible a los datos que efectivamente observamos.

En R, `glm()` resuelve este problema automáticamente.

Sintaxis en R

Logit

```
logit_ej <- glm(D ~ x1 + x2 + x3,  
               family = binomial(link = "logit"),  
               data = mis_datos)
```

Probit

```
probit_ej <- glm(D ~ x1 + x2 + x3,  
                family = binomial(link = "probit"),  
                data = mis_datos)
```

Las predicciones en probabilidad se obtienen con:

```
predict(logit_ej, type = "response")    # en [0, 1]  
predict(logit_ej)                       # en log-odds (escala lineal)
```

Demo: el propensity score en NSW-CPS

Los datos: NSW y CPS

National Supported Work (NSW): programa de empleo aleatorizado en EE.UU. Tomamos solo los **tratados** experimentales ($n = 185$). El efecto experimental sobre ingresos fue $\approx \$1\{, \}800$.

Current Population Survey (CPS): muestra representativa de la población. Los usamos como **controles observacionales** ($n = 16,177$).

Variable	Descripción
treat	1 = participó en NSW, 0 = CPS
re78	Ingresos en 1978 (resultado)
age, educ, black, hisp	Covariables demográficas
marr, nodegree, re74, re75	Covariables socioeconómicas

Carga de datos

```
read_data <- function(df)
  read_dta(paste0(
    "https://github.com/scunning1975/mixtape/raw/master/", df))

nsw_dw <- read_data("nsw_mixtape.dta") |> filter(treat == 1)
data_ps <- read_data("cps_mixtape.dta") |> bind_rows(nsw_dw)

table(data_ps$treat)

##
##      0      1
## 15992   185
```

MPL en los datos NSW-CPS

El MPL aquí está en su peor escenario: solo $\approx 1\%$ de la muestra es tratada.

```
lpm_ps <- lm(treat ~ age + educ + black + hisp +  
             marr + nodegree + re74 + re75,  
             data = data_ps)
```

```
summary(predict(lpm_ps))
```

```
##      Min.  1st Qu.   Median     Mean  3rd Qu.    Max.  
## -0.01799 -0.00913  0.00211  0.01144  0.01569  0.14259
```

```
mean(predict(lpm_ps) < 0)
```

```
## [1] 0.4568
```

Logit básico para el PS

```
logit_basico <- glm(  
  treat ~ age + educ + black + hisp +  
    marr + nodegree + re74 + re75,  
  family = binomial(link = "logit"),  
  data = data_ps  
)
```


```
data_ps$ps_basico <- predict(logit_basico, type = "response")
```

```
summary(data_ps$ps_basico)
```

```
##      Min. 1st Qu.  Median      Mean 3rd Qu.      Max.  
## 0.0000 0.0000 0.0002 0.0114 0.0019 0.4884
```

Todas las predicciones en $(0, 1)$.

Distribución del propensity score



Coeficientes del logit: ¿qué significan?

El modelo logit estima:

$$\Pr(D = 1 \mid X) = \Lambda(X\beta) = \frac{e^{X\beta}}{1 + e^{X\beta}}$$

El efecto de X_k sobre la probabilidad es:

$$\frac{\partial \Pr(D = 1 \mid X)}{\partial X_k} = \underbrace{\lambda(X\beta)}_{\text{depende de } X} \cdot \beta_k$$

donde $\lambda(z) = \Lambda(z)(1 - \Lambda(z)) \in (0, 0.25]$.

$\hat{\beta}_k$ no es el cambio en probabilidad. El signo y la significancia estadística sí son informativos — pero no el valor numérico del coeficiente directamente.

Efectos marginales promedio (AME)

Para resumir el efecto de X_k , usamos el **efecto marginal promedio (AME)**:

$$AME_k = \frac{1}{n} \sum_{i=1}^n \lambda(X_i \hat{\beta}) \cdot \hat{\beta}_k$$

El AME promedia el efecto marginal calculado en cada observación. Es el estándar moderno porque no requiere elegir un punto de evaluación arbitrario.

Coeficientes logit (no son efectos sobre $Pr(D=1)$)

```
round(coef(logit_basico)[-1], 4)
```

##	age	educ	black	hisp	marr	nodegree	re74	re75
##	-0.0038	0.0346	4.2068	1.7936	-0.9899	1.0355	0.0000	-0.0002

AME con marginales

```
avg_slopes(logit_basico) |>
  select(Variable = term,
         AME       = estimate,
         `Err. Est.` = std.error) |>
  mutate(across(where(is.numeric), \(x) round(x, 5))) |>
  knitr::kable(booktabs = TRUE)
```

Variable	AME	Err. Est.
age	0.0000	0.0001
black	0.0759	0.0062
educ	0.0003	0.0004
hisp	0.0213	0.0058
marr	-0.0078	0.0017
nodegree	0.0086	0.0022

Balance e iteración de la especificación

Midiendo el balance: la DME

La **Diferencia Media Estandarizada (DME)** mide el desbalance en una covariable X_k entre tratados y controles:

$$DME_k = \frac{\bar{X}_k^T - \bar{X}_k^C}{\sqrt{\frac{s_k^{T^2} + s_k^{C^2}}{2}}}$$

- Estandariza la diferencia por la desviación estándar combinada
- Permite comparar entre covariables de distintas escalas
- Regla de referencia: $|DME| < 0.1$ indica buen balance

```
smd <- function(x_t, x_c)
  (mean(x_t) - mean(x_c)) / sqrt((var(x_t) + var(x_c)) / 2)
```

Desbalance crudo en NSW-CPS

```
vars <- c("age", "educ", "black", "hisp", "marr", "nodegree", "re74", "re75")
smd_crudo <- sapply(vars, function(v)
  smd(data_ps[[v]][data_ps$treat == 1],
      data_ps[[v]][data_ps$treat == 0]))
round(smd_crudo, 2)
```

##	age	educ	black	hisp	marr	nodegree	re74	re75
##	-0.80	-0.68	2.43	-0.05	-1.23	0.90	-1.57	-1.75

El desbalance es enorme: el grupo NSW (tratados) y el CPS (controles) son muestras muy distintas. Esto es exactamente el problema que el propensity score quiere resolver.

Ponderación IPW con el PS básico

Para el ATT, los pesos IPW son:

$$w_i = \begin{cases} 1 & \text{si } D_i = 1 \\ \frac{\hat{p}(X_i)}{1 - \hat{p}(X_i)} & \text{si } D_i = 0 \end{cases}$$

```
w_att1 <- with(data_ps,  
               ifelse(treat == 1, 1, ps_basico / (1 - ps_basico)))
```

La DME ponderada evalúa si los pesos logran equilibrar la distribución de X .

Balance post-IPW: especificación básica

Variable	DME crudo	DME post-IPW (básico)
age	-0.80	0.06
educ	-0.68	0.01
black	2.43	0.00
hisp	-0.05	0.00
marr	-1.23	0.01
nodegree	0.90	-0.01
re74	-1.57	-0.02
re75	-1.75	-0.01

Éxito: todas las DME post-IPW caen bajo 0.1, el umbral convencional para considerar balance aceptable. La especificación básica funciona en estos datos.

La regla del juego

Principio

El PS es un **medio** para balancear X , no un fin.

El criterio **es**: ¿la especificación logra balance en X ?

Si la DME post-IPW (o post-matching) sigue alta para alguna covariable, mejoramos la especificación añadiendo:

- Polinomios: X^2 , X^3
- Interacciones: $X_j \times X_k$
- Indicadores para valores especiales (e.g., $\mathbb{1}\{X = 0\}$)

Es lo que hace Dehejia & Wahba (1999) en NSW-CPS — y por eso la especificación de `logit_nsw` en `Selección.Rmd` incluye cuadrados, cubos e interacciones.

¿Y por qué no usamos t -tests para balance?

Una intuición común: “comparemos las medias con un t -test.”

Mala idea. El estadístico t entre tratados y controles para X_k es aproximadamente:

$$t_k \approx \text{DME}_k \cdot \sqrt{\frac{n_T n_C}{n_T + n_C}}$$

El t -stat **conflata tamaño del desbalance con tamaño muestral**:

- Con $n_C = 16,177$ controles: *cualquier* diferencia es “significativa”, aunque $\text{DME} = 0.01$
- Con un RCT pequeño ($n = 50$ por grupo): diferencias reales pueden no salir significativas

La DME mide el **tamaño del desbalance**, independiente de n . Es lo que importa para el sesgo del estimador, no la “significancia” estadística de la diferencia.

Modelo	Garantiza $[0, 1]$	Coef = ΔPr	Estimación
MPL	No	Sí	MCO
Probit	Sí	No	MLE
Logit	Sí	No	MLE

Para el PS: logit (o probit) por construcción produce $\hat{p} \in (0, 1)$.

Para interpretar: los coeficientes no son efectos en probabilidad; usar AME (`avg_slopes()`).

Para evaluar: balance en X post-IPW o post-matching ($DME < 0.1$); iterar la especificación si falla. *No* t -tests.

En Selección.Rmd la especificación de `logit_nsw` ya incorpora cuadrados, cubos e