Repaso Probabilidad y Estadística

Joao Garcia

2025-02-06

USACH

Objetivos de la clase

Al finalizar esta clase podrás:

1. Describir una distribución y calcular sus momentos (promedio, varianza, covarianza)
2. Calcular probabilidades condicionales e interpretar la esperanza condicional $E[Y|X]$
3. Calcular y aplicar la Ley de Esperanzas Iteradas con ejemplos concretos
4. Distinguir entre independencia estadística, independencia en media y correlación cero

¿Por qué importa? Estas herramientas son el lenguaje de la inferencia causal. La suposición central de cada estrategia de identificación que veremos es una condición de independencia.

Momentos: esperanza y varianza

Esperanza (valor promedio poblacional):

$$E[X] = \sum_x x \cdot \Pr(X = x) \qquad \bar{X} = \frac{1}{N}\sum_{i=1}^{N} x_i \text{ (muestral)}$$

Propiedades: $E[a + bX] = a + bE[X]$; $E[X + Y] = E[X] + E[Y]$.

Varianza (dispersión):

$$\mathrm{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2$$

Propiedad: $\mathrm{Var}(a + bX) = b^2\,\mathrm{Var}(X)$.

¿Por qué el promedio y no la mediana? El promedio es lineal — la mediana generalmente no. Esto facilita enormemente el álgebra de la inferencia causal.

Covarianza y correlación

La **covarianza** mide la asociación lineal entre dos variables:

$$\mathrm{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

Propiedades: $\mathrm{Cov}(X, X) = \mathrm{Var}(X)$; $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X, Y)$.

La **correlación** normaliza la covarianza al rango $[-1, 1]$:

$$\mathrm{Corr}(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}$$

Conexión con regresión: el coeficiente de regresión simple es $\beta = \dfrac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}$.

Desviación estándar y distribución normal

La **desviación estándar** $\sigma = \sqrt{\mathrm{Var}(X)}$ devuelve las unidades naturales de X.

Si $X \sim \mathcal{N}(\mu, \sigma^2)$: simétrica; $\approx 68\%$ de la masa en $[\mu \pm \sigma]$; $\approx 95\%$ en $[\mu \pm 2\sigma]$.

Ley de los Grandes Números: con n grande, $\bar{X} \xrightarrow{p} \mu$.

Teorema Central del Límite: $\dfrac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$.

Esto justifica el uso de la distribución normal en pruebas de hipótesis — incluso cuando los datos individuales no son normales.

Población y muestra

Hasta ahora hemos tratado X como una variable con una distribución fija (la **población**).

En la práctica, observamos una **muestra** de N observaciones $\{x_1, \ldots, x_N\}$ extraídas de esa distribución.

- La media poblacional $\mu = E[X]$ es **desconocida**.
- La **media muestral** $\bar{X} = \frac{1}{N}\sum_{i=1}^{N} x_i$ es nuestro estimador.
- $\bar{X}$ es una variable aleatoria: varía entre muestras.

La distinción población/muestra es central en econometría: el parámetro β existe en la población; $\hat{\beta}$ lo estima con datos muestrales.

Distribuciones condicionales

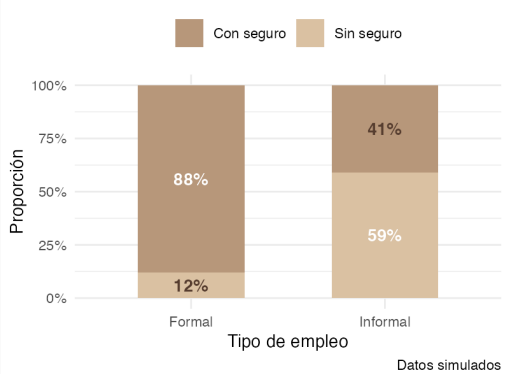

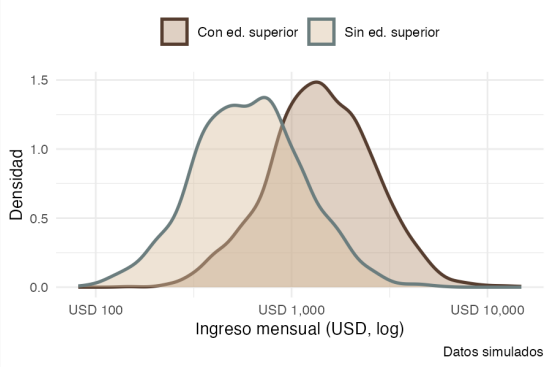

La distribución de una variable *cambia* según el valor de otra — eso es una distribución condicional.

Probabilidad condicional

Escribimos $\Pr(Y{=}y \mid X{=}x)$ para la probabilidad de que Y tome el valor y, dado que X tomó el valor x.

Regla del producto

$$\Pr(A \cap B) = \Pr(A \mid B) \cdot \Pr(B)$$

Reordenando obtenemos el **Teorema de Bayes**:

$$\Pr(A \mid B) = \frac{\Pr(B \mid A) \cdot \Pr(A)}{\Pr(B)}$$

Ejemplo: El 1% de la población tiene una enfermedad. Un test tiene 90% de sensibilidad y 95% de especificidad. Si el test da positivo, ¿cuál es la probabilidad de estar enfermo?

Esperanza Condicional

Otra forma de resumir cómo se relacionan dos variables es la esperanza condicional.

$$E[Y|X = x] = \sum_y y \cdot \Pr(Y = y|X = x)$$

Sea Y = indicador de pobreza extrema y X = país. Cada barra es $E[Y \mid X = \text{país}]$:

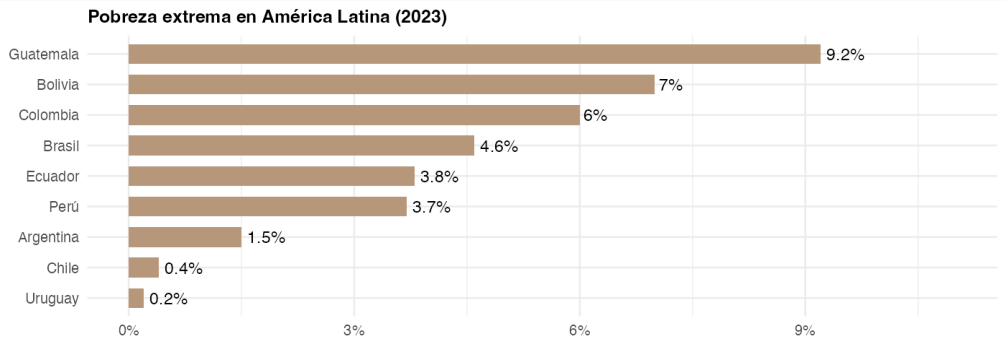

Esperanza Condicional

Supón que tienes las esperanzas condicionales para cada valor de X.

¿Cómo se puede calcular la esperanza no condicional?

Ejemplo: dadas las tasas de pobreza en cada país, ¿cómo calcular la tasa de pobreza de Latinoamérica?

Esperanza Condicional

¿Cómo se puede calcular la esperanza no condicional?

Podemos calcular la tasa de pobreza en Latinoamérica multiplicando cada tasa por la población del país, sumando, y dividiendo por la población total.

En general:

Ley de Esperanzas Iteradas

$$E[X] = \sum_y E[X|Y = y] \cdot \Pr(Y = y) = E[E[X|Y]]$$

LIE: aplicación

Ejemplo: estatura promedio

La estatura promedio de hombres es 175 cm y la de mujeres es 163 cm. En un grupo hay 3 hombres por cada 2 mujeres. ¿Cuál es la estatura promedio?

$$E[H] = E[H \mid \text{Hombre}] \cdot \Pr(\text{Hombre}) + E[H \mid \text{Mujer}] \cdot \Pr(\text{Mujer})$$

$$= 175 \cdot \tfrac{3}{5} + 163 \cdot \tfrac{2}{5} = 105 + 65.2 = \mathbf{170.2} \text{ cm}$$

Clave: podemos recuperar la esperanza incondicional ponderando las esperanzas condicionales por las probabilidades de cada grupo. Usaremos esto constantemente al trabajar con submuestras (tratados vs. control).

Independencia

¿Por qué importa? La condición $E[u|X] = 0$ de OLS es independencia en media. Cada estrategia de identificación del curso es una forma distinta de garantizarla.

Decimos que dos variables son **independientes** si la información sobre una no cambia la distribución de la otra.

Definición

$$X \perp Y \iff \Pr(X = x | Y = y) = \Pr(X = x),\ \forall x, y$$

Es decir, la distribución condicional de X no varía con el valor que tome Y.

Alternativamente: $X \perp Y \Leftrightarrow \Pr(X{=}x,\ Y{=}y) = \Pr(X{=}x)\ \Pr(Y{=}y)\ \forall x, y$.

Independencia en media

Aplicación directa: La suposición clave de la regresión OLS es $E[u|X] = 0$ — el error es independiente en media del regresor.

Cuando Y es independiente de X, toda la distribución de Y es la misma para cualquier valor de X.

Una hipótesis más débil es la *independencia en media*. Y es independiente en media de X si su esperanza condicional es la misma para todos los valores de X:

$$E[Y|X] = E[Y]$$

- Es más débil que independencia: no requiere que toda la distribución sea constante.
- **No es simétrica**: que $E[Y|X] = E[Y]$ no implica $E[X|Y] = E[X]$.

Independencia en media

La siguiente tabla muestra $\Pr(X{=}x,\ Y{=}y)$:

$X \backslash Y$	0	1
-1	$1/3$	0
0	0	$1/3$
1	$1/3$	0

- ¿X e Y son independientes?
- ¿X es independiente en media de Y?
- ¿Y es independiente en media de X?
- ¿Cuál es la correlación entre X e Y?

Independencia en media

Solución

Marginales: $\Pr(X=-1)=\Pr(X=0)=\Pr(X=1)=\frac{1}{3}$; $\Pr(Y=0)=\frac{2}{3}$, $\Pr(Y=1)=\frac{1}{3}$.

- **¿X e Y independientes?** No: $\Pr(X=-1, Y=0)=\frac{1}{3}\neq\frac{1}{3}\cdot\frac{2}{3}=\frac{2}{9}$.
- **¿X ind. en media de Y?** $E[X]=0$. $E[X|Y=0]=0$ ✓; $E[X|Y=1]=0$ ✓. **Sí.**
- **¿Y ind. en media de X?** $E[Y]=\frac{1}{3}$. $E[Y|X=-1]=0\neq\frac{1}{3}$. **No.**
- **Correlación:** $E[XY]=0$, $E[X]=0\Rightarrow \mathrm{Cov}(X,Y)=0$. **Correlación cero.**

Este ejemplo ilustra que la independencia en media **no es simétrica**.

Conceptos de independencia

$$\text{Independencia} \Rightarrow \text{Independencia en media} \Rightarrow \text{Correlación cero}$$

- **Independencia**: $\Pr(x, y) = \Pr(x)\Pr(y)$
- **Independencia en media**: $E[Y|X] = E[Y]$
- **Correlación cero**: $E[XY] = E[X]E[Y]$

¿Por qué ind. en media $\Rightarrow$ correlación cero? Usando la LIE:

$$E[XY] = E\big[E[XY|X]\big] = E\big[X \cdot E[Y|X]\big] = E\big[X \cdot E[Y]\big] = E[X]\,E[Y]$$

Las implicaciones son en una sola dirección — las recíprocas no se cumplen en general.

La correlación cero y la independencia son simétricas, pero la independencia en media no

Teoría, Población y Muestra

Teoría, Población y Muestra

La teoría económica postula relaciones sobre las variables — contiene *parámetros*.

Identificación: relacionar un parámetro teórico a una cantidad en *la población*.

La población es *fija*, pero observamos una *muestra aleatoria*.

Inferencia: los estimadores (calculados con la muestra) son aleatorios; usarlos para aproximar los estimandos fijos de la población.

Próxima clase

Usaremos estas herramientas de inmediato:

- **Módulo 02**: La regresión OLS descansa en $E[u|X] = 0$ — independencia en media del error
- **Módulo 04**: El supuesto de independencia en resultados potenciales se escribe $Y^0 \perp D$
- **Módulos 09–11**: Cada estrategia de identificación es una condición de independencia diferente

A continuación: Repaso de regresión.