Repaso de Regresión

2025-02-06

¿Por qué regresión?

- Queremos entender qué determina los salarios, la salud, el crecimiento económico. . .
- La **regresión** es la herramienta estadística central en economía aplicada: resume relaciones entre variables y permite controlar por factores de confusión.
- En este módulo construimos la base técnica. En los módulos siguientes preguntaremos: ¿cuándo podemos interpretar $\hat{\beta}$ **causalmente**?

Esperanza condicional

Esperanza condicional: visualización

En datos reales, calcular $E[Y|X]$ directamente es difícil — puede no haber observaciones con exactamente el mismo X. Una solución práctica: *discretizar* el espacio y calcular la media dentro de cada bin.

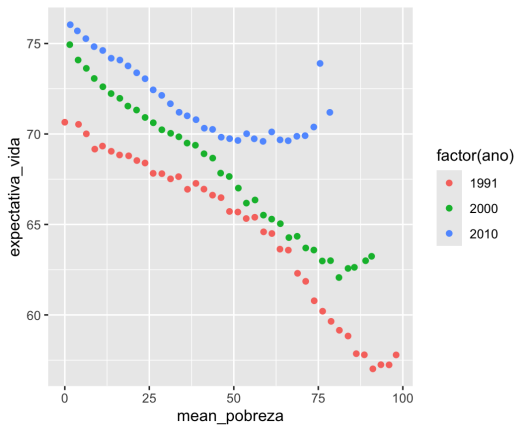

Descomposición de la CEF

Para cualesquiera variables Y y X:

$$y = E[y|x] + u$$

Con $E[u|x] = 0$ y $\mathrm{Cov}(u, f(x)) = 0$.

Cualquier variable puede descomponerse en una parte "explicada" por x y otra **ortogonal** a x. Este resultado no requiere ningún supuesto de linealidad.

CEF como mejor predictor

La esperanza condicional es el **mejor predictor** de Y dado X:

$$E[Y|X] = \arg\min_{f(x)} E\left[(Y - f(X))^2\right]$$

Si sólo disponemos de X, ninguna función $f(x)$ produce menor error cuadrático esperado que $E[Y|X]$.

Regresión lineal

Regresión lineal

Asumir que $E[Y|X]$ es lineal en X simplifica mucho el análisis:

$$y = \alpha + \beta x + u$$

Ventajas: resumimos la relación en dos números; fácil de comunicar y extender a múltiples regresores.

Limitación: si la relación verdadera no es lineal, $\hat{\beta}$ sólo captura la mejor *aproximación lineal* — puede ser poco precisa en rangos extremos de X.

Regresión poblacional

La pendiente poblacional se puede escribir como:

$$\beta = \frac{\mathrm{Cov}(x, y)}{\mathrm{Var}(x)}$$

Supuestos del modelo lineal:

- $E[u] = 0$
- Exogeneidad: $E[u|x] = 0$

Con estos supuestos, $E[y|x] = \alpha + \beta x$ — la línea de regresión coincide con la CEF.

Mínimos Cuadrados Ordinarios

MCO minimiza la suma de cuadrados de los residuos:

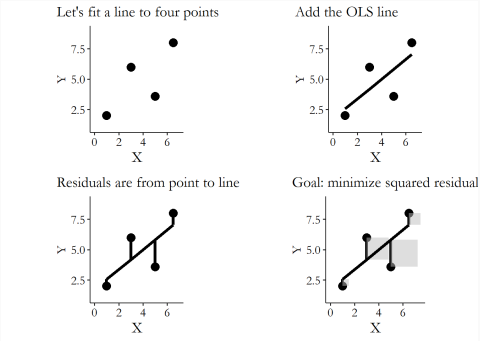

Figure 2: MCO

$$\hat{\beta} = \frac{\sum_i (x_i - \bar{x}) y_i}{\sum_i (x_i - \bar{x})^2}$$

$$\hat{\alpha} = \bar{y} - \hat{\beta}\,\bar{x}$$

El numerador es el análogo muestral de $\mathrm{Cov}(x, y)$; el denominador, de $\mathrm{Var}(x)$.

Bondad de ajuste: R^2

El R^2 mide qué fracción de la varianza de y es explicada por la regresión:

$$R^2 = 1 - \frac{\sum_i \hat{u}_i^2}{\sum_i (y_i - \bar{y})^2}$$

- $R^2 \in [0, 1]$: $0 =$ la regresión no explica nada; $1 =$ ajuste perfecto.
- Un R^2 alto **no** implica causalidad ni que el modelo sea útil para inferencia.

¡Recuerda!

La regresión poblacional es un objeto en la población. El estimador de MCO es un objeto construido con datos de una muestra.

- β es la inclinación de la CEF lineal, **fijo**. $\hat{\beta}$ es su estimador, **aleatorio**.
- X es la variable aleatoria. x_i es una observación en la muestra.
- u son los errores: la parte de Y no explicada por X. $\hat{u}$ son los residuos, su contraparte muestral.
- El supuesto clave es $E[u|X] = 0$ (exogeneidad). Cuando se viola, $\hat{\beta}$ es sesgado — el problema central del curso.

Insesgadez

El estimador de MCO es insesgado si $E[\hat{\beta}] = \beta$. Esto requiere:

1. El modelo está bien especificado (lineal en los parámetros).
2. Muestra aleatoria.
3. $\mathrm{Var}(X) \neq 0$
4. $E[u|x] = E[u] = 0$

Bajo **homocedasticidad**, MCO es además el Mejor Estimador Lineal Insesgado (MELI) — *Teorema de Gauss-Markov*.

El sesgo por endogeneidad

En la regresión simple $y = \alpha + \beta x + u$:

$$\hat{\beta} \xrightarrow{p} \beta + \underbrace{\frac{\mathrm{Cov}(x, u)}{\mathrm{Var}(x)}}_{\text{sesgo por endogeneidad}}$$

El sesgo desaparece sólo si $E[u|x] = 0$.

Ejemplo: si $x =$ educación y u contiene habilidad no observada, $\mathrm{Cov}(\text{educ}, \text{habilidad}) > 0 \Rightarrow$ MCO sobreestima el retorno a la educación.

Cada módulo del curso propone una estrategia para lograr $E[u|x] = 0$: emparejamiento (Mód. 6), IV (Mód. 9), RDD (Mód. 10) y DiD (Mód. 11).

Regresión Múltiple: el teorema FWL

En $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$, el estimador MCO de β_1 es:

$$\hat{\beta}_1 = \frac{\sum_i \tilde{x}_{1i}\, y_i}{\sum_i \tilde{x}_{1i}^2}$$

donde $\tilde{x}_{1i}$ son los **residuos** de regresar x_1 sobre x_2.

Interpretación (Frisch-Waugh-Lovell): MCO "elimina" la variación de x_2 de x_1 antes de estimar. Esto es exactamente lo que significa *controlar por* x_2.

Relevancia en el curso: DiD controla por efectos fijos. IV parcializa el instrumento. Matching elimina diferencias en observables. Todos son variantes de este principio.

Regresión Múltiple: interpretación

En una regresión múltiple, β_1 es el aumento en y asociado con un aumento de 1 unidad en x_1, *manteniendo constante* x_2.

Ejemplo

- X_1: kilos de fertilizante por m^2
- X_2: lluvia en mm
- Y: rendimiento en kg por m^2

$$Y = 30 + 0.4\,X_1 + 2\,X_2$$

Una plantación con 1 kilo más de fertilizante tiene 0.4 kg más de rendimiento, *manteniendo constante el nivel de lluvia*.

Prueba de hipótesis

Varianza y errores estándar

El error estándar de $\hat{\beta}$ mide la precisión de la estimación:

$$\widehat{se}(\hat{\beta}) = \sqrt{\frac{\hat{\sigma}^2}{\sum_i (x_i - \bar{x})^2}}$$

Aumenta con la varianza del error; disminuye con la varianza de x y con n.

Recomendación práctica: usar siempre **errores estándar robustos**.

- Si los errores son homocedásticos: no hay costo.
- Si son heterocedásticos: los SE clásicos subestiman la varianza $\rightarrow$ inferencia inválida.

Prueba de hipótesis

Procedimiento:

1. Se elige una hipótesis nula: $H_0 : \beta = \mu_0$
2. Se calcula el estadístico de prueba: $t = \dfrac{\hat{\beta} - \mu_0}{\widehat{se}(\hat{\beta})}$
3. Si $|t| > 1.96$ (valor crítico para muestras grandes), rechazamos H_0 al 5%.

En términos prácticos, el software lo calcula automáticamente. Lo que debemos saber: qué estamos probando y cómo interpretar el resultado.

Ejercicio: retorno a la educación

Estimamos:

$$\log(salario_i) = \alpha + \beta\, educ_i + u_i$$

$\hat{\beta} = 0.08$, $\widehat{se}(\hat{\beta}) = 0.036$

Pruebe $H_0 : \beta = 0$ contra $H_1 : \beta \neq 0$.

Nota: Angrist & Krueger (1991) usan el trimestre de nacimiento como instrumento para educ precisamente porque el $\hat{\beta}$ MCO puede estar sesgado al alza.

Ejercicio: Respuesta

$$t = \frac{\hat{\beta} - \mu_0}{\widehat{se}(\hat{\beta})} = \frac{0.08 - 0}{0.036} = 2.22$$

Como $|t| = 2.22 > 1.96$, **rechazamos** $H_0 : \beta = 0$ al 5%.

Un año adicional de educación tiene un efecto estadísticamente significativo sobre el salario — aunque no sabemos todavía si ese efecto es causal.

Errores comunes en inferencia

1. **"No significativo"** $\neq$ **"sin efecto"**: con muestras pequeñas es difícil rechazar hipótesis. Ausencia de evidencia no es evidencia de ausencia.
2. **Significancia estadística** $\neq$ **relevancia económica**: con n grande, efectos triviales se vuelven significativos. Reportar el tamaño del coeficiente, no solo el p-valor.
3. $p < 0.05$ **no valida el modelo**: un modelo mal especificado puede producir coeficientes significativos pero sesgados.

Formas funcionales

Variables indicadoras

Variables que toman valor 1 para un grupo y 0 para otro (*dummy*).

Ejemplo: brecha salarial de género

$$\ln(Salario_i) = \alpha + \beta_1 \cdot Mujer_i + u_i$$

$\hat{\beta}_1 \approx -0.18$: las mujeres ganan en promedio $\approx 18\%$ menos que los hombres.

Variables indicadoras: controlando por observables

Controlando por educación y experiencia:

$$\ln(Salario_i) = \alpha + \beta_1 Mujer_i + \beta_2 Educ_i + \beta_3 Exper_i + u_i$$

$\hat{\beta}_1 \approx -0.12$: brecha salarial **condicional** del $\approx 12\%$. La diferencia entre -18% y -12% es la parte explicada por diferencias en capital humano.

Variable Binaria: interpretación

- La categoría con valor 0 es la **referencia** (aquí: hombres).
- $\hat{\beta}_1$ es la diferencia de media entre el grupo 1 y el grupo de referencia, *controlando por los demás regresores*.
- En una regresión simple, el intercepto es el promedio del grupo de referencia.

Variables Categóricas

¿Cómo varía el salario según el sector económico?

Podemos regresar $\ln(Salario)$ sobre dummies de sector (referencia: Agricultura):

	$\ln(Salario)$
Manufactura	0.15^{**}
	(0.04)
Comercio	0.08^{*}
	(0.04)
Servicios	0.22^{***}
	(0.03)
Constante	12.45^{***}
	(0.02)
N	5,200
R^2	0.06

$^{*}p < 0.1$; $^{**}p < 0.05$; $^{***}p < 0.01$

Categoría de referencia: Agricultura

Variables Categóricas: interpretación

- Para variables categóricas, se elige una categoría como **referencia**.
- Cada coeficiente se interpreta como la diferencia entre su categoría y la referencia.
- Con K categorías se incluyen $K - 1$ dummies — incluirlas todas causaría multicolinealidad perfecta.

Transformaciones de variables: polinomios

La regresión lineal puede capturar relaciones no lineales incluyendo potencias de X:

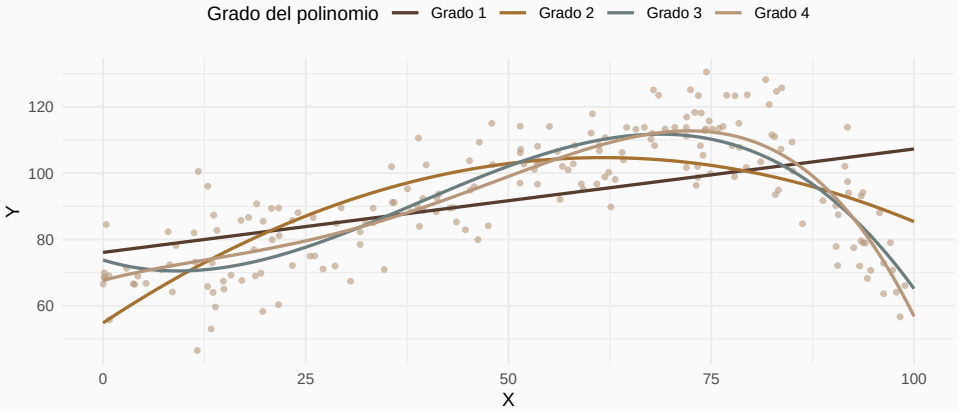

Logaritmos

En vez de regresar Y sobre X, podemos estimar $\log(Y)$ o $\log(X)$:

$$Y_i = \alpha + \beta \ln(X_i) + u_i$$

Razones para usar logaritmos:

1. Si la distribución es muy asimétrica (p. ej., ingresos), la transformación log reduce la influencia de valores extremos.
2. Variables con relaciones multiplicativas o exponenciales se vuelven aproximadamente lineales en logs.

La interpretación es en términos de **cambios relativos**.

La ecuación de Mincer

Una de las regresiones más influyentes en economía laboral:

$$\ln(Salario_i) = \alpha + \beta_1\, Educ_i + \beta_2\, Exper_i + \beta_3\, Exper_i^2 + u_i$$

- $\hat{\beta}_1 \approx 0.08$: 1 año de educación aumenta el salario en ~8%
- $\hat{\beta}_2 > 0$, $\hat{\beta}_3 < 0$: perfil de ingresos cóncavo en la experiencia
- Combina logaritmo y polinomio — en un solo modelo

Esta ecuación reaparecerá en el módulo de Variables Instrumentales (Angrist & Krueger, 1991).

Interacciones: motivación

Algunas veces, la relación entre dos variables depende de una tercera:

- El efecto del precio de la bencina en los km recorridos depende de si la persona *tiene auto*.
- Una misma política puede tener efectos distintos para mujeres y hombres, o para personas con distintos niveles de ingresos.

Para capturar este tipo de relación, usamos *interacciones*:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 Z_i + \beta_3 X_i \cdot Z_i + u_i$$

Interacciones: binaria $\times$ binaria

Una interacción entre dummies se interpreta como una diferencia adicional para un grupo.

Ejemplo

$$Ingr_i = \beta_0 + \beta_1 Mujer_i + \beta_2 EdSupr_i + \beta_3 Mujer_i \cdot EdSupr_i + u_i$$

Ingresos promedio de:

- Hombres sin educación superior: β_0
- Mujeres sin educación superior: $\beta_0 + \beta_1$
- Hombres con educación superior: $\beta_0 + \beta_2$
- Mujeres con educación superior: $\beta_0 + \beta_1 + \beta_2 + \beta_3$

β_3 captura si la *brecha de género en ingresos* difiere entre quienes tienen o no educación superior.

Interacciones: continua $\times$ binaria

Una interacción entre una variable continua y una dummy permite **pendientes distintas** por grupo.

Ejemplo

$$Ingr_i = \beta_0 + \beta_1 Mujer_i + \beta_2 Educ_i + \beta_3 Mujer_i \cdot Educ_i + u_i$$

El retorno a la educación es:

- Para hombres: β_2
- Para mujeres: $\beta_2 + \beta_3$

$\beta_3 < 0$ indicaría que las mujeres obtienen un menor retorno por cada año adicional de educación.