

La Revolución de la Credibilidad

Historia intelectual y cierre del arco metodológico

2026-05-04

Bloque 1: La Revolución de la Credibilidad


1. ¿Dónde estamos? El arco del curso
2. La crisis: Leamer (1983) y el problema de la especificación
3. El choque empírico: LaLonde (1986) y el debate del PS
4. Diseño sobre modelo: Mariel y la lotería de Vietnam
5. La crítica de Heckman
6. Puente al post-midterm

Al terminar este bloque, deberías poder:

1. Explicar por qué la econometría aplicada entró en crisis antes de los 90 y cómo se conecta con OVB
2. Ubicar LaLonde (1986), Dehejia-Wahba (1999) y Smith-Todd (2005) como un debate metodológico, no solo técnico
3. Describir qué es un experimento natural y cómo se relaciona con los métodos del curso
4. Identificar la limitación fundamental que los métodos basados en observables no pueden superar

1. ¿Dónde estamos?

El arco del curso



Vimos este mapa en la primera clase. Hoy recorreremos la transición **Estructura** → **Credibilidad** con los papers que la provocaron.

Las tres estrategias: ¿qué aprendimos?

Una pregunta, tres respuestas:

Estrategia	Supuesto de identificacion	Lo que vimos
Regresion OLS	$E[U X, D] = 0$ (no OVB)	Modulos 2 y 6
Matching / PS	CIA: $(Y(1), Y(0)) \perp D X$	Modulo 6
RCT	D asignado aleatoriamente	Modulo 5

Cada estrategia es una respuesta a: *dado tratamiento no aleatorio, ¿cómo recuperamos el efecto causal?*

Hoy vemos por qué **ninguna de estas era la respuesta dominante antes de 1990** — y qué cambió.

2. La crisis: Leamer (1983)

El paradigma estructural (Haavelmo, 1944; Comisión Cowles):

- La economía tiene un sistema de ecuaciones causales subyacente
- La teoría económica provee las restricciones que identifican el modelo
- Si especificas bien el modelo completo, obtienes estimaciones causales

El problema: los modelos son enormemente sensibles a qué variables incluir, qué ecuaciones escribir, y qué restricciones imponer.

- ¿Qué entra al lado derecho de la regresión?
- ¿Linealidad? ¿Interacciones? ¿Polinomios?
- Distintas elecciones “razonables” → conclusiones opuestas

Leamer (1983): “Let’s Take the Con Out of Econometrics”

Leamer documenta sistemáticamente que los mismos datos producen conclusiones opuestas según la especificación.

Análisis de cotas extremas (*extreme bounds*): variar el conjunto de controles “razonables” y registrar cuánto cambia el coeficiente de interés.

“Nadie toma en serio los análisis de datos de otros econometristas.”

— Leamer (1983, p.~37)

Si el efecto cambia de signo dependiendo de qué controles se incluyen: ¿en qué resultado debería confiar un lector?

Leamer está describiendo el problema de **sesgo por variable omitida** en toda su extensión:

- Cada especificación incluye o excluye controles distintos $\rightarrow$ distinto $\hat{\beta}$ (recuerda Frisch-Waugh-Lovell)
- Sin un criterio **externo** para elegir especificación, la elección es arbitraria
- La crítica es estructural: no hay una regresión “correcta” sin una fuente de identificación creíble

La respuesta de la nueva generación

Angrist, Card, Imbens y otros propusieron cambiar la pregunta:

Antes: ¿cómo especifico el modelo para controlar todo el sesgo?

Después: ¿qué *fente de variación* me permite comparar unidades similares sin suponer que controlo todo?

Cambio de paradigma

De “¿cómo controlo suficiente?” a “¿qué varió cuasi-aleatoriamente?”

Angrist y Pischke (2010) llaman a esto la **Revolución de la Credibilidad**: identificación transparente > modelo sofisticado con supuestos dudosos.

3. El choque empírico: LaLonde y el debate del PS

National Supported Work (NSW): experimento aleatorio de empleo subsidiado para poblaciones vulnerables (Estados Unidos, 1970s–80s).

- Participantes: ex-criminales, exadictos, mujeres en asistencia social, jóvenes sin diploma
- Tratados: empleo garantizado por 9–18 meses
- Grupo de control: excluidos del programa **por sorteo**

Efecto experimental sobre ingresos: $\approx \$1,794$ (comparacion directa entre grupos asignados aleatoriamente)

Lalonde (1986) se pregunta: *si no tuviéramos el grupo de control experimental, ¿podríamos recuperar este efecto con métodos observacionales?*

Los grupos de comparación observacionales

Lalonde construye **6 grupos de control no experimentales** a partir de dos encuestas:

- **PSID 1–3** (*Panel Study of Income Dynamics*): hombres jefes de hogar con distintas restricciones de empleo y edad
- **CPS 1–3** (*Current Population Survey*): hombres con restricciones de edad, desempleo e ingresos

Sobre cada grupo prueba **7 estimadores**:

- Diferencia de medias
- OLS con distintos conjuntos de controles
- Diferencias en diferencias (con y sin controles)

El resultado de LaLonde (1986)

Los estimadores **experimentales** son robustos: similares entre sí, todos cerca de \$1,794.

Los estimadores **no experimentales** son inestables:

- Estimados que van desde $-\$15,000$ hasta $+\$2,000$ según grupo y especificación
- Muchos son negativos — el “efecto del tratamiento” aparece como *perjudicial*
- Incluir más controles mejora algo, pero no elimina el sesgo

Conclusion de Lalonde

Los metodos observacionales estandar **no pueden recuperar el benchmark experimental**. Un resultado perturbador para la evaluacion de politicas sociales.

¿Por qué fallan? El vínculo con PS

El diagnóstico conecta directamente con el módulo 6:

- Los controles del PSID y CPS son **muy distintos** a los tratados del NSW en características observables y no observables
- El **soporte común es limitado**: la mayoría de los controles cae en valores del propensity score donde casi no hay tratados

El rescate: Dehejia y Wahba (1999)

Dehejia y Wahba retoman los datos de LaLonde con dos ajustes:

1. **Propensity score** con especificación cuidadosa: polinomios, interacciones, estimación iterativa hasta lograr balance
2. **Soporte común** estricto: excluir controles fuera del rango del PS de los tratados

Resultado: sus estimadores PS recuperan el benchmark experimental ($\approx \$1,600$ – $\$1,800$).

Mensaje: el matching con PS *puede* recuperar el efecto causal **si se cuida el soporte común**.

La especificación del módulo 6 sigue directamente a Dehejia y Wahba (1999).

Smith y Todd (2005): la re-evaluación

Smith y Todd aplican los métodos de Dehejia-Wahba con variaciones pequeñas:

1. La muestra original completa de LaLonde (sin la restricción de D&W de excluir tardíos)
2. Distintas combinaciones de variables en el PS

Resultado: los estimadores PS vuelven a tener sesgo grande. La recuperación de D&W es **sensible a elecciones de muestra que parecen menores**.

Conclusión del debate:

- PS + soporte común *ayuda*, pero no es garantía
- La CIA no se puede verificar directamente: la credibilidad descansa en supuestos no testeables
- **Esto motiva buscar variación que no dependa de la ignorabilidad**

4. Diseño sobre modelo: experimentos naturales

La idea del experimento natural

Si no podemos aleatorizar, ¿podemos encontrar situaciones donde la naturaleza o la política *casi* aleatorizó por nosotros?

Experimento natural: un evento externo (política, desastre, lotería, regla institucional) crea variación en el tratamiento que es *aproximadamente* independiente de las características de las unidades.

- La variación en D no es intencional desde la perspectiva del investigador
- Pero se origina en algo exógeno $\rightarrow$ permite comparaciones creíbles
- La *transparencia del diseño* reemplaza los supuestos de ignorabilidad

Los métodos de la segunda parte del curso son formalizaciones de esta idea.

Mariel: el diseño (Card, 1990)

Evento: entre abril y octubre de 1980, $\approx 125,000$ cubanos llegaron súbitamente a Miami (*Boatlift de Mariel*).

- Aumentó la fuerza laboral de Miami en $\approx 7\%$ en pocos meses
- Concentrada en trabajadores poco calificados
- La llegada fue **inesperada** — no hubo anticipación ni ajuste previo del mercado

Pregunta de Card: ¿qué le pasó a los salarios y el desempleo de los trabajadores locales poco calificados?

Diseño: comparar Miami antes y después del boatlift, con **ciudades similares como contrafactual** (Atlanta, Houston, Los Ángeles, Tampa).

Reconoces esta logica: es la base de Diferencias en Diferencias — modulo 11.

Mariel: el resultado y su debate

Card (1990): ningún impacto detectable sobre salarios ni desempleo de trabajadores poco calificados en Miami. La ciudad absorbió el shock sin efectos negativos apreciables.

Borjas (2017): reanaliza restringiendo al subgrupo de trabajadores *sin diploma de secundaria*. Encuentra impacto negativo de $\approx 10\text{--}25\%$ en los salarios de ese grupo.

Card y Peri (2016): la restricción de Borjas produce una muestra pequeña e inestable; los resultados cambian con pequeños ajustes.

El debate no está resuelto — pero ilustra algo importante:

Leccion metodologica

La transparencia del diseño de Card invita al escrutinio: cualquiera puede reproducir el analisis y variar las decisiones. Esto **es** la revolucion de la credibilidad en accion.

La lotería de Vietnam (Angrist, 1990)

Contexto: el reclutamiento para Vietnam (1969–1971) se determinó por **lotería**: a cada hombre se le asignó un número del 1 al 365 según su fecha de cumpleaños. Los números más bajos eran llamados primero.

- El número asignado es **aleatorio** → es un instrumento para el servicio militar
- Los hombres con número bajo tenían $\approx 50\%$ más probabilidad de servir

Pregunta: ¿cuál es el efecto de haber servido en Vietnam sobre los ingresos futuros?

Resultado de Angrist: los veteranos ganan aproximadamente 15% menos que los no veteranos comparables.

Del ATE al LATE: semilla para el post-midterm

Problema: no todos los hombres con números bajos sirvieron (obtuvieron exenciones médicas, educativas, etc.), y algunos con números altos se alistaron voluntariamente.

- Hay **incumplimiento imperfecto** con la asignación de la lotería
- Angrist no puede estimar el efecto promedio sobre *todos* los hombres
- Solo puede estimar el efecto sobre quienes **realmente cambiaron de conducta** al recibir un número bajo: los *compliers*
- Este efecto local se llama **LATE** (Local Average Treatment Effect)

Proxima clase: Cumplimiento Imperfecto

El modulo 8 formaliza exactamente este problema. El paper de Angrist (1990) es su motivación histórica y su ejemplo canónico.

5. La crítica de Heckman

Validez interna vs. validez externa

La Revolución de la Credibilidad ganó en **validez interna**: estimaciones creíbles *para la población y contexto del estudio*.

Heckman señala que esto tiene un costo:

- Los diseños estiman el efecto sobre *quienes respondieron a la variación exógena* (compliers, unidades cerca del umbral) — no sobre toda la población
- Los parámetros relevantes para política (*¿qué pasa si expandimos el programa?*) requieren **extrapolación estructural** — precisamente lo que los diseños evitan
- La **validez externa** no está garantizada por el diseño

Lo que el diseño no puede darte

En términos del marco de resultados potenciales:

- El diseño identifica $E[Y(1) - Y(0) \mid \text{compliers}]$ o el efecto local en el umbral
- No identifica el ATE si hay heterogeneidad de efectos y los “compliers” no son representativos
- No permite simular cambios de política que van más allá de la variación exógena observada

Posición de Heckman: necesitamos tanto diseños creíbles *como* modelos estructurales — la elección depende de la pregunta.

El debate entre el enfoque “reduced-form” (Angrist-Pischke) y el estructural (Heckman, Wolpin) está activo en la disciplina. No hay consenso.

6. Puente al post-midterm

La segunda parte del curso

Hasta aquí: condicionamos en observables para hacer grupos comparables — requiere CIA.

Segunda parte: explotamos variación que es independiente de los no observables **por diseño**.

Modulo	Metodo	Fuente de variacion cuasi-aleatoria
8	Cumplimiento Imperfecto	Asignacion con no-cumplimiento
9	Variables Instrumentales	Instrumento exogeno
10	Discontinuidad en Regresion	Umbral de asignacion
11	Diferencias en Diferencias	Variacion en tiempo y grupo
12	Control Sintetico	Comparador construido

Parte 1 (modulos 3–7)

Condicionamos en X para hacer D independiente de U :

Regresion, matching, PS $\rightarrow$ supuesto de **ignorabilidad condicional (CIA)**

Parte 2 (modulos 8–12)

Buscamos variacion en D que ya es independiente de U por diseno:

IV, RDD, DID, SC $\rightarrow$ supuesto de **exogeneidad del instrumento o la variacion**

Los dos enfoques son **complementarios**, no rivales. La elección depende del contexto, los datos disponibles, y la pregunta de política.

Bloque 2: Preparación para el examen

Miércoles 6 de mayo

- **Temas cubiertos:** módulos 3–7 (DAGs, Resultados Potenciales, RCTs, Regresión, Matching, PS, Inferencia)
- **Formato:** *(completar)*
- **Material permitido:** *(completar)*
- **Duración:** *(completar)*

El examen evalúa interpretación y juicio sobre diseños de investigación, no derivaciones matemáticas.

¿Qué preguntas tienen?

Todo el material de los módulos 3–7 es válido.

Avanzar solo si hay tiempo

Un investigador estima el efecto de la educación (D) sobre el ingreso (Y). Incluye como control el tipo de trabajo (M , que está en el camino causal $D \rightarrow M \rightarrow Y$) y también el ingreso del padre (F , que afecta tanto D como Y).

1. Dibuja el DAG.
2. ¿Qué pasa si controlamos por M ? ¿Y si no controlamos?
3. ¿Qué pasa si no controlamos por F ?
4. ¿Cuál es el conjunto de control correcto para estimar el efecto total de D sobre Y ?

Avanzar solo si hay tiempo

Un investigador estima el efecto del tamaño del aula (D , número de alumnos) sobre el rendimiento académico (Y). Corre la regresión $Y_i = \alpha + \beta D_i + \varepsilon_i$ y encuentra $\hat{\beta} < 0$.

1. ¿Qué variables podrían estar omitidas que generarían OVB en $\hat{\beta}$?
2. ¿En qué dirección iría el sesgo para cada variable que mencionas?
3. ¿Qué estrategia de identificación usarías para obtener un estimado creíble? *(Puede ser cualquiera de las que vimos.)*

Avanzar solo si hay tiempo

Un investigador aplica PS matching para evaluar un programa de capacitación laboral. El histograma del PS muestra:

- Los tratados: distribuidos entre 0.1 y 0.9
 - Los controles: $\approx 85\%$ apilados entre 0 y 0.1
1. ¿Qué diagnóstico haces del soporte común?
 2. ¿Puedes estimar el ATT? ¿El ATE? ¿Por qué?
 3. ¿Qué harías para proceder de todas formas? ¿Qué cambia en el estimand?